

Syllabus: 공정 의사결정을 위한 서로게이트 모델

공정 예측, physics-informed learning, 최적화 embedding을 연결하는 화학공학 대학원 입문 8주 과정입니다.

과목 설계·강의 노트: Sunwoo Kim · 대학원 입문 · 수정 2026-10-06

과목의 목적

공정 surrogate는 공정 모델이나 측정값의 입력-출력 관계를 근사한다. 의사결정 시스템에는 조작변수, 목적함수, 제약, 그리고 선택한 운전점을 검증하는 절차도 필요하다. 이 과목은 예측 정확도만으로 좋은 의사결정을 주장하지 않고, 이 과정을 연결해 공부한다.

Sunwoo Kim이 화학공학 대학원 입문자를 위해 직접 구성한 독립적인 자율 학습 과정이다. 직접 작성한 설명과 연습문제를 인용한 연구 논문에 연결한다.

수강 대상과 선수 지식

Python 기초, 미분, 행렬 연산, 선형대수, 물질수지를 알고 있다고 가정한다. 신경망이나 수리계획 연구 경험은 요구하지 않는다. LP/MILP, convexity, KKT 조건은 필요한 시점에 설명한다.

권장 주간 학습량은 이론 90분, 안내된 실습 60-90분, 읽기·연습문제 2-3시간이다. 실제 수업 시간표가 아니라 자율 학습을 위한 제안이다.

학습 목표

과정을 마친 뒤에는 다음을 할 수 있어야 한다.

1. 의사결정 변수, 고정 context, 상태, 출력, 단위, 유효한 운전 영역을 정의한다.
2. 미래 조작변수 계획을 입력으로 받는 모델을 포함해 정상상태 vector-to-vector와 동적 sequence-to-sequence surrogate를 구축하고 평가한다.
3. 데이터 기반, soft physics-informed, hard 선형 등식 제약 모델을 예측 오차와 제약 residual로 각각 비교한다.
4. 학습 후 고정된 ReLU 신경망의 유효한 MILP graph formulation을 유도하고 forward 출력과 수치적으로 대조한다.
5. ReLU ICNN/PICNN의 LP epigraph formulation이 가능한 조건과 원래 문제와 동치가 아닌 경우를 설명한다.
6. 공정 모델 재검증, feasibility, 의사결정 품질, bounds, solver 종료 상태, 계산 시간을 각각 보고한다.

8주 구성

주차	주제와 범위	결과물
1	공정 예측에서 의사결정으로. 변수·단위·운전 영역, 데이터 분할, 최적화 문제, 공정 모델 재검증.	CSTR 문제 정의와 재현 가능한 예측-의사결정 baseline.
2	정상상태 vector-to-vector surrogate. 다출력 MLP, scaling, sampling, 출력별 오차와 수지 residual.	운전 영역과 독립 평가 결과를 명시한 다출력 MLP.
3	동적 sequence-to-sequence surrogate. Window MLP, 상태전이, RNN/LSTM, direct prediction, rollout, 궤적 단위 분할.	미래 조작변수 계획을 입력으로 받는 one-step-multi-step 예측.
4	Physics-informed learning과 KKT-hPINN. Residual loss, 자동미분, 선형 등식 projection, KKT 유도과 rank 조건.	예측 정확도와 제약 만족을 각각 평가하는 MLP/PINN/KKT-hPINN 비교.
5	ReLU 신경망의 exact MILP embedding. 신경망 graph, binary variable, Big-M 유도, 유효한 activation bounds와 scaling.	고정 입력에서 학습된 신경망과 출력이 일치하는 직접 작성한 embedding.
6	Embedding 실무: bounds, OMLT, horizon. Bound tightening, LP relaxation, MIP gap, OMLT, affine projection layer와 유한 horizon ReLU 모델.	Forward 재검증을 포함한 formulation-풀이 시간 비교.
7	ICNN/PICNN과 조건부 LP reformulation. Convexity 조건, epigraph, 고정 context, 제약 방향과 등식 반례.	Convexity가 확인된 예제의 LP와 동치 조건 목록.
8	공정 의사결정 전체 workflow. 의사결정 지점 오차, extrapolation, feasibility, 경제성, 공정 모델 재검증과 데이터 추가.	모델 오차-의사결정 품질-제약 위반-계산 시간을 보고하는 재현 가능한 결과물.

2-4주차는 모델 구축과 평가, 5-7주차는 최적화 embedding에 집중한다. 8주차에서 두 부분을 연결한다. 현재 syllabus와 **1주차**를 공개했다. 2-8주차는 강의 계획이며 해당 주차의 강의 노트는 아직 공개하지 않았다.

주차별 읽기 안내

주차	읽기 범위
1	Boyd & Vandenberghe 2-4장 중 지정 내용; OMLT 서론.
2	KKT-hPINN 1-3절 중 MLP와 공정 surrogate 문제 설정.
3	Sutskever et al. 1-2절; DeepONet 서론(선택).
4	Raissi et al.의 PINN formulation; Chen et al. 3절과 선정 공정 사례.
5	Anderson et al.의 formulation 기초와 ReLU formulation.
6	OMLT 논문·문서; Anderson et al.의 강한 formulation 중 지정 내용.
7	Amos et al. 3절과 Supplement B.
8	1-7주차의 가정과 검증 결과 재검토.

지정된 절을 읽는 방식이다. 매주 여러 논문 전체를 읽도록 요구하지 않는다. 고급 formulation 증명과 operator learning 확장은 선택 내용이다.

핵심 참고자료

- **Convex optimization 기초:** S. Boyd와 L. Vandenberghe, *Convex Optimization* (2004). 2–4장의 convex set, convex function, epigraph, 최적화 문제 관련 내용을 읽고, duality와 KKT는 5장으로 돌아온다. **공식 교재·다운로드·EE364a 슬라이드.**
- **ICNN/PICNN:** B. Amos, L. Xu, J. Z. Kolter, *Input Convex Neural Networks*, ICML (2017). 3절은 구조 조건, Supplement B는 ReLU/linear unit의 LP inference를 설명한다. **논문·PDF·Supplement.**
- **ReLU formulation:** R. Anderson, J. Huchette, W. Ma, C. Tjandraatmadja, J. P. Vielma, *Strong mixed-integer programming formulations for trained neural networks*, Mathematical Programming (2020). 공개 원고는 2018년 처음 제출되었고 2020년 수정되었다. **공개 원고.**
- **Embedding 소프트웨어:** F. Ceccon, J. Jalving, J. Haddad, A. Thebelt, C. Tsay, C. D. Laird, R. Misener, *OMLT: Optimization & Machine Learning Toolkit*, JMLR 23(349), 1–8 (2022). **논문·PDF·코드·문서.**
- **PINN:** M. Raissi, P. Perdikaris, G. E. Karniadakis, *Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations*, Journal of Computational Physics 378, 686–707 (2019). **정식 논문.** 관련 2017년 Part I 원고는 공개 입문 자료로 활용한다. 최종 학술지 논문과 동일한 버전은 아니다. **2017 Part I.**
- **KKT-hPINN:** H. Chen, G. E. Constante Flores, C. Li, *Physics-informed neural networks with hard linear equality constraints*, Computers & Chemical Engineering 189, 108764 (2024). **정식 논문·공개 원고·코드·데이터.**
- **Sequence learning 기초:** I. Sutskever, O. Vinyals, Q. V. Le, *Sequence to Sequence Learning with Neural Networks*, NeurIPS (2014). 원 논문의 응용은 번역이며, 이 강의의 공정 궤적 실습은 별도로 만든 교육 예제다. **논문.**

선택 확장: 입력 함수에서 출력 함수로의 mapping을 다루는 **DeepONet, Nature Machine Intelligence (2021)**; 비선형 등식·부등식 projection을 다루는 **KKT-Hardnet 공개 원고(2025), C&CE 출판(2026).**

공정 예제와 소프트웨어

주요 교육 예제는 1차 반응을 갖는 작은 등온 CSTR이다. 1주차에 지배식, 교육용 가상 파라미터, 정상상태 mapping, 동적 시뮬레이션을 제공한다. Aspen이나 플랜트 데이터 없이 실행할 수 있다. 공개 KKT-hPINN 데이터는 별도의 연구 재현 실습에 활용하며, 이 강의의 교육용 simulator가 생성한 데이터와 구분한다.

Convexity와 LP 동치성은 convex target이 알려진 별도 예제에서 먼저 확인한다. ICNN 근사 함수가 convex라는 사실이 실제 CSTR나 flowsheet의 모든 출력이 convex라는 뜻은 아니다.

1주차에는 Python, NumPy, Matplotlib이 필요하다. 이후 PyTorch, Pyomo/OMLT와 적절한 solver를 소개한다. 첫 실습은 notebook과 독립 Python 스크립트를 함께 제공하므로 Jupyter가 필수는 아니다.

이 과목에서 exact와 hard가 뜻하는 것

- **Exact embedding:** 명시한 영역에서 학습 후 고정된 함수를 표현한다. 물리 공정에 대한 근사 오차를 없애지 않는다. 전체 문제가 MILP인지는 나머지 목적함수와 제약에도 달려 있다.
- **LP reformulation:** ReLU/linear ICNN 구조, 고정된 PICNN context, 유효한 비음수 전파, 적절한 epigraph 사용이 필요하다. 임의의 출력 등식, 반대 방향 부등식, smooth activation, 추가 비선형 제약은 LP라는 주장을 무효화할 수 있다.

- **Hard constraint:** KKT-hPINN은 행렬 가정하에서 명시된 일관된 선형 등식을 수치 연산 오차 범위에서 만족시킨다. 양수성, 비선형 열역학, 안정성, 모든 운전 한계를 자동으로 만족시키지는 않는다.
- **Physics-informed 모델의 최적화 활용:** 학습 loss가 고정된 predictor의 대수적 종류를 결정하지 않는다. ReLU backbone에 고정 affine 등식 projection을 붙이면 piecewise affine 구조를 유지한다. Smooth 또는 비선형 projection은 필요한 formulation을 바꿀 수 있다.

연습문제와 종합 프로젝트

매주 수식 유도 또는 문제 정의를 실행 가능한 확인 절차에 연결한다. 최종 보고서에는 데이터 영역, 분할 방법, 모델 구조, 고정된 가중치, scaling, formulation 가정, solver-종료 상태, 재검증용 simulator를 명시한다.

독립 평가점과 선택한 의사결정 지점 모두에서 예측 오차와 제약 위반을 평가한다. 경제성은 기준 공정 모델로 비교한다. Grid나 local solver를 기준으로 사용했다면 grid 또는 local benchmark라고 쓰며, 인증된 공정 전역 최적해라고 부르지 않는다.

자율 학습에서는 수리 formulation의 정확성, 재현성, 의사결정 품질의 근거, 남은 오차-feasibility 문제에 대한 정확한 보고로 프로젝트를 평가한다. 미완료 solve나 실패한 운전점도 정확하게 보고하면 유용한 근거가 된다.