강의계획서: 공정 예측과 최적화를 위한 서로게이트 모델링

공정 예측 모델을 학습·검증하고, 최적화 정식화와 모델 구조를 배운 뒤 운전 조건을 선택하고 재검증하는 8주 과정입니다.

과목 설계·강의 노트: Sunwoo Kim · 대학원 입문

과목의 목적

입력과 출력을 정의하고 데이터로 공정 응답을 예측하는 surrogate를 학습한 뒤, 독립적인 조건에서 예측을 검증합니다. 이어서 물리적 일관성을 평가하고 학습된 함수를 최적화 문제에 넣어 운전 조건을 선택한 다음, 기준 공정 모델로 재검증합니다.

이미 학습된 모델을 최적화 문제로 정식화하는 방법과 최적화 활용에 맞춰 모델 구조를 설계하는 방법을 함께 다룹니다. 예측 오차, 물리적 일관성, 정식화의 일치성, 의사결정 품질은 구분해 평가합니다.

Sunwoo Kim이 화학공학 대학원 입문자를 위해 설계한 8주 자율 학습 과정입니다. 직접 작성한 설명과 계산을 포함한 읽기자료, 실행 예제를 검증된 연구 원문과 함께 제공합니다.

수강 대상과 선수 지식

Python 기초, 미분, 행렬 연산, 선형대수, 물질수지 지식을 전제로 합니다. LP/MILP, convexity, KKT 조건은 필요한 시점에 설명하므로 신경망이나 수리계획 연구 경험은 없어도 됩니다.

주당 이론 90분, 안내된 실습 60–90분, 읽기·연습문제 2–3시간을 권장합니다.

학습 목표

과정을 마치면 다음 작업을 수행할 수 있어야 합니다.

1. 공정 예측 문제의 입력·출력·고정 context·상태·단위·데이터 분할·유효한 영역을 정의합니다.
2. 정상상태·동적 surrogate를 학습하고, 독립 데이터와 정해진 미래 입력으로 성분별·궤적 예측 오차를 평가합니다.
3. 일반 모델, soft physics 모델, hard 선형 등식 모델을 비교하고 예측 정확도와 물리적 일관성을 구분합니다.
4. 조작변수·목적함수·제약을 정의하고, 고정된 ReLU 모델의 유효한 MILP 표현을 작성해 forward 출력과 대조합니다.
5. 활용 목적에 맞는 모델 구조와 정식화를 선택하고, ReLU ICNN/PICNN epigraph가 동치인 LP 문제를 허용하는 조건을 확인합니다.
6. Surrogate 기반 운전 최적화를 풀고 기준 공정 모델의 제약 만족·경제성·solver 종료 상태·gap·시간을 각각 보고합니다.

8주 구성

주차	주제와 범위	필수 결과물
1	**공정 예측과 surrogate 모델의 기초.** 입력·출력·고정 context·단위·운전 영역, 기준 데이터, 회귀 baseline과 독립 예측 평가.	정상상태 CSTR 예측 문제 정의, 회귀 baseline과 독립 test 평가 보고서.
2	**MLP로 다성분 정상상태 응답 학습하기.** 세 성분 수지, scaling, MLP forward·backpropagation, 학습, 성분별 오차와 농도 합 일관성.	물리 단위로 평가한 정상상태 MLP와 손 계산으로 확인한 gradient 갱신.
3	**동적 응답 예측과 rollout.** 상태전이 MLP, 초기 상태, 미래 운전 입력, one-step 예측과 전체 궤적 rollout. RNN/LSTM·encoder–decoder는 선택 확장.	정해진 미래 입력에 대한 one-step·전체 궤적 오차 비교.
4	**물리 제약을 반영한 학습.** Residual loss, 자동미분, hard 선형 등식 projection, KKT 유도, rank 가정과 남은 제약 위반.	정확도와 물리적 일관성을 구분한 MLP·soft physics·hard 등식 모델 비교.
5	**예측 모델을 최적화 문제에 넣기.** 조작변수와 고정 context, 목적함수·제약, 고정된 ReLU graph, binary variable, Big-M, 유효한 bounds와 scaling.	고정 신경망의 forward 출력과 대조한 직접 작성한 MILP 표현.
6	**실제로 풀 수 있는 정식화 만들기.** Bound tightening, scaling, OMLT, relaxation, solver 종료 상태, gap, 계산 시간과 선택 short-horizon 확장.	Bounds·종료 상태·gap·계산 시간·forward 재확인을 기록한 운전 최적화 풀이.
7	**최적화 활용을 위한 모델 구조 설계.** ICNN/PICNN, convexity 조건, ReLU/linear epigraph, 고정 context, 부등식 방향과 동치성 반례.	알려진 convex 예제의 ICNN·유효한 LP와 적용 조건 목록.
8	**운전 조건 선택과 공정 모델 재검증.** 선택 지점의 오차, extrapolation, 물리적 feasibility, 경제성, 기준 공정 모델 재검증과 데이터 보완.	오차·제약 위반·의사결정 품질·계산 부담을 구분한 재현 가능한 예측–최적화 보고서.

1–3주차에는 예측 모델을 구축하고 4주차에는 물리적 일관성을 확인합니다. 5–6주차에서 학습된 모델을 최적화 문제로 정식화하고 풀이하며, 7주차에서는 최적화에 맞는 모델 구조를 설계합니다. 8주차에는 이 과정을 연결해 운전 조건을 선택하고 재검증합니다. 1주차의 운전 의사결정 예시는 후반부 학습을 미리 보여주는 짧은 예고입니다.

현재 강의계획서와 **1주차**, **2주차**, **3주차**, **4주차**, **5주차** 강의자료를 제공합니다. 6–8주차는 계획 단계입니다.

주차별 읽기 안내

주차	읽기 범위
1	1주차 직접 제공 읽기자료; Boyd & Vandenberghe의 affine mapping 관련 내용(선택).
2	2주차 직접 제공 읽기자료; PyTorch 모델 구성·autograd·학습 tutorial의 지정 내용.
3	3주차 직접 제공 읽기자료: 상태전이 유도·계산 예·평가 코드; Sutskever et al. 1–2절(선택).
4	4주차 직접 제공 읽기자료; Raissi et al.의 residual-loss formulation; Chen et al. 3절과 선정 공정 사례.
5	5주차 직접 제공 읽기자료; Boyd & Vandenberghe의 최적화 문제 관련 지정 내용; Anderson et al.의 ReLU formulation.
6	OMLT 논문·문서; Anderson et al.의 강한 formulation 중 지정 내용.
7	Amos et al. 3절과 Supplement B.
8	1–7주차 모델·정식화 가정, 검증 근거와 기준 결과 재검토.

1주차, **2주차**, **3주차**, **4주차**, **5주차 읽기자료**를 국문·영문 PDF로도 제공합니다. 외부 원문은 지정된 절을 읽습니다. RNN/LSTM·encoder–decoder·DeepONet, 고급 formulation 증명과 긴 horizon 예제는 선택 확장입니다.

핵심 참고자료

- Convex optimization 기초: S. Boyd와 L. Vandenberghe, *Convex Optimization* (2004). 2–4장의 convex set, convex function, epigraph, 최적화 문제 관련 내용을 읽고 duality와 KKT는 5장을 참고합니다. **공식 교재·다운로드** · **EE364a 슬라이드**.
- 신경망 구현: PyTorch tutorial의 **모델 구성**, **autograd**, **학습**.
- ICNN/PICNN: B. Amos, L. Xu, J. Z. Kolter, *Input Convex Neural Networks*, ICML (2017). 3절은 구조 조건, Supplement B는 ReLU/linear unit의 LP inference를 설명합니다. **논문** · **PDF** · **Supplement**.
- ReLU formulation: R. Anderson, J. Huchette, W. Ma, C. Tjandraatmadja, J. P. Vielma, *Strong mixed-integer programming formulations for trained neural networks*, Mathematical Programming (2020). 공개 원고는 2018년 처음 제출되었고 2020년 수정되었습니다. **공개 원고**.
- Embedding 소프트웨어: F. Ceccon, J. Jalving, J. Haddad, A. Thebelt, C. Tsay, C. D. Laird, R. Misener, *OMLT: Optimization & Machine Learning Toolkit*, JMLR 23(349), 1–8 (2022). **논문·PDF** · **코드** · **문서**.
- PINN: M. Raissi, P. Perdikaris, G. E. Karniadakis, *Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations*, Journal of Computational Physics 378, 686–707 (2019). **정식 논문**. 관련 2017년 Part I 원고는 공개 입문 자료로 활용하며, 최종 학술지 논문과는 버전이 다릅니다. **2017 Part I**.
- KKT-hPINN: H. Chen, G. E. Constante Flores, C. Li, *Physics-informed neural networks with hard linear equality constraints*, Computers & Chemical Engineering 189, 108764 (2024). **정식 논문** · **공개 원고** · **코드·데이터**.
- Sequence learning 기초: I. Sutskever, O. Vinyals, Q. V. Le, *Sequence to Sequence Learning with Neural Networks*, NeurIPS (2014). 원 논문은 번역을 다루며, 이 강의의 공정 궤적 실습은 별도로 만든 교육 예제입니다. **논문**.

선택 확장: 입력 함수를 출력 함수로 매핑하는 **DeepONet, Nature Machine Intelligence (2021)**; 비선형 등식·부등식 projection을 다루는 **KKT-Hardnet 공개 원고(2025), C&CE 출판(2026)**.

연습문제와 종합 프로젝트

1주차에는 예측 문제 정의, 학습한 baseline, 독립 test 평가를 제출합니다. 2주차에는 정상상태 MLP, 손 계산으로 확인한 gradient 갱신, 성분별 오차와 일관성 진단을 제출합니다. 이후 주차에서는 검증한 요소를 하나씩 연결합니다.

최종 프로젝트에는 영역, 데이터 분할, 모델 구조, 고정 가중치, scaling, 정식화 가정, solver 종료 상태와 기준 공정을 명시합니다. 독립 데이터의 예측 오차, 물리적 일관성, 정식화의 일치성, 선택한 운전 조건의 품질은 구분해 평가합니다. 경제성은 기준 모델과 비교하며, grid나 local solver 결과를 비교 기준으로 사용했다면 이를 명시하고 인증된 공정 전역 최적해와 구분합니다.

수리적 정확성, 재현성, 의사결정 품질의 근거와 남은 오차·feasibility에 대한 보고를 평가합니다. 실패한 운전점이나 완료하지 못한 풀이도 보고 대상입니다.