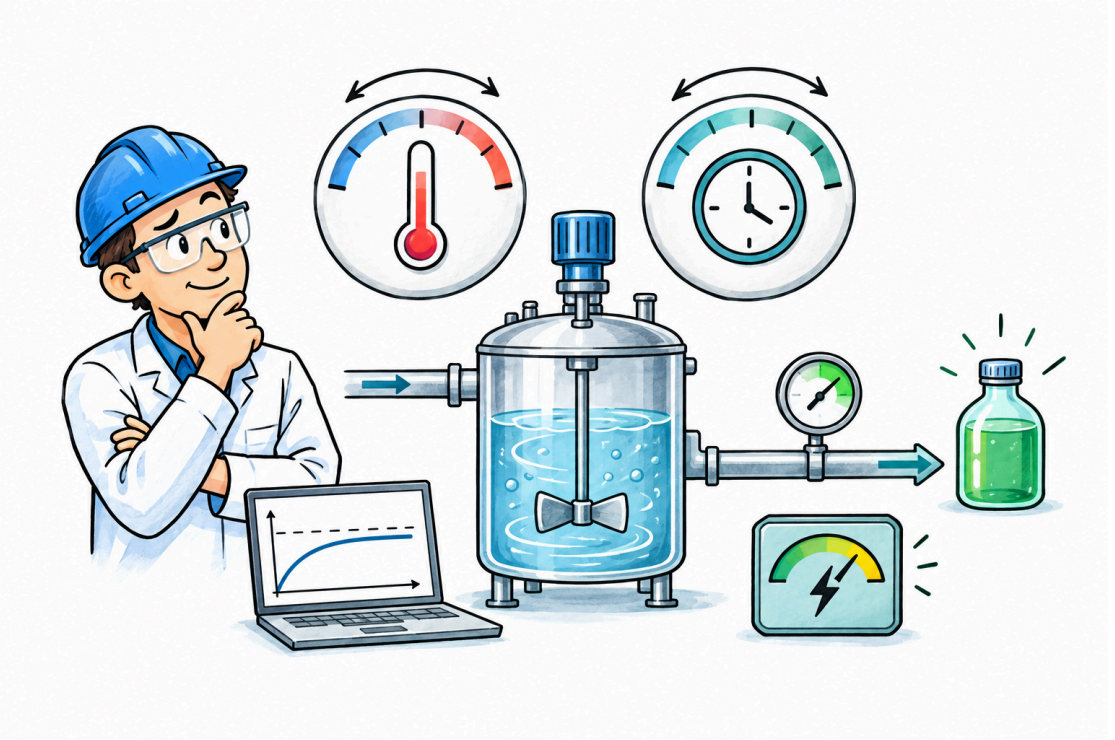
1주차: 공정 예측과 surrogate 모델의 기초

운전 조건에 따른 출구 농도 예측

공정 엔지니어가 새로운 온도와 체류시간에서 출구 농도와 전환율을 예측하려고 합니다.

조건마다 실험하거나 상세 공정 모델을 계산해야 한다면 시간이 걸립니다. 이미 확보한 데이터로 각 조건의 응답을 예측할 수 있을까요?



새 운전 조건에서의 예측 성능

학습 데이터를 잘 따라가는 모델도 새로운 입력에서는 큰 오차를 낼 수 있습니다. 단위나 운전 범위, 고정한 가정이 달라지면 출력의 의미부터 달라집니다.

이번 주에는 예측 문제를 정의하고 독립 데이터로 평가하는 과정을 다뤄봅니다. 기준 응답을 직접 계산할 수 있는 작은 CSTR를 사용해 각 기준값을 확인합니다.

예측 모델의 학습과 독립 평가

1. 입력·출력·고정 조건(context)·단위·영역 정의
2. 정상상태 기준 데이터 생성과 train·validation·test 구분
3. 이차 회귀 기준 모델(baseline) 학습과 물리 단위의 test 오차
4. 농도·전환율의 일관성과 오차가 커지는 입력 조건

2주차는 다성분 MLP, 3주차는 시간 응답, 4주차는 물리적 일관성을 다룹니다. 5-7주차에서 최적화 정식화와 모델 구조를 배운 뒤, 8주차에는 운전 조건을 선택하고 기준 모델로 재검증합니다.

제출물: 독립 평가를 마친 예측 모델

1. 예측 문제의 입력과 출력 정의하기

역할	이 예제
입력	온도 T [K], 체류시간 τ [min], 유입 농도 C_Af [mol/L]
출력	출구 농도 C_A [mol/L], 전환율 X [−]
영역	300–360 K; 1–10 min; 0.8–1.5 mol/L
고정 context	이상적 혼합, 일정 부피·밀도, 1차 반응 A → B, 명시한 속도식 파라미터
기준값	정의한 CSTR 수지의 정상상태 해

유입 농도: 이 예측 문제의 가변 입력

입력 한 행은 운전 조건 하나입니다. 같은 온도라도 체류시간이나 유입 농도가 달라지면 다른 질문이 되므로 세 값을 함께 전달합니다. 출력 두 개는 그 조건에서 충분히 시간이 지난 뒤의 농도와 전환율입니다.

2. 기준 CSTR 모델

1차 반응 A → B가 일어나는 이상적인 완전혼합·일정 부피·등온 CSTR를 사용합니다. 밀도는 일정하고 유입물에는 B가 없으며, 반응기 온도 T를 조작변수로 둡니다.

$$\frac{dC_A}{dt} = \frac{C_{Af} - C_A}{\tau} - k\left(T\right)C_A$$

농도 단위는 mol/L, 시간과 체류시간은 min, T는 K, k는 1/min입니다. 유량/부피가 체류시간의 역수이므로 유입·유출 항과 반응 항의 단위는 모두 mol/(L·min)입니다.

탱크 안 A의 양은 V·C_A입니다. 유입량 Q·C_Af에서 유출량 Q·C_A와 반응 소모량 V·k·C_A를 빼면 축적량의 시간 변화가 됩니다. 부피 V로 나누고 Q/V=1/τ를 대입하면 위 식을 얻습니다.

온도 의존성과 운전 영역

온도에 따른 속도상수:

$$k\left(T\right) = k_{\mathrm{ref}}\exp\left[\beta\left(\frac{1}{T_{\mathrm{ref}}} - \frac{1}{T}\right)\right]$$

파라미터·입력	값·범위	의미
기준 속도상수	0.2 /min	기준 온도에서의 속도
기준 온도	330 K	속도식의 기준
β = E/R	6000 K	교육용 온도 민감도 파라미터
온도	300–360 K	Sampling·평가 영역
체류시간	1–10 min	Sampling·평가 영역
유입 A 농도	0.8–1.5 mol/L	Sampling 영역; 기준 지도에서는 1.2

T=330 K에서는 괄호가 0이므로 지수항이 1입니다. 온도가 올라가면 1/T가 작아져 지수항과 반응속도가 커집니다. 이 식에 섭씨 온도를 넣으면 역온도 차이가 바뀌므로 반드시 K로 계산합니다.

3. 정상상태 mapping 유도

시간 미분을 0으로 놓고 체류시간을 곱한 뒤 출구 농도가 포함된 항을 모으면 정상상태 관계식과 전환율을 얻습니다.

$$C_A = \frac{C_{Af}}{1 + k(T)\,\tau}, \quad X = 1 - \frac{C_A}{C_{Af}} = \frac{k(T)\,\tau}{1 + k(T)\,\tau}$$

입력 3개: 온도·체류시간·유입 농도. 출력 2개: 출구 농도·전환율. 이 1차 반응 모델에서는 전환율이 유입 농도에 무관합니다.

정상상태는 반응이 멈춘 상태가 아닙니다. 유입·유출·반응이 계속되지만 그 합이 0이어서 탱크 농도가 일정합니다. 분모의 1은 유출, kτ는 체류시간 동안의 반응 소모에서 나옵니다.

정상상태 농도의 계산 순서

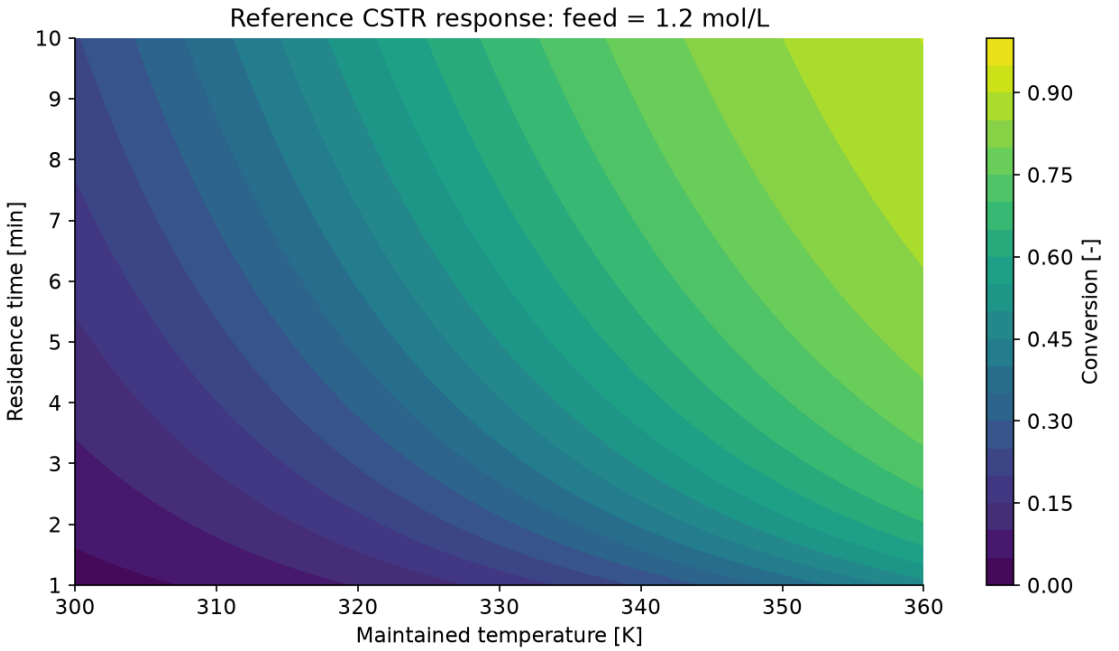
330 K, τ=5 min, C_Af=1.2 mol/L에서 k=0.2/min입니다. 농도를 미지수로 두고 수지를 한 줄씩 정리합니다.

단계	계산	의미
축적 0	0=(1.2−C_A)/5−0.2C_A	유입·유출·반응의 상쇄
체류시간 곱하기	0=1.2−C_A−1.0C_A	각 항의 단위 mol/L
농도 묶기	2C_A=1.2	같은 미지수의 계수 합
농도와 전환율	C_A=0.6; X=1−0.6/1.2=0.5	A의 절반 전환

역대입하면 유입·유출 차이는 (1.2−0.6)/5=0.12 mol/(L·min), 반응 소모도 0.2×0.6=0.12입니다. 두 항이 같으므로 농도가 더 변하지 않습니다.

기준 모델의 응답 곡면 읽기

330 K·5 min에서 전환율은 0.5이고, 유입 농도가 1.2 mol/L이면 출구 농도는 0.6 mol/L입니다.



고정된 유입 농도에서 온도나 체류시간을 늘리면 kτ가 커집니다. 그러면 분모가 커져 A 농도는 내려가고 전환율은 올라갑니다. 그림의 각 점은 이 식을 다른 입력에 대입한 결과입니다.

4. Train·validation·test의 역할 나누기

Seed 42로 명시한 영역 안에서 train 400개, validation 120개, test 160개를 독립적으로 생성

데이터 역할: train은 계수 학습, validation은 모델 선택, test는 최종 오차 보고. 제공 기준 모델: 미리 정한 이차 기저함수

계수를 고를 때 이미 본 점의 오차는 새 조건의 오차를 대신하지 못합니다. 검증 오차로 모델을 여러 번 고른 뒤에는 검증 집합도 선택에 사용된 자료입니다. 마지막 시험 집합을 따로 남기는 이유입니다.

5. 작은 quadratic baseline 학습하기

명시한 하한과 상한으로 각 입력의 크기를 조정합니다.

$$\tilde{x}_j = 2\frac{x_j - l_j}{u_j - l_j} - 1$$

특징량(feature) 10개: 상수 1개, 크기를 조정한 입력 3개, 제곱 3개, 두 입력의 곱 3개. 행렬 크기: Φ 400 × 10, Y 400 × 2, B 10 × 2

학습: 최소제곱법(least squares)을 통한 두 출력의 회귀 계수 추정

$$\min_B \|\Phi B - Y\|_F^2, \quad \hat{y} = \varphi\left(x\right)B$$

예측할 때는 학습한 회귀 계수를 고정하고 새 입력의 출력을 계산합니다.

입력의 제곱과 곱은 반응 곡면의 굽음과 변수 간 관계를 표현합니다. 입력에 대해서는 이차식이지만 미지 계수 B에 대해서는 선형이므로 선형 최소제곱으로 계산할 수 있습니다.

세 데이터에서 최소제곱 계수 구하기

계수 학습을 작은 무차원 데이터 x=[−1,0,1], y=[1,2,2]로 계산합니다. 모델은 b+ax이며, 세 점을 모두 지나는 직선이 없으므로 오차 제곱합을 가장 작게 만듭니다.

오차 $e_i=b+ax_i-y_i$에 대해 b로 미분하면 $2\sum e_i=0$, a로 미분하면 $2\sum x_i e_i=0$입니다. $\sum x_i=0$, $\sum x_i^2=2$, $\sum y_i=5$, $\sum x_i y_i=1$을 넣으면 3b=5, 2a=1입니다.

x	기준 y	예측 5/3+x/2	오차
−1	1	7/6	1/6
0	2	5/3	−1/3
1	2	13/6	1/6

```
import numpy as np
x = np.array([-1., 0., 1.])
phi = np.column_stack((np.ones(3), x))
coef = np.linalg.lstsq(phi, [1., 2., 2.], rcond=None)[0]
prediction = phi @ coef  # [7/6, 5/3, 13/6]
```

coef=[b,a]이고 오차 제곱합은 1/6입니다. CSTR에서는 특성 열을 10개로 늘리고 출력 두 열에 같은 계산을 적용합니다. `lstsq`는 역행렬을 직접 만들지 않고 최소제곱 문제를 풉니다.

입력 한 행에서 열 개의 특성으로

[330, 5, 1.2]를 정해진 범위로 변환하면 [a,b,c]=[0,−1/9,1/7]입니다. 단위와 크기가 다른 입력을 같은 −1~1 범위로 옮깁니다.

특성 묶음	해당 행의 값
상수와 입력	1, 0, −0.111111, 0.142857
제곱 a^2,b^2,c^2	0, 0.012346, 0.020408
곱 ab,ac,bc	0, 0, −0.015873

```
phi = features(np.array([[330., 5., 1.2]]))
phi_train = features(train_x)
coef = np.linalg.lstsq(phi_train, train_y, rcond=None)[0]
prediction = phi @ coef
```

phi는 (1,10), coef는 (10,2), prediction은 (1,2)입니다. 행렬곱은 특성 열마다 계수를 곱해 두 출력별로 합산합니다. 새 입력에서도 학습 때 사용한 특성 순서를 유지합니다.

체류시간 열은 2×(5−1)/(10−1)−1=−1/9, 유입 농도 열은 2×(1.2−0.8)/(1.5−0.8)−1=1/7입니다. 제곱 열은 이 변환값을 제곱하며 원래 단위의 5나 1.2를 제곱하지 않습니다.

6. 예측 오차와 출력 일관성 확인하기

학습에 사용하지 않은 test 데이터의 출력별 오차:

$$\mathrm{RMSE}_j = \sqrt{\frac{1}{N}\sum_{n=1}^{N}\left(\hat{y}_{nj} - y_{nj}\right)^2}$$

농도 RMSE 단위: mol/L. 전환율 RMSE는 무차원이며 0.025608은 약 2.56%p에 해당합니다. 두 예측 출력이 전환율의 정의와도 일치하는지 확인

$$r = \hat{C_A} + C_{\mathrm{Af}}\hat{X} - C_{\mathrm{Af}}$$

기준 모델에서는 r = 0이지만, 제약 없는 두 출력 회귀는 이 관계를 위반할 수 있습니다. 평균 RMSE만으로 모든 입력 조건의 오차가 작다고 판단해서는 안 됩니다.

잔차의 부호는 과대·과소 예측 방향을 나타내지만 평균하면 서로 상쇄될 수 있습니다. 제곱한 뒤 평균하면 그 상쇄를 막고, 마지막 제곱근으로 원래 출력 단위를 회복합니다.

잔차에서 RMSE와 일관성 검사로

농도 기준값 [0.60,0.40] mol/L와 예측 [0.65,0.38] mol/L를 비교합니다.

계산	결과
예측−기준	[0.05,−0.02] mol/L
제곱	[0.0025,0.0004] (mol/L)²
평균	0.00145 (mol/L)²
제곱근	RMSE≈0.038079 mol/L

```
error = prediction - truth
rmse = np.sqrt(np.mean(error**2, axis=0))
```

axis=0은 여러 입력 행을 평균하고 출력 열은 남깁니다. 두 출력을 모두 평균하면 농도와 무차원 전환율을 섞게 됩니다. 별도로 C_A=0.65, X=0.45, C_Af=1.2를 검사하면 0.65+1.2×0.45−1.2=−0.01 mol/L입니다. 정확도와 출력 간 관계를 각각 검사합니다.

재현할 예측 평가 결과

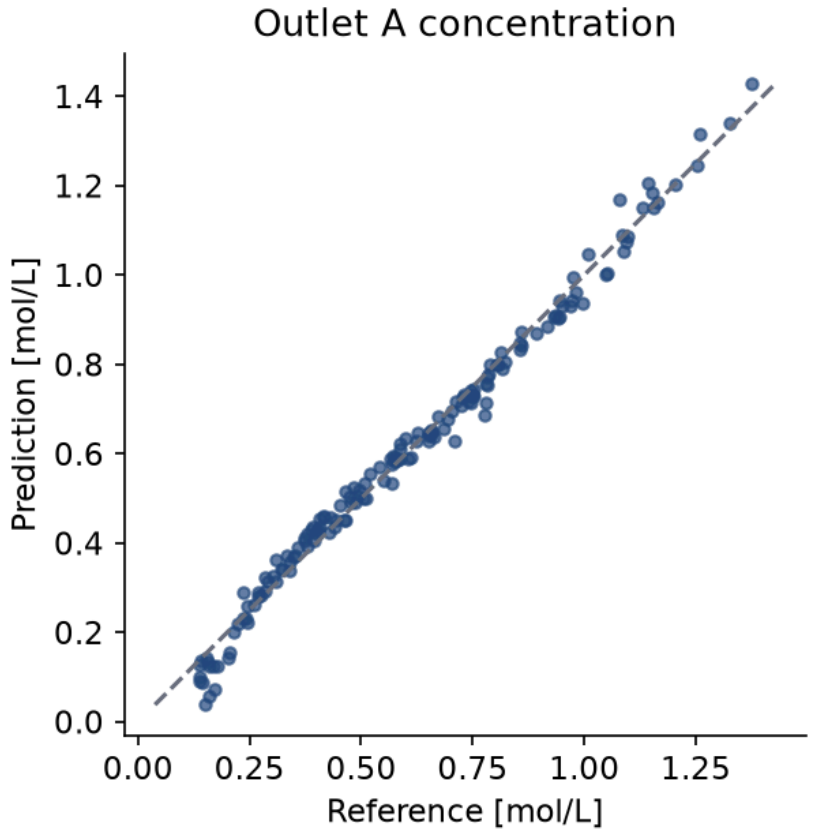
확인 항목	Seed 42 baseline
Test 농도 RMSE	0.032623 mol/L
Test 전환율 RMSE	0.025608
Test 표본	독립된 160개 점
모델	10개 quadratic feature의 least squares

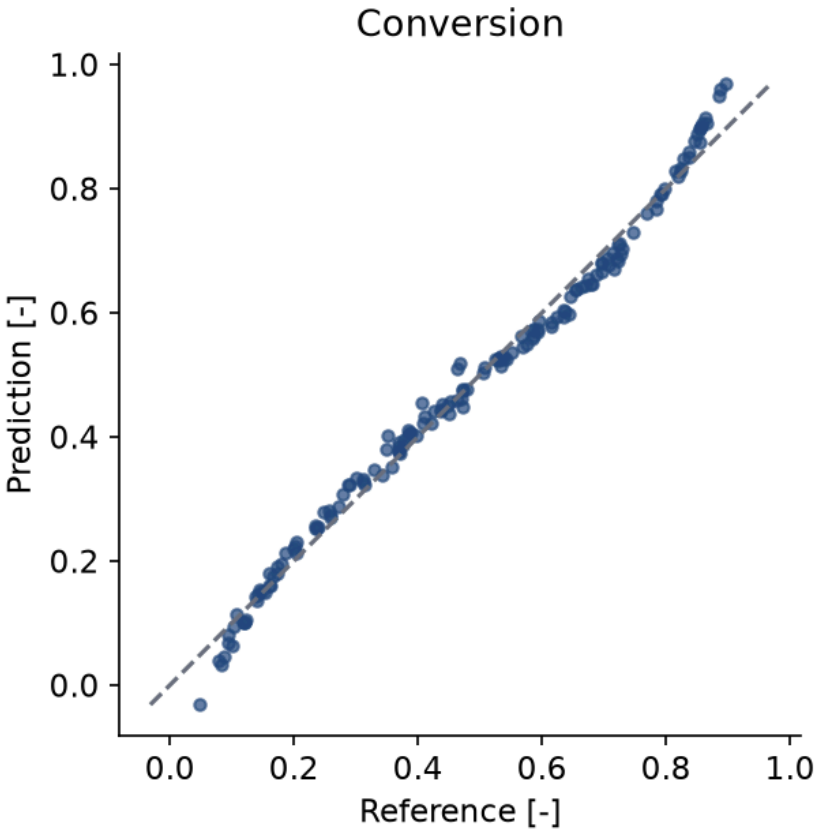
이 오차가 특정 용도에 충분히 작은지는 예측값과 기준값을 비교한 parity plot, 잔차(residual)를 함께 보고 판단합니다.

전환율 오차 0.025608은 전환율 자체의 약 2.56%라는 뜻이 아니라 0~1 척도에서 약 2.56 퍼센트포인트입니다. 작은 평균 오차와 특정 조건의 큰 오차가 함께 나타날 수 있어 최대 오차와 입력 위치도 확인합니다.

운전 조건별 예측 오차

대각선에서는 예측과 기준값이 같습니다. 농도와 전환율을 따로 비교한 뒤, 큰 오차가 나타난 점의 입력 조건을 살펴봅니다.





대각선 위의 점은 과대 예측, 아래의 점은 과소 예측입니다. 한쪽으로 휘는 패턴은 단순한 무작위 산포와 다릅니다. 잔차를 온도·체류시간별로 다시 그리면 이차식이 놓친 곡률이 어느 구간에 모이는지 볼 수 있습니다.

7. 예측 실습 실행하기

Notebook 또는 스크립트와 requirements.txt를 받습니다.

```
python -m pip install -r requirements.txt
python week01_lab.py --output-dir week01-results --seed 42
```

실행하면 데이터, 예측 지표, 기준 응답 지도와 test parity plot이 저장됩니다. 공개 데이터와 기록된 결과를 대조합니다.

후반부의 선택 예제는 스크립트의 `--extensions` 옵션으로 실행합니다.

8. 연습문제와 필수 제출물

1. 정상상태 수지에서 C_A와 X를 유도하고 단위를 확인
2. 330 K, 10 min, 유입 1.2 mol/L의 응답을 계산
3. 이차 특징량의 수와 $\Phi \cdot B \cdot Y$의 차원을 적습니다.
4. 다른 seed로 다시 실행해 독립 평가 오차를 비교하고, train 오차만으로 충분하지 않은 이유를 설명합니다.
5. 유입 1.2 mol/L에서 예측 $C_A = 0.65$ mol/L, $X = 0.45$의 일관성 residual을 구합니다.

제출물: 예측 문제 정의, 학습한 기준 모델, 단위·parity plot·일관성 진단을 포함한 test 보고서

답 확인: 2번은 $C_A = 0.4$ mol/L, $X = 2/3$. 특징량은 10개이고, 5번 residual은 -0.01 mol/L

읽기자료와 다음 예측 문제

1주차 읽기자료 · 국문 PDF

예측 모델을 운전 조건 선택에 사용하려면 목적함수와 운전 제약을 정의하고 기준 공정 모델로 재검증해야 합니다. 이 과정은 5-8주차에서 다룹니다.