

1주차: 공정 예측에서 의사결정으로

공정 의사결정 문제를 정의하고 재현 가능한 baseline을 만든 뒤, 선택한 운전점을 기준 CSTR 모델로 재검증합니다.

과목 설계·강의 노트: Sunwoo Kim · 대학원 입문 · 수정 2026-10-06

학습 목표

이 강의를 마치면 surrogate의 입력, 출력, 고정 context, 단위, 운전 영역을 정의하고, 학습과 운전 최적화를 구분하며, 정상상태·동적 CSTR 예제를 구성하고, surrogate가 선택한 운전점이 기준 모델의 제약을 만족하는지 확인할 수 있어야 한다.

1. 의사결정 문제에서 시작하기

반응기 운전자가 비용을 낮추면서 높은 전환율을 얻고 싶다고 하자. 주어진 온도에서 전환율을 예측하는 일과, 전환율 요구를 만족하도록 온도·체류시간을 선택하는 일은 다르다. 후자는 optimizer가 선호하는 영역에서 모델을 반복해서 평가한다. 그 영역은 일반적인 독립 test 표본의 분포와 다를 수 있다.

신경망을 고르기 전에 무엇을 바꿀 수 있는지, 이번 결정에서 무엇이 고정되는지, 무엇을 예측해야 하는지, 어떤 운전점을 받아들일 것인지부터 작성한다. 영역 전체의 평균 예측 오차가 작다고 해서 선택한 운전점이 제약을 만족하는 것은 아니다.

역할	의미	이번 예제
의사결정 변수	최적화가 선택하는 양	반응기 온도 T 와 체류시간 τ
고정 context	한 번의 solve에서 고정하는 알려진 양	의사결정 비교에서는 유입 농도 1.2 mol/L
모델 출력	제안된 입력에서 예측하는 양	출구 농도와 전환율
상태	동적 모델에서 시간에 따라 변하는 양	반응기 내부 농도
영역	모델을 평가할 조건의 범위	온도·체류시간·유입 농도의 명시된 bounds

학습은 데이터를 이용해 모델 파라미터를 조정한다. 운전 최적화는 학습된 파라미터를 고정하고 의사결정 변수를 바꾼다. 서로 다른 최적화 문제다.

2. 직접 확인할 수 있는 기준 공정

1차 반응 $A \rightarrow B$ 가 일어나는 이상적인 완전혼합·일정 부피·등온 CSTR를 사용한다. 밀도는 일정하고 유입물에는 B가 없다. 반응기 온도 T 를 조작변수로 둔다.

$$\frac{dC_A}{dt} = \frac{C_{Af} - C_A}{\tau} - k(T)C_A$$

농도 단위는 mol/L, 시간과 체류시간은 min, T는 K, k는 1/min이다. 유량/부피는 체류시간의 역수이므로 유입-유출 항과 반응 항의 단위는 모두 mol/(L·min)이다.

속도상수의 온도 의존성은 다음과 같다.

$$k(T) = k_{\text{ref}} \exp \left[\beta \left(\frac{1}{T_{\text{ref}}} - \frac{1}{T} \right) \right]$$

파라미터·입력	값·범위	의미
기준 속도상수	0.2 /min	기준 온도에서의 속도
기준 온도	330 K	속도식의 기준
$\beta = E/R$	6000 K	교육용 온도 민감도 파라미터
온도	300–360 K	Sampling·의사결정 영역
체류시간	1–10 min	Sampling·의사결정 영역
유입 A 농도	0.8–1.5 mol/L	Sampling 영역; 최적화에서는 1.2로 고정


3. 정상상태 mapping 유도

시간 미분을 0으로 놓고 체류시간을 곱한 뒤 출구 농도가 들어 있는 항을 모은다. 정상상태 mapping과 전환율은 다음과 같다.

$$C_A = \frac{C_{Af}}{1 + k(T)\tau}, \quad X = 1 - \frac{C_A}{C_{Af}} = \frac{k(T)\tau}{1 + k(T)\tau}$$

온도·체류시간·유입 농도라는 세 입력에서 출구 농도·전환율이라는 두 출력을 얻는다. 이 1차 반응 모델에서 전환율은 유입 농도에 무관하다.

계산 확인: 330 K, 5 min에서는 $k\tau$ 가 1이므로 전환율은 0.5이고 출구 A 농도는 유입 농도의 절반이다. 유입이 1.2 mol/L이면 출구는 0.6 mol/L이다.



기준 모델의 전환율. Contour는 의사결정 실습에서 사용할 전환율 요구를 나타낸다.

4. 최적화 문제 명시하기

다음 무차원 비용 지수를 최소화한다.

$$J(T, \tau) = \frac{T - 300K}{20K} + \frac{\tau}{10min}$$

높은 온도와 긴 체류시간에 비용을 부여한다. 유입 농도를 1.2 mol/L로 고정하고, 명시된 bounds 안에서 예측 전환율이 0.8 이상이 되도록 이 지수를 최소화한다. 예측 농도는 0과 유입 농도 사이, 예측 전환율은 1 이하라는 조건도 둔다.

기준 mapping에서는 전환율 0.8 이상이 $k\tau \geq 4$ 와 동치다. 전환율 부등식의 양변에 양수인 분모를 곱하면 확인할 수 있다. 모델을 학습하지 않고도 feasible region을 확인하는 기준이다.

Surrogate의 예측 오차로 feasible set이 달라질 수 있다. 선택한 온도-체류시간을 기준 모델에 넣고 전환율 요구를 만족하는지 확인한다.

5. 사용할 목적에 맞는 데이터 설계

실습은 고정 random seed로 명시된 box 안에서 train 400개, validation 120개, test 160개를 독립 생성한다. Train 데이터로 계수를 학습하고, validation은 모델 선택에, test는 최종 평가에 사용한다. Baseline은 고정 영역 scaling과 quadratic feature를 사용한다.

다출력 baseline은 상수항, 세 scaled 입력, 각 입력의 제곱, 입력 사이의 곱으로 구성된 열 개 feature에 대한 ordinary least squares를 사용한다.

측정 데이터는 batch, 실험, 운전 campaign, 시간 단위로 분할한다. 동적 데이터는 같은 궤적의 겹치는 window가 한 분할에 속하도록 전체 궤적 단위로 나눈다.


6. 예측 오차와 의사결정 오차

농도 RMSE는 mol/L, 전환율 RMSE는 무차원 비율로 보고한다. 두 출력의 일관성 residual도 확인한다. 예측 출구 농도에 유입 농도×예측 전환율을 더하고 유입 농도를 빼면 된다. 다출력 fit이 이 관계를 만족하지 않을 수 있다.

의사결정 비교는 surrogate와 기준 모델에 동일한 grid를 사용한다. 온도 간격은 0.5 K, 체류시간 간격은 0.1 min이다. 이 grid에서 비용이 가장 작은 feasible 후보를 찾는다.

확인 항목	결과
독립 test 농도 RMSE	0.032623 mol/L
독립 test 전환율 RMSE	0.025608
Surrogate가 선택한 운전점	347.000000 K; 8.100000 min
그 지점의 예측 전환율	0.800144
그 지점의 기준 모델 전환율	0.797893
기준 모델에서 0.8 대비 전환율 부족분	0.002107
선택한 운전점의 기준 비용	3.160000
기준 모델 feasible grid benchmark 비용	3.155000

선택한 운전점의 예측 전환율은 0.8 이상이지만, 기준 모델 전환율은 0.8보다 낮다. 이 운전점은 전환율 제약을 위반한다. 비용은 기준 모델에서 feasible인 운전점 사이에서 비교한다.



선택한 운전점 근처의 비교. 제약 경계 근처 오차가 선택 가능한 운전 조건을 바꿀 수 있다.

7. 변수 벡터에서 시간 시계열로 연결하기


정상상태 출력에는 시간 index가 없다. 동적 출력은 초기 상태와 조작변수 외란의 이력에 의존한다. 운전 계획 문제에서는 검토하는 미래 조작변수 sequence도 모델이 입력으로 받아야 한다. 과거 관측만으로 예측하는 모델은 임의의 미래 운전 계획을 비교하기에 충분하지 않다.

동적 실험에서는 유입 농도·체류시간을 고정하고 10 min에 유지 온도를 330 K에서 345 K로 바꾼다. 각 입력이 일정한 구간에서 농도 수치는 다음 해석적 update를 갖는다.

$$C_A(t + \Delta t) = C_{Ass} + \left[C_A(t) - C_{Ass} \right] \exp \left[- \left(\frac{1}{\tau} + k(T) \right) \Delta t \right]$$

각 구간의 정상상태 농도는 해당 구간의 입력으로 계산한다.

코드는 입력을 구간마다, 농도를 구간 경계 시점마다 기록한다. 온도가 바뀌는 순간 농도는 연속이며 이후 새로운 정상값에 접근한다.



기준 동적 응답. 즉시 정상상태 값을 반환하는 mapping은 과도 농도 궤적을 놓친다.

8. 실험 실행

Notebook 또는 **독립 스크립트**와 **requirements.txt**를 받는다.

```
python -m pip install -r requirements.txt
python week01_lab.py --output-dir week01-results
```

스크립트는 지정한 출력 폴더에 dataset, metrics JSON, 동적 궤적 CSV, 그림 세 개를 생성한다. 비교를 위한 **공개 dataset**과 **기록된 결과**도 제공한다.

9. 연습문제와 제출물

1. 정상상태 농도를 유도하고 단위를 확인한다. 이 모델에서 온도 또는 체류시간을 높이면 전환율이 증가하는 이유를 설명한다.
2. 전환율 목표의 조건 $k\tau \geq 4$ 를 유도한다. 모델을 학습하지 않고 기존 feasible region을 확인한다.
3. Training seed를 바꾸어 다시 실행한다. Test RMSE, 선택한 운전점, 기존 feasibility를 비교한다. RMSE가 더 좋은 모델이 항상 더 좋은 결정을 선택하는가?
4. 온도 영역을 330–350 K로 좁힌다. Feasible set과 training sampling 영역을 어떻게 함께 바꿔야 하는지 설명한다.
5. 온도 step 시점을 바꾼다. 입력 구간과 출력 경계 시점 중 무엇이 달라지는지 설명한다. 정상상태 predictor가 과도 응답을 표현할 수 없는 이유를 설명한다.
6. 의사결정 변수, 고정 context, 상태, 출력, 단위, 영역, 목적함수, 제약, 데이터 분할, 재검증 규칙을 포함한 한 쪽짜리 문제 정의서를 작성한다.

기준 확인: 330 K·5 min의 전환율은 0.5이고, 목표 전환율은 $k\tau \geq 4$ 를 요구하며, 양수 β 에서는 T 가 증가하면 k 가 증가한다. 나머지 문제는 직접 계산한 결과와 해석을 제출하며, 제약을 위반했다면 그 결과도 포함한다.

읽기자료와 다음 강의

Boyd와 Vandenberghe의 **2–4장** 중 domain, 제약, convex function, 최적화 문제 관련 내용을 읽는다. **OMLT 서론**에서는 큰 최적화 문제 안에 학습된 모델을 넣는 역할을 확인한다.

2주차에서는 같은 데이터 정의와 기준 확인 절차를 사용해 다출력 MLP를 만든다.