

1주차: 공정 예측에서 의사결정으로

공정 의사결정 문제를 정의하고 재현 가능한 baseline을 만든 뒤, 선택한 운전점을 기준 CSTR 모델로 재검증합니다.

과목 설계·강의 노트: Sunwoo Kim · 대학원 입문 · 수정 2026-10-06

학습 목표

이 강의를 마치면 surrogate의 입력, 출력, 고정 context, 단위, 운전 영역을 정의하고, 학습과 운전 최적화를 구분하며, 정상상태·동적 CSTR 예제를 구성하고, surrogate가 선택한 운전점이 기준 모델의 제약을 만족하는지 확인할 수 있어야 한다.

권장 학습 시간은 노트·유도 90분, 실습 60–90분, 연습문제 2시간이다. **Syllabus**에서 나머지 주차와의 연결을 확인할 수 있다.

1. 의사결정 문제에서 시작하기

반응기 운전자가 비용을 낮추면서 높은 전환율을 얻고 싶다고 하자. 주어진 온도에서 전환율을 예측하는 일과, 전환율 요구를 만족하도록 온도·체류시간을 선택하는 일은 다르다. 후자는 optimizer가 선호하는 영역에서 모델을 반복해서 평가한다. 그 영역은 일반적인 독립 test 표본의 분포와 다를 수 있다.

신경망을 고르기 전에 무엇을 바꿀 수 있는지, 이번 결정에서 무엇이 고정되는지, 무엇을 예측해야 하는지, 어떤 운전점을 받아들일 것인지부터 작성한다. 영역 전체의 평균 예측 오차가 작다고 해서 선택한 운전점이 제약을 만족하는 것은 아니다.

역할	의미	이번 예제
의사결정 변수	최적화가 선택하는 양	반응기 온도 T 와 체류시간 τ
고정 context	한 번의 solve에서 고정하는 알려진 양	의사결정 비교에서는 유입 농도 1.2 mol/L
모델 출력	제안된 입력에서 예측하는 양	출구 농도와 전환율
상태	동적 모델에서 시간에 따라 변하는 양	반응기 내부 농도
영역	모델을 평가할 조건의 범위	온도·체류시간·유입 농도의 명시된 bounds

학습은 데이터를 이용해 모델 파라미터를 조정한다. 운전 최적화는 학습된 파라미터를 고정하고 의사결정 변수를 바꾼다. 서로 다른 최적화 문제다.

2. 직접 확인할 수 있는 기준 공정

1차 반응 $A \rightarrow B$ 가 일어나는 이상적인 완전혼합·일정 부피·등온 CSTR를 사용한다. 밀도는 일정하고 유입물에는 B가 없다. 각 운전 조건에서 반응기 온도는 외부에서 유지된다. 농도 동역학만 모델링하며 에너지수지는 생략한다. 온도는 반응속도를 바꾸지만 필요한 열부하는 계산하지 않는다.

$$\frac{dC_A}{dt} = \frac{C_{Af} - C_A}{\tau} - k(T)C_A$$

농도 단위는 mol/L, 시간과 체류시간은 min, T는 K, k는 1/min이다. 유량/부피는 체류시간의 역수이므로 유입-유출 항과 반응 항의 단위는 모두 mol/(L·min)이다.

교육용 속도식은 다음과 같다.

$$k(T) = k_{\text{ref}} \exp \left[\beta \left(\frac{1}{T_{\text{ref}}} - \frac{1}{T} \right) \right]$$

파라미터·입력	값·범위	의미
기준 속도상수	0.2 /min	기준 온도에서의 속도
기준 온도	330 K	속도식의 기준
$\beta = E/R$	6000 K	교육용 온도 민감도 파라미터
온도	300–360 K	Sampling·의사결정 영역
체류시간	1–10 min	Sampling·의사결정 영역
유입 A 농도	0.8–1.5 mol/L	Sampling 영역; 최적화에서는 1.2로 고정

실제 반응기나 출판된 사례에서 추정된 값이 아니라 교육용 가상 파라미터다. 이 simulator는 실습의 기준 모델이며, 실제 플랜트의 정확성을 주장하지 않는다.


3. 정상상태 mapping 유도

시간 미분을 0으로 놓고 체류시간을 곱한 뒤 출구 농도가 들어 있는 항을 모은다. 정상상태 mapping과 전환율은 다음과 같다.

$$C_A = \frac{C_{Af}}{1 + k(T)\tau}, \quad X = 1 - \frac{C_A}{C_{Af}} = \frac{k(T)\tau}{1 + k(T)\tau}$$

온도·체류시간·유입 농도라는 세 입력에서 출구 농도·전환율이라는 두 출력을 얻는다. 전환율이 유입 농도에 무관한 것은 이 특정한 1차 반응·등온 모델의 성질이다. 다른 반응속도식이나 비등온 반응기로 일반화하지 않는다.

계산 확인: 330 K, 5 min에서는 $k\tau$ 가 1이므로 전환율은 0.5이고 출구 A 농도는 유입 농도의 절반이다. 유입이 1.2 mol/L이면 출구는 0.6 mol/L이다. Simulator와 surrogate 구현을 평가할 때 사용할 기본 기준점이다.



기준 모델의 전환율. Contour는 의사결정 실습에서 사용할 전환율 요구를 나타낸다.

4. 최적화 문제 명시하기

산업 경제성 모델 대신 설명용 무차원 비용 지수를 사용한다.

$$J(T, \tau) = \frac{T - 300K}{20K} + \frac{\tau}{10min}$$

높은 온도와 긴 체류시간에 비용을 부여하는 무차원 지수다. 열부하·이익·화폐 단위를 계산한 값은 아니다. 유입 농도를 1.2 mol/L로 고정하고, 명시된 bounds 안에서 예측 전환율이 0.8 이상이 되도록 이 지수를 최소화한다. 예측 농도는 0과 유입 농도 사이, 예측 전환율은 1 이하라는 조건도 둔다.

기준 mapping에서는 전환율 0.8 이상이 $k\tau \geq 4$ 와 동치다. 전환율 부등식의 양변에 양수인 분모를 곱하면 확인할 수 있다. 모델을 학습하지 않고도 feasible region을 확인하는 기준이다.

기준 mapping을 surrogate로 바꾸면 feasible set이 달라진다. Surrogate 문제를 정확하게 풀었다는 사실로 기준 공정의 feasibility를 주장할 수 없다. 선택한 온도·체류시간을 기준 모델에 넣고, 전환율 요구를 얼마나 위반하는지 확인한다.

5. 사용할 목적에 맞는 데이터 설계

실습은 고정 random seed로 명시된 box 안에서 train 400개, validation 120개, test 160개를 독립 생성한다. Training 정의로 scaling을 정하고 train 데이터로만 계수를 학습한다. Validation은 모델 선택에, test는 최종 보고에 사용한다. 제공 baseline은 고정 영역 scaling과 미리 정한 quadratic feature를 사용하며 test 결과로 튜닝하지 않는다.

다출력 baseline은 상수항, 세 scaled 입력, 각 입력의 제곱, 입력 사이의 곱으로 구성된 열 개 feature에 대한 ordinary least squares다. 첫 주에는 의사결정 workflow에 집중하기 위한 선택이다. ReLU 모델이나 MILP embedding은 아니다. 이후 주차에서 신경망으로 바꾸고 formulation을 유도한다.

측정 데이터에서는 batch, 실험, 운전 campaign, 시간이 정보를 공유한다면 해당 단위로 분할한다. 동적 데이터에서는 같은 궤적에서 겹치는 window를 무작위 행 단위로 나누면 정보가 누출될 수 있다. 새로운 궤적에 대한 일반화를 평가할 때는 전체 궤적이나 독립 운전 campaign을 분리한다.

입력 box 안에 있다는 사실만으로 믿을 만한 interpolation이라고 판단할 수 없다. 표본 밀도, 운전 regime, 제약 경계 부근 오차를 살핀다. 실습의 독립 box sampling은 통제된 교육 설계이며 실제 데이터의 이런 분석을 대신하지 않는다.

6. 예측 오차와 의사결정 오차


농도 RMSE는 mol/L, 전환율 RMSE는 무차원 비율로 보고한다. 두 출력의 일관성 residual도 확인한다. 예측 출구 농도에 유입 농도×예측 전환율을 더하고 유입 농도를 빼면 된다. 다출력 fit이 이 관계를 만족하지 않을 수 있다.

의사결정 비교는 surrogate와 기준 모델에 동일한 grid를 사용한다. 온도 간격은 0.5 K, 체류시간 간격은 0.1 min이다. 유한 grid에서 비용이 가장 작은 feasible 후보를 찾으며, 연속 문제의 전역 최적해를 인증하지 않는다.

아래 값은 다운로드 실습을 seed 42로 실행해 얻은 결과다. 논문 결과가 아니라 이 가상 예제의 결과다.

확인 항목	결과
독립 test 농도 RMSE	0.032623 mol/L
독립 test 전환율 RMSE	0.025608
Surrogate가 선택한 운전점	347.000000 K; 8.100000 min
그 지점의 예측 전환율	0.800144
그 지점의 기준 모델 전환율	0.797893
기준 모델에서 0.8 대비 전환율 부족분	0.002107
선택한 운전점의 기준 비용	3.160000
기준 모델 feasible grid benchmark 비용	3.155000

선택한 운전점이 기준 모델에서 infeasible이면 낮은 비용을 경제성 개선이라고 해석할 수 없다. 비용 비교는 기준 모델의 feasibility를 먼저 요구한다. 실습에서는 feasibility를 먼저 보고하고, 이를 통과한 경우에만 feasible decision cost gap을 보고한다.



선택한 운전점 근처의 비교. 제약 경계 근처 오차가 선택 가능한 운전 조건을 바꿀 수 있다.

7. 변수 벡터에서 시간 시계열로 연결하기


정상상태 출력에는 시간 index가 없다. 동적 출력은 초기 상태와 조작변수·외란의 이력에 의존한다. 운전 계획 문제에서는 검토하는 미래 조작변수 sequence도 모델이 입력으로 받아야 한다. 과거 관측만으로 예측하는 모델은 임의의 미래 운전 계획을 비교하기에 충분하지 않다.

동적 실험에서는 유입 농도·체류시간을 고정하고 10 min에 유지 온도를 330 K에서 345 K로 바꾼다. 각 입력이 일정한 구간에서 농도 수치는 다음 해석적 update를 갖는다.

$$C_A(t + \Delta t) = C_{Ass} + \left[C_A(t) - C_{Ass} \right] \exp \left[- \left(\frac{1}{\tau} + k(T) \right) \Delta t \right]$$

이 식의 정상상태 농도는 해당 구간의 입력으로 다시 계산한다. Piecewise-constant 입력을 갖는 교육용 ODE에서는 수치 연산 오차 범위에서 exact update다. 임의의 비선형 공정에 적용되는 시간 이산화식은 아니다.

코드는 입력을 구간마다, 농도를 구간 경계 시점마다 기록한다. 온도가 바뀌는 순간 농도는 연속이며 이후 새로운 정상값에 접근한다. 이 indexing은 3주차 시계열 모델을 학습할 때 중요해진다.



기준 동적 응답. 즉시 정상상태 값을 반환하는 mapping은 과도 농도 궤적을 놓친다.

8. 실습 실행

Notebook 또는 **독립 스크립트**와 **requirements.txt**를 받는다. Notebook에는 영어·한국어 안내와 필요한 모델 코드가 모두 들어 있다. 외부 데이터나 API key는 필요하지 않다.

```
python -m pip install -r requirements.txt
python week01_lab.py --output-dir week01-results
```

스크립트는 지정한 출력 폴더에 가상 dataset, metrics JSON, 동적 궤적 CSV, 그림 세 개를 생성한다. 비교를 위한 **공개 dataset**과 **기록된 결과**도 제공한다. Library 버전에 따라 작은 수치 차이가 있을 수 있으며 운전 grid와 random seed는 고정되어 있다.

9. 연습문제와 제출물

1. 정상상태 농도를 유도하고 단위를 확인한다. 이 모델에서 온도 또는 체류시간을 높이면 전환율이 증가하는 이유를 설명한다.
2. 전환율 목표의 조건 $k\tau \geq 4$ 를 유도한다. 모델을 학습하지 않고 기준 feasible region을 확인한다.
3. Training seed를 바꾸어 다시 실행한다. Test RMSE, 선택한 운전점, 기준 feasibility를 비교한다. RMSE가 더 좋은 모델이 항상 더 좋은 결정을 선택하는가?
4. 온도 영역을 330–350 K로 좁힌다. Feasible set과 training sampling 영역을 어떻게 함께 바꿔야 하는지 설명한다.
5. 온도 step 시점을 바꾼다. 입력 구간과 출력 경계 시점 중 무엇이 달라지는지 설명한다. 정상상태 predictor가 과도 응답을 표현할 수 없는 이유를 설명한다.
6. 의사결정 변수, 고정 context, 상태, 출력, 단위, 영역, 목적함수, 제약, 데이터 분할, 재검증 규칙을 포함한 한 쪽짜리 문제 정의를 작성한다.

기준 확인: 330 K·5 min의 전환율은 0.5이고, 목표 전환율은 $k\tau \geq 4$ 를 요구하며, 양수 β 에서는 T가 증가하면 k가 증가한다. 나머지 문제는 직접 계산한 결과와 해석을 제출하며, 제약을 위반했다면 그 결과도 포함한다.

읽기자료와 다음 강의

Boyd와 Vandenberghe의 **2-4장** 중 domain, 제약, convex function, 최적화 문제 관련 내용을 읽는다.

OMLT 서론에서는 큰 최적화 문제 안에 학습된 모델을 넣는 역할을 확인한다. 위 CSTR 식과 가상 파라미터는 명시한 수지 가정에서 작성한 교육용 예제다.

2주차에서는 이 간단한 baseline을 다출력 MLP로 바꾼다. 모델을 바꿀 때도 이번 주의 데이터 정의와 기준 확인 절차를 유지한다.