

1주차 읽기자료: 공정 예측과 회귀 baseline

1. 데이터를 만들기 전에 mapping 정의하기

Surrogate는 명시한 영역에서 입력으로부터 출력을 예측한다. Label은 입력 한 행에 짝지은 기준 출력이다.

역할	이 예측 문제
입력	T: 300–360 K; τ : 1–10 min; C_{Af} : 0.8–1.5 mol/L
출력	C_A : mol/L; 전환율 X: 무차원
고정 context	이상적·일정 부피·등온 CSTR, 1차 반응 $A \rightarrow B$, 고정된 속도식 파라미터
기준값	정상상태 물질수지의 해

여기에서 유입 농도는 입력이다. 모든 데이터를 1.2 mol/L로 고정하지 않는다. 반응 가정과 단위는 데이터 행들 사이에서 같아야 한다.

확인: “온도”라는 수만으로는 부족하다. 단위와 운전 범위를 함께 알아야 한다.

2. 정상상태 mapping 직접 유도하기

이상적인 완전혼합·등온·일정 부피 CSTR에서 1차 반응 $A \rightarrow B$ 가 일어난다. 축적 = 유입 - 유출 - 반응으로 수지를 작성한다.

$$\frac{dC_A}{dt} = \frac{C_{Af} - C_A}{\tau} - k(T)C_A$$

정상상태에서는 미분을 0으로 둔다. 체류시간을 곱하고 농도가 있는 항을 한쪽에 모은 뒤 출구 농도를 뮴는다. 양수인 계수로 나누면 다음 결과를 얻는다.

$$C_A = \frac{C_{Af}}{1 + k(T)\tau}, \quad X = 1 - \frac{C_A}{C_{Af}} = \frac{k(T)\tau}{1 + k(T)\tau}$$

330 K에서 속도상수는 0.2/min이다. 체류시간이 5 min이면 속도상수와 체류시간의 곱이 1이므로 전환율은 0.5다. 유입 농도가 1.2 mol/L이면 출구는 0.6 mol/L이다.

이 1차 반응 모델에서는 전환율이 유입 농도에 무관하다. 모든 반응기에 적용되는 일반 성질은 아니다.

3. 독립 train·validation·test 데이터 만들기

다음 교육용 속도식을 사용한다. T의 단위는 K, k는 1/min이다:

$$k(T) = 0.2 \exp \left[6000 \left(\frac{1}{330} - \frac{1}{T} \right) \right]$$

명시한 box 안에서 입력을 독립·균등 표본추출하고 정상상태 식으로 각 label을 계산한다. Seed 42로 재현 가능한 표본을 만든다.

분할	행 수	역할
Train	400	계수 학습
Validation	120	모델 선택 비교
Test	160	최종 독립 평가

제공한 basis는 미리 고정되어 있다. 다른 basis나 capacity를 비교하면 validation을 쓰고 test는 남겨둔다. 새 simulator 표본이 새 실험 campaign과 같은 것은 아니다.

4. 입력 scaling과 10개 feature 학습하기

$$\tilde{x}_j = 2 \frac{x_j - l_j}{u_j - l_j} - 1$$

[330 K, 5 min, 1.2 mol/L]의 scaled 입력은 약 [0, -0.111111, 0.142857]이다. Scaling에는 명시한 bounds를 쓰며 test 통계량을 사용하지 않는다.

Feature는 상수 1개 + 입력 3개 + 제곱 3개 + 두 입력의 곱 3개 = **10개**다. Train 400행에서 Φ 의 shape는 (400, 10), Y는 (400, 2), B는 (10, 2)다.

$$\min_B \|\Phi B - Y\|_F^2, \quad \hat{y} = \varphi(x)B$$

`np.linalg.lstsq`로 B를 학습한다. 새 입력을 예측할 때 B는 고정한다. 파라미터 학습은 최적화 계산이며, 공정의 운전 조건을 선택하는 문제는 후반부에서 별도로 다룬다.

5. 정확도와 일관성을 따로 읽기

$$\text{RMSE}_j = \sqrt{\frac{1}{N} \sum_{n=1}^N (\hat{y}_{nj} - y_{nj})^2}$$

출력별로 예측에서 기준값을 빼고, 제곱하여 test 행들에서 평균한 뒤 제곱근을 구한다. 농도 RMSE는 mol/L, 전환율 RMSE는 무차원이다.

Seed 42 baseline의 농도 RMSE는 **0.032623 mol/L**, 전환율 RMSE는 **0.025608**이다. 평균과 함께 개별 오차도 확인한다.

$$r = \hat{C}_A + C_{Af}\hat{X} - C_{Af}$$

유입 1.2에서 예측 $C_A = 0.65$, $X = 0.45$ 라면 $r = 0.65 + 1.2 \times 0.45 - 1.2 = -0.01$ mol/L다. 예측 쌍은 정의한 전환율 관계를 정확히 만족하지 않는다. 물리적 일관성을 반영하는 방법은 4주차에서 공부한다.

6. 확인 문제·해설과 읽기자료

먼저 계산: 330 K, 10 min, 유입 1.2 mol/L에서 C_A 와 X 는 얼마인가? 두 출력을 학습하는 회귀 계수는 몇 개인가? 작은 train 오차만 보면 왜 오해할 수 있는가?

확인 답: $k\tau = 2$ 이므로 $C_A = 1.2/3 = 0.4 \text{ mol/L}$, $X = 2/3$ 다. B에는 출력별 10개, 총 **20개** 계수가 있다. Train 평가는 학습에 사용한 점을 다시 확인하므로 독립 오차가 더 클 수 있다.

직접 작성한 이 해설과 [1주차 실습](#)을 따라간다. 선택 배경자료: Boyd·Vandenberghe, *Convex Optimization*, 2·4장의 affine map과 least-squares 문제([공식 교재 PDF](#)).

2주차는 MLP, 3주차는 동적 예측으로 이어진다. 운전 목적함수·제약은 5–8주차에서 다시 다룬다.