1주차 읽기자료: 공정 예측과 회귀 baseline

1. 예측 mapping의 정의

Surrogate는 명시한 영역에서 입력에 대응하는 출력을 예측하는 모델이며, label은 입력 한 행에 짝지은 기준 출력입니다.

역할	이 예측 문제
입력	T: 300–360 K; τ: 1–10 min; C_Af: 0.8–1.5 mol/L
출력	C_A: mol/L; 전환율 X: 무차원
고정 context	이상적·일정 부피·등온 CSTR, 1차 반응 A → B, 고정된 속도식 파라미터
기준값	정상상태 물질수지의 해

유입 농도는 명시한 영역에서 변화시키며, 반응 가정과 단위는 모든 데이터 행에 동일하게 적용합니다.

“온도”라는 이름과 수치에 단위·운전 범위를 함께 적어야 예측 문제를 정의할 수 있습니다.

2. 정상상태 mapping 직접 유도하기

이상적인 완전혼합·등온·일정 부피 CSTR에서 1차 반응 A → B가 일어납니다. 축적 = 유입 − 유출 − 반응으로 수지를 작성합니다.

$$\frac{dC_A}{dt} = \frac{C_{Af} - C_A}{\tau} - k\left(T\right)C_A$$

정상상태에서는 미분을 0으로 둡니다. 체류시간을 곱해 농도 항을 한쪽에 모으고 출구 농도를 묶은 뒤, 양수인 계수로 나눕니다.

$$C_A = \frac{C_{Af}}{1 + k\left(T\right)\tau}, \quad X = 1 - \frac{C_A}{C_{Af}} = \frac{k\left(T\right)\tau}{1 + k\left(T\right)\tau}$$

330 K에서 속도상수는 0.2/min입니다. 체류시간 5 min에서는 속도상수와 체류시간의 곱이 1이므로 전환율은 0.5이고, 유입 농도 1.2 mol/L에 대한 출구 농도는 0.6 mol/L입니다.

이 1차 반응 모델에서는 전환율이 유입 농도에 무관합니다.

정상상태 농도의 계산 순서

330 K, τ=5 min, C_Af=1.2 mol/L에서 k=0.2/min입니다. 농도를 미지수로 두고 수지를 한 줄씩 정리합니다.

단계	계산	의미
축적 0	0=(1.2−C_A)/5−0.2C_A	유입·유출·반응의 상쇄
체류시간 곱하기	0=1.2−C_A−1.0C_A	각 항의 단위 mol/L
농도 묶기	2C_A=1.2	같은 미지수의 계수 합
농도와 전환율	C_A=0.6; X=1−0.6/1.2=0.5	A의 절반 전환

역대입하면 유입·유출 차이는 (1.2−0.6)/5=0.12 mol/(L·min), 반응 소모도 0.2×0.6=0.12입니다. 두 항이 같으므로 농도가 더 변하지 않습니다.

3. 독립 train·validation·test 데이터 만들기

교육용 속도식에서 T의 단위는 K, k는 1/min입니다.

$$k\left(T\right) = 0.2\exp\left[6000\left(\frac{1}{330} - \frac{1}{T}\right)\right]$$

명시한 영역 안에서 입력을 독립·균등 표본추출하고 정상상태 식으로 각 기준값을 계산합니다. Seed 42를 사용하면 같은 표본을 재현할 수 있습니다.

분할	행 수	역할
Train	400	계수 학습
Validation	120	모델 선택 비교
Test	160	최종 독립 평가

제공한 기저함수는 미리 고정되어 있습니다. 다른 기저함수나 모델 크기를 비교할 때는 validation을 사용하고 test는 최종 평가에 남겨둡니다.

4. 입력 scaling과 10개 feature 학습하기

$$\tilde{x}_j = 2\frac{x_j - l_j}{u_j - l_j} - 1$$

[330 K, 5 min, 1.2 mol/L]의 크기를 조정한 입력은 약 [0, −0.111111, 0.142857]입니다. 이 조정에는 명시한 bounds를 사용하며 test 통계량은 사용하지 않습니다.

특징량은 상수 1개 + 입력 3개 + 제곱 3개 + 두 입력의 곱 3개 = 10개입니다. Train 400행에서 Φ의 크기는 (400, 10), Y는 (400, 2), B는 (10, 2)입니다.

$$\min_B \|\Phi B - Y\|_F^2, \quad \hat{y} = \varphi\left(x\right)B$$

`np.linalg.lstsq`로 B를 학습한 뒤 새 입력을 예측할 때는 고정합니다.

NumPy 최소제곱 함수는 Y가 여러 열이면 각 출력 열의 계수를 구합니다. 표기 ‖ΦB−Y‖²_F는 행·열의 모든 오차 제곱을 더한다는 뜻입니다. 400개 행을 정확히 맞춘다는 조건은 아닙니다.

세 데이터에서 최소제곱 계수 구하기

계수 학습을 작은 무차원 데이터 x=[−1,0,1], y=[1,2,2]로 계산합니다. 모델은 b+ax이며, 세 점을 모두 지나는 직선이 없으므로 오차 제곱합을 가장 작게 만듭니다.

오차 $e_i=b+ax_i-y_i$에 대해 b로 미분하면 $2\sum e_i=0$, a로 미분하면 $2\sum x_i e_i=0$입니다. $\sum x_i=0$, $\sum x_i^2=2$, $\sum y_i=5$, $\sum x_i y_i=1$을 넣으면 3b=5, 2a=1입니다.

x	기준 y	예측 5/3+x/2	오차
−1	1	7/6	1/6
0	2	5/3	−1/3
1	2	13/6	1/6

```
import numpy as np
x = np.array([-1., 0., 1.])
phi = np.column_stack((np.ones(3), x))
coef = np.linalg.lstsq(phi, [1., 2., 2.], rcond=None)[0]
prediction = phi @ coef  # [7/6, 5/3, 13/6]
```

coef=[b,a]이고 오차 제곱합은 1/6입니다. CSTR에서는 특성 열을 10개로 늘리고 출력 두 열에 같은 계산을 적용합니다. `lstsq`는 역행렬을 직접 만들지 않고 최소제곱 문제를 풉니다.

입력 한 행에서 열 개의 특성으로

[330, 5, 1.2]를 정해진 범위로 변환하면 [a,b,c]=[0,−1/9,1/7]입니다. 단위와 크기가 다른 입력을 같은 −1~1 범위로 옮깁니다.

특성 묶음	해당 행의 값
상수와 입력	1, 0, −0.111111, 0.142857
제곱 a^2,b^2,c^2	0, 0.012346, 0.020408
곱 ab,ac,bc	0, 0, −0.015873

```
phi = features(np.array([[330., 5., 1.2]]))
phi_train = features(train_x)
coef = np.linalg.lstsq(phi_train, train_y, rcond=None)[0]
prediction = phi @ coef
```

phi는 (1,10), coef는 (10,2), prediction은 (1,2)입니다. 행렬곱은 특성 열마다 계수를 곱해 두 출력별로 합산합니다. 새 입력에서도 학습 때 사용한 특성 순서를 유지합니다.

체류시간 열은 2×(5−1)/(10−1)−1=−1/9, 유입 농도 열은 2×(1.2−0.8)/(1.5−0.8)−1=1/7입니다. 제곱 열은 이 변환값을 제곱하며 원래 단위의 5나 1.2를 제곱하지 않습니다.

5. 예측 정확도와 출력 일관성 평가

$$\mathrm{RMSE}_j = \sqrt{\frac{1}{N}\sum_{n=1}^{N}\left(\hat{y}_{nj} - y_{nj}\right)^2}$$

출력별로 예측에서 기준값을 빼고 제곱한 값을 test 행 전체에서 평균한 뒤 제곱근을 구합니다. 농도 RMSE는 mol/L, 전환율 RMSE는 무차원입니다.

Seed 42 기준 모델의 농도 RMSE는 0.032623 mol/L, 전환율 RMSE는 0.025608입니다. 평균 오차와 함께 개별 입력의 오차도 확인합니다.

$$r = \hat{C_A} + C_{\mathrm{Af}}\hat{X} - C_{\mathrm{Af}}$$

유입 1.2에서 예측 C_A = 0.65, X = 0.45라면 r = 0.65 + 1.2 × 0.45 − 1.2 = −0.01 mol/L입니다. 이 예측 쌍은 전환율의 정의를 정확히 만족하지 않습니다.

잔차에서 RMSE와 일관성 검사로

농도 기준값 [0.60,0.40] mol/L와 예측 [0.65,0.38] mol/L를 비교합니다.

계산	결과
예측−기준	[0.05,−0.02] mol/L
제곱	[0.0025,0.0004] (mol/L)²
평균	0.00145 (mol/L)²
제곱근	RMSE≈0.038079 mol/L

```
error = prediction - truth
rmse = np.sqrt(np.mean(error**2, axis=0))
```

axis=0은 여러 입력 행을 평균하고 출력 열은 남깁니다. 두 출력을 모두 평균하면 농도와 무차원 전환율을 섞게 됩니다. 별도로 C_A=0.65, X=0.45, C_Af=1.2를 검사하면 0.65+1.2×0.45−1.2=−0.01 mol/L입니다. 정확도와 출력 간 관계를 각각 검사합니다.

6. 확인 문제·해설과 읽기자료

먼저 계산해봅니다. 330 K, 10 min, 유입 1.2 mol/L에서 C_A와 X는 얼마일까요? 두 출력을 학습하는 회귀 계수는 몇 개이며, 작은 train 오차만 보면 왜 잘못 판단할 수 있을까요?

$k\tau = 2$이므로 $C_A = 1.2/3 = 0.4$ mol/L, $X = 2/3$입니다. B에는 출력별 10개씩 총 20개 계수가 있습니다. Train 평가는 학습에 사용한 점을 다시 평가하므로 독립 데이터의 오차는 더 클 수 있습니다.

계산한 내용을 1주차 실습에서 확인합니다. 선택 배경자료는 Boyd·Vandenberghe의 *Convex Optimization* 2·4장에 나오는 affine map과 least-squares 문제입니다(공식 교재 PDF).