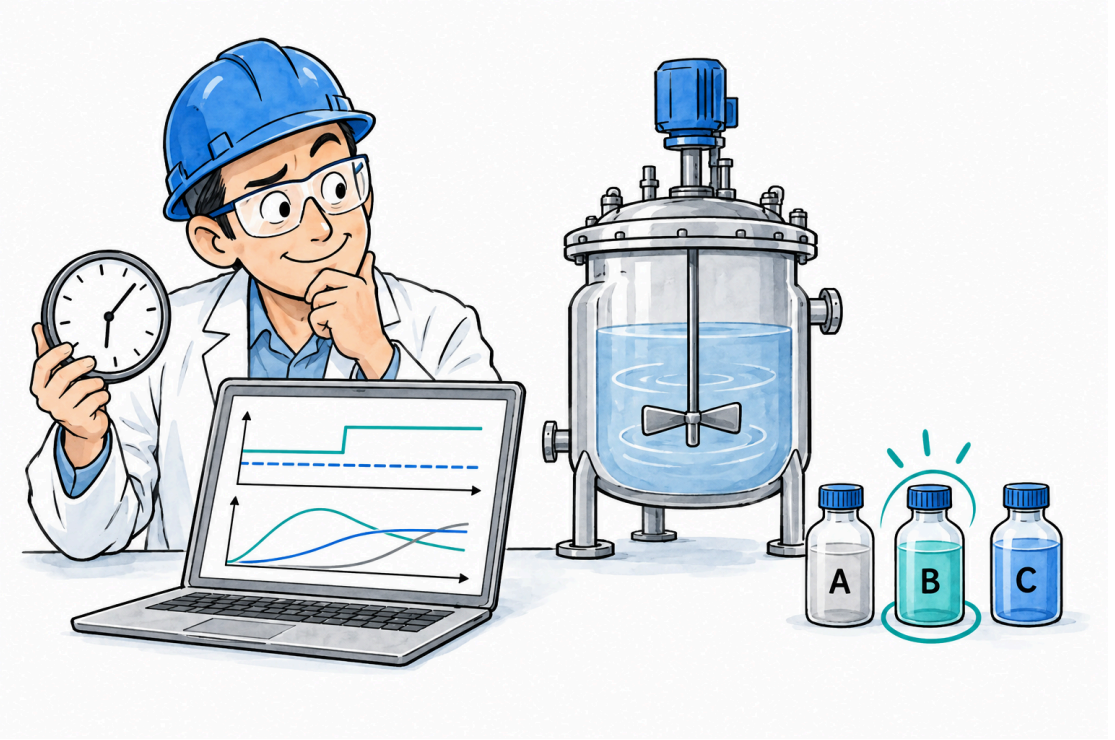
2주차: MLP로 다성분 정상상태 응답 학습하기

연속반응의 전환율과 생성물 조성

A → B → C에서 원하는 중간 생성물은 B입니다. 체류시간이 짧으면 B가 충분히 만들어지지 않고, 길면 더 많은 B가 C로 반응합니다.

전환율 하나로는 제품 조성을 알 수 없으므로 엔지니어는 각 조건의 세 출구 농도를 모두 예측해야 합니다.

한 모델로 A·B·C를 일관되게 예측할 수 있을까요?



성분별 예측 오차

세 농도의 단위는 같아도 변화 폭은 다르므로, 크기를 조정하지 않은 손실함수는 한 성분의 오차를 더 크게 반영할 수 있습니다.

이번 주에는 MLP의 출력 계산, gradient 한 번으로 파라미터가 바뀌는 과정과 성분별 평가를 다뤄봅니다.

정상상태 MLP를 학습하고 확인하기

1. A·B·C의 정상상태 기준값을 유도합니다.
2. 데이터 크기를 조정하고 순전파·역전파·파라미터 갱신을 한 번씩 계산
3. MLP를 학습해 성분별 RMSE와 농도 합 residual을 비교

1. CSTR의 연속반응 A → B → C

기준 공정: 완전혼합·일정 부피·일정 밀도·등온 CSTR의 1차 연속반응 A → B → C. 유입: A 포함, B·C 농도 0. 운전 입력: 온도. 단위: 농도 mol/L, 온도 K, 시간 min

$$\frac{dC_A}{dt} = \frac{C_{Af} - C_A}{\tau} - k_1 C_A$$

$$\frac{dC_B}{dt} = -\frac{C_B}{\tau} + k_1 C_A - k_2 C_B$$

$$\frac{dC_C}{dt} = -\frac{C_C}{\tau} + k_2 C_B$$

B 수지에는 생성과 소모가 모두 들어갑니다. A에서 생기는 $k_1 C_A$는 양수, 다음 반응으로 사라지는 $k_2 C_B$와 탱크 밖으로 나가는 C_B/τ는 음수입니다. B의 최대점은 이 경쟁에서 생깁니다.

속도상수와 운전 영역

두 속도상수의 단위는 1/min이며, 온도에 따라 아래 식으로 계산

$$k_1\left(T\right) = 0.2\exp\left[6000\left(\frac{1}{330} - \frac{1}{T}\right)\right]$$
$$k_2\left(T\right) = 0.1\exp\left[5000\left(\frac{1}{330} - \frac{1}{T}\right)\right]$$

항목	값·범위
기준 온도	330 K
기준 k_1; k_2	0.2; 0.1 /min
온도 민감도 파라미터	6000 K; 5000 K
온도 T	300–360 K
체류시간 τ	1–10 min
유입 A 농도	0.8–1.5 mol/L

세 수지는 각각 A의 소모, B의 생성·소모, C의 생성을 나타냅니다. 세 식을 더하면 반응 항이 상쇄됩니다.

2. 세 출력을 갖는 정상상태 mapping 유도

시간 미분을 0으로 놓고 각 식에 τ를 곱한 뒤 농도 항을 모읍니다.

$$(1 + k_1\tau)\, C_A = C_{\mathrm{Af}}$$
$$(1 + k_2\tau)\, C_B = k_1\tau C_A$$
$$C_C = k_2\tau C_B$$

첫 식은 A만 포함하므로 바로 풀 수 있습니다. 그 A를 두 번째 식에 넣어 B를 구하고, B를 마지막 식에 넣어 C를 구합니다. 이 순서 때문에 세 미지수를 동시에 반복 계산할 필요가 없습니다.

A·B·C 농도 계산

A를 먼저 구하고 B, C에 차례로 대입합니다.

$$C_A = \frac{C_{\mathrm{Af}}}{1 + k_1\tau}$$

$$C_B = \frac{k_1\tau C_{\mathrm{Af}}}{(1 + k_1\tau)(1 + k_2\tau)}$$

$$C_C = k_2\tau C_B$$

330 K, τ = 5 min, 유입 농도 1.2 mol/L에서 농도는 [0.6, 0.4, 0.2] mol/L. 합은 유입 농도와 같으며, 이 세 농도를 정상상태 MLP의 기준값으로 사용

수치 대입은 A=1.2/2=0.6, B=(0.2×5×0.6)/1.5=0.4, C=0.1×5×0.4=0.2 순서입니다. B 계산에서는 분모의 유출 항 1과 다음 반응 항 0.5를 모두 남겨야 합니다.

중간 생성물 B의 비단조 응답

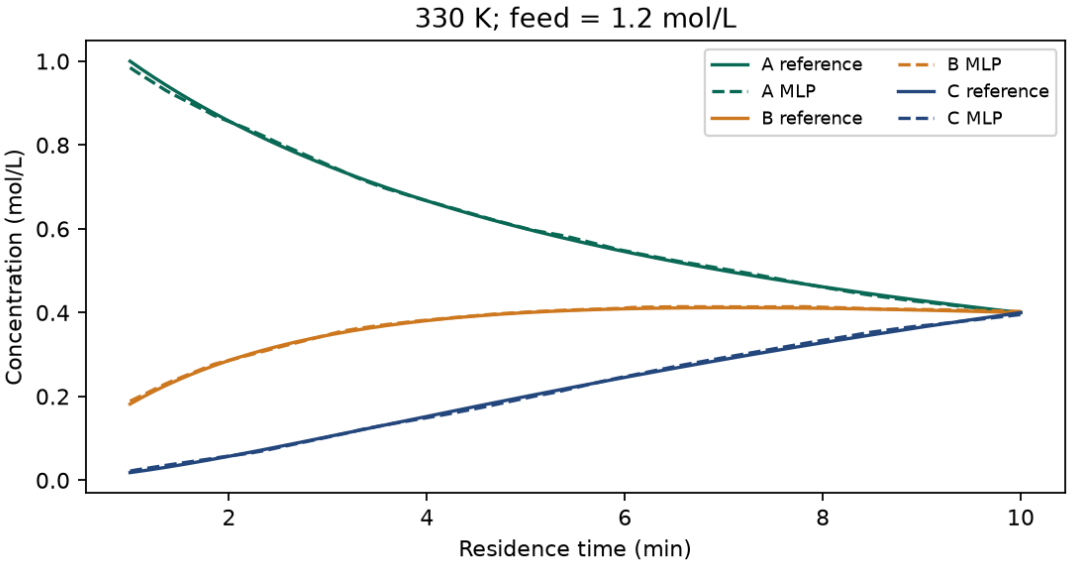
온도가 고정되면 C_B 식에서 B의 수율과 그 수율을 최대화하는 체류시간을 구할 수 있습니다.

$$Y_B = \frac{C_B}{C_{\mathrm{Af}}} = \frac{k_1\tau}{\left(1+k_1\tau\right)\left(1+k_2\tau\right)}, \quad \tau^* = \frac{1}{\sqrt{k_1 k_2}}$$

분모를 $D=1+(k_1+k_2)\tau+k_1k_2\tau^2$로 두면 미분의 분자는 $k_1(D-\tau D')=k_1(1-k_1k_2\tau^2)$입니다. 양의 분모 D^2는 부호를 바꾸지 않습니다. 따라서 $\tau=1/\sqrt{(k_1k_2)}$ 전에는 증가하고 이후에는 감소합니다.

세 성분의 농도 profile 비교

330 K에서 τ*는 약 7.07 min. 짧은 체류시간에서는 B 생성이 부족하고, 체류시간이 길어지면 더 많은 B가 C로 반응합니다.



330 K에서의 다성분 응답. B 농도는 중간 체류시간에서 최대가 된다.

3. 학습 데이터 구성

한 행의 입력은 [T, τ, C_Af], 출력은 [C_A, C_B, C_C]이며 두 배열의 크기는 모두 (N, 3). 표의 운전 영역에서 train 400개, validation 120개, test 160개를 생성하고 정상상태 식으로 기준값을 계산

Train 데이터에서 세 농도의 표준편차는 약 [0.283, 0.110, 0.217] mol/L로, 단위가 같아도 변화 폭은 다릅니다.

한 행의 A·B·C는 같은 입력에서 계산한 하나의 묶음입니다. 성분별로 행을 따로 섞으면 입력과 정답의 대응이 깨집니다. 분할과 순서 섞기는 입력 행과 출력 행에 함께 적용합니다.

4. Forward 계산과 scaling

MLP 구조: 3 → 32 → 32 → 3. ReLU 은닉층과 선형 출력층

은닉층 계산: 가중합 + bias → ReLU(a) = max(0, a). 양수는 통과, 음수는 0. 농도 데이터로 학습하는 파라미터: 가중치와 bias

$$h_1 = \mathrm{ReLU}\left(W_1 \tilde{\mathrm{x}} + b_1\right)$$
$$h_2 = \mathrm{ReLU}\left(W_2 h_1 + b_2\right)$$
$$\hat{z} = W_3 h_2 + b_3$$

층	Weight shape	Bias shape	Parameter 수
입력 → hidden 1	32 × 3	32	128
Hidden 1 → hidden 2	32 × 32	32	1056
Hidden 2 → 출력	3 × 32	3	99
합계			**1283**

한 뉴런은 입력 열 전체를 가중합해 숫자 하나를 만듭니다. 첫 층의 뉴런 32개가 각각 입력 3개의 가중치와 편향 하나를 가져 32×(3+1)=128개입니다. 은닉층은 이 계산을 여러 특징에 반복합니다.

열벡터 수식을 batch 행렬로 계산하기

수식은 입력을 열벡터로 씁니다. Batch 코드가 입력을 (N,3)의 행으로 저장하면 첫 층은 `X @ W1.T + b1`이고 결과는 (N,32)입니다. 전치는 같은 가중합을 행 단위 저장 방식에 맞추며, bias 32개는 각 데이터 행에 반복 적용됩니다.

배열	크기	각 축의 의미
X	N×3	데이터 행, 입력 변수
W1.T	3×32	입력 변수, 은닉 뉴런
X @ W1.T	N×32	데이터 행, 은닉 뉴런
b1	32	각 뉴런의 bias

두 입력 행 [1,0,−1], [0,1,1]과 첫 뉴런 가중치 [1,0,0], bias 0.2를 생각합니다. 첫 출력 열은 각각 1×1+0×0−1×0+0.2=1.2와 0×1+1×0+1×0+0.2=0.2입니다. 나머지 31개 열도 해당 뉴런의 가중치로 같은 계산을 합니다.

행렬곱 뒤 ReLU는 각 원소에 따로 적용합니다. 행 하나가 다른 데이터 행과 섞이는 연산은 아닙니다.

Scaling과 학습 loss

입력은 명시한 하한·상한으로 크기를 조정합니다. 출력은 train 평균 μ와 표준편차 s로 표준화하고, 예측한 뒤 원래 단위로 복원

$$\tilde{x}_j = 2\frac{x_j - l_j}{u_j - l_j} - 1$$

$$z_j = \frac{y_j - \mu_j}{s_j}, \quad \hat{y}_j = \mu_j + s_j \hat{z}_j$$

손실함수는 표본과 표준화된 출력 성분 전체의 제곱 오차를 평균합니다.

$$L = \frac{1}{3N} \sum_{n=1}^{N} \sum_{j=1}^{3} \left(\hat{z}_{n,j} - z_{n,j} \right)^2$$

각 농도 오차를 해당 성분의 train 변화 폭에 상대적으로 평가하므로, 표준편차가 작은 B의 원래 단위 제곱 오차에는 더 큰 가중치가 붙습니다.

같은 0.01 mol/L 오차라도 A의 표준화 오차는 0.01/0.283≈0.0353, B는 0.01/0.110≈0.0909입니다. 제곱하면 B의 손실 기여가 약 6.62배입니다. 출력 scaling은 단위 변환과 함께 학습에서 강조하는 성분도 바꿉니다.

5. Backpropagation 한 번 계산하기

계산 예제: bias가 모두 0인 3 → 2 → 3 신경망. 손실함수: $L = \frac{1}{2}\|\hat{y} - y\|^2$. 학습률: 0.1

$$x = \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}, y = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}$$

$$W_1 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix}, W_2 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix}$$

은닉층의 활성화 전 값 a와 활성화 값 h, 예측값과 오차를 구합니다.

$$a = \begin{bmatrix} 1 \\ -1 \end{bmatrix}, h = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \hat{y} = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}, e = \begin{bmatrix} 1 \\ -1 \\ 1 \end{bmatrix}$$

첫 은닉 뉴런은 입력 첫 성분 1을 읽고, 두 번째는 셋째 성분 −1을 읽습니다. ReLU 뒤에는 [1,0]만 남습니다. 출력층은 이 두 숫자를 각각 [첫째,둘째,두 값의 합]으로 조합하므로 [1,0,1]이 됩니다.

가중치 하나의 연쇄법칙

손계산 손실은 $L=\frac{1}{2}\sum e_j^2$이고 $e_j=\hat{y}_j-y_j$입니다. 따라서 출력 $\hat{y}_j$를 조금 늘렸을 때의 손실 변화율은 e_j입니다. 출력 가중치 $W_{2,ji}$를 늘리면 $\hat{y}_j$는 은닉값 h_i만큼 변합니다.

미분 경로	곱하는 값	앞 예제의 결과
$W_{2,A1} \to \hat{y}_A \to L$	$e_A \times h_1$	$1\times1=1$
$W_{2,B1} \to \hat{y}_B \to L$	$e_B \times h_1$	$-1\times1=-1$
$h_1 \to$ 세 출력 $\to L$	연결 가중치×오차의 합	$1\times1+0\times(-1)+1\times1=2$
$W_{1,13} \to a_1 \to h_1 \to L$	$x_3 \times \mathrm{ReLU}'(a_1) \times 2$	$(-1)\times1\times2=-2$

ReLU 미분은 $a>0$에서 1, $a<0$에서 0입니다. 이 예는 $a=0$을 피합니다. Bias는 가중합에 1배로 더해지므로 그 미분에는 입력값 대신 1을 곱합니다.

δ는 해당 층의 활성화 전 값에 대한 손실 미분, $\odot$는 같은 위치끼리의 곱입니다. 실제 평균제곱 손실에서는 출력 미분이 $2e/(3N)$이므로 손계산의 ½ 제곱합과 계수가 다릅니다.

Gradient와 파라미터 갱신

출력 오차를 출력층 가중치와 ReLU 미분을 거쳐 전달합니다.

$$\delta_2 = e, \nabla_{W_2} L = eh^T = \begin{bmatrix} 1 & 0 \\ -1 & 0 \\ 1 & 0 \end{bmatrix}$$

$$\delta_1 = \left({W_2}^T e \right) \odot \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 2 \\ 0 \end{bmatrix}$$

$$\nabla_{W_1} L = \delta_1 x^T = \begin{bmatrix} 2 & 0 & -2 \\ 0 & 0 & 0 \end{bmatrix}$$

Bias gradient는 각각 δ_1, δ_2입니다. 모든 가중치와 bias를 parameter ← parameter − 0.1 × gradient로 갱신하면 다음 순전파 출력은 [0.26, 0.14, 0.26]이고, loss는 1.5에서 0.4374로 줄어듭니다. Notebook의 autograd 결과와 손계산을 대조합니다.

첫 은닉값은 A와 C 출력에 각각 가중치 1로 연결되어 있어 두 오차 1+1=2를 받습니다. 두 번째 은닉값의 pre-activation은 음수라 ReLU 미분이 0입니다. 따라서 그 뉴런의 입력 가중치와 편향은 이번 단계에서 움직이지 않습니다.

가중치 갱신 뒤의 두 번째 순전파

학습률 0.1로 가중치와 편향을 모두 갱신합니다. 첫 은닉 가중치 [1,0,0]에서 0.1×[2,0,−2]를 빼면 [0.8,0,0.2], 편향은 −0.2가 됩니다.

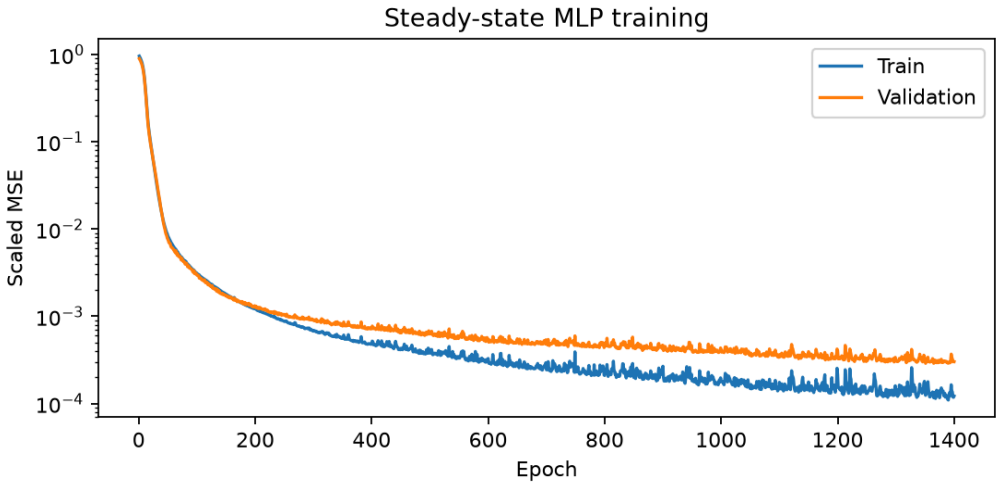
중간값	갱신 뒤 계산
첫 은닉 pre-activation	0.8×1+0×0+0.2×(−1)−0.2=0.4
두 번째 은닉 pre-activation	−1
ReLU 출력	[0.4,0]
출력 A, C	0.9×0.4−0.1=0.26
출력 B	0.1×0.4+0.1=0.14

새 오차는 [0.26,−0.86,0.26]입니다. 손실은 (0.0676+0.7396+0.0676)/2=0.4374로 줄지만 B는 여전히 목표 1보다 작습니다. 한 번의 감소가 학습 완료를 뜻하지는 않습니다.

6. 정상상태 모델 학습과 평가

학습 설정: Adam, 학습률 0.001, batch 64, 최대 1400 epoch. 가중치 선택: 매 epoch의 validation loss 중 최솟값

```
prediction = model(inputs)
loss = loss_function(prediction, targets)
optimizer.zero_grad()
loss.backward()
optimizer.step()
```



Train·validation loss. 아래 예측 지표는 mol/L 단위로 되돌린 뒤 계산한다.

학습 루프의 값과 변경 시점

```
prediction = model(inputs)
loss = loss_function(prediction, targets)
optimizer.zero_grad()
loss.backward()
optimizer.step()
```

줄	만들어지거나 바뀌는 값
model(inputs)	현재 가중치로 batch의 출력 계산
loss_function	출력과 정답 차이를 스칼라 손실로 축약
zero_grad	이전 batch의 기울기 제거
backward	현재 손실의 가중치·편향별 기울기
step	기울기와 optimizer 상태로 파라미터 갱신

손 계산은 단순 gradient descent였고 실제 학습은 Adam입니다. Adam은 과거 기울기 정보도 사용하므로 같은 0.1배 빼기와 수치가 같지 않습니다. step 뒤의 성능을 보려면 갱신된 가중치로 순전파를 다시 수행합니다.

Adam의 첫 갱신과 batch의 의미

Batch는 한 번에 손실과 기울기를 계산하는 데이터 묶음입니다. 400개 행을 batch 64로 나누면 한 epoch에 64개짜리 6묶음과 16개짜리 마지막 묶음, 총 7번 갱신합니다. Epoch는 학습 데이터 한 바퀴입니다.

Adam은 기울기 평균 m과 제곱 평균 v를 누적합니다. 처음 $m=v=0$, 기울기 $g=2$, $\beta_1=0.9$, $\beta_2=0.999$인 가중치 하나를 계산합니다.

계산	첫 단계 값
$m=0.9m+0.1g$	0.2
$v=0.999v+0.001g^2$	0.004
초기 0의 편향 보정	$\hat{m}=0.2/(1-0.9)=2$; $\hat{v}=0.004/(1-0.999)=4$
학습률 0.001의 이동 크기	$0.001\times2/(\sqrt{4}+10^{-8})\approx0.001$

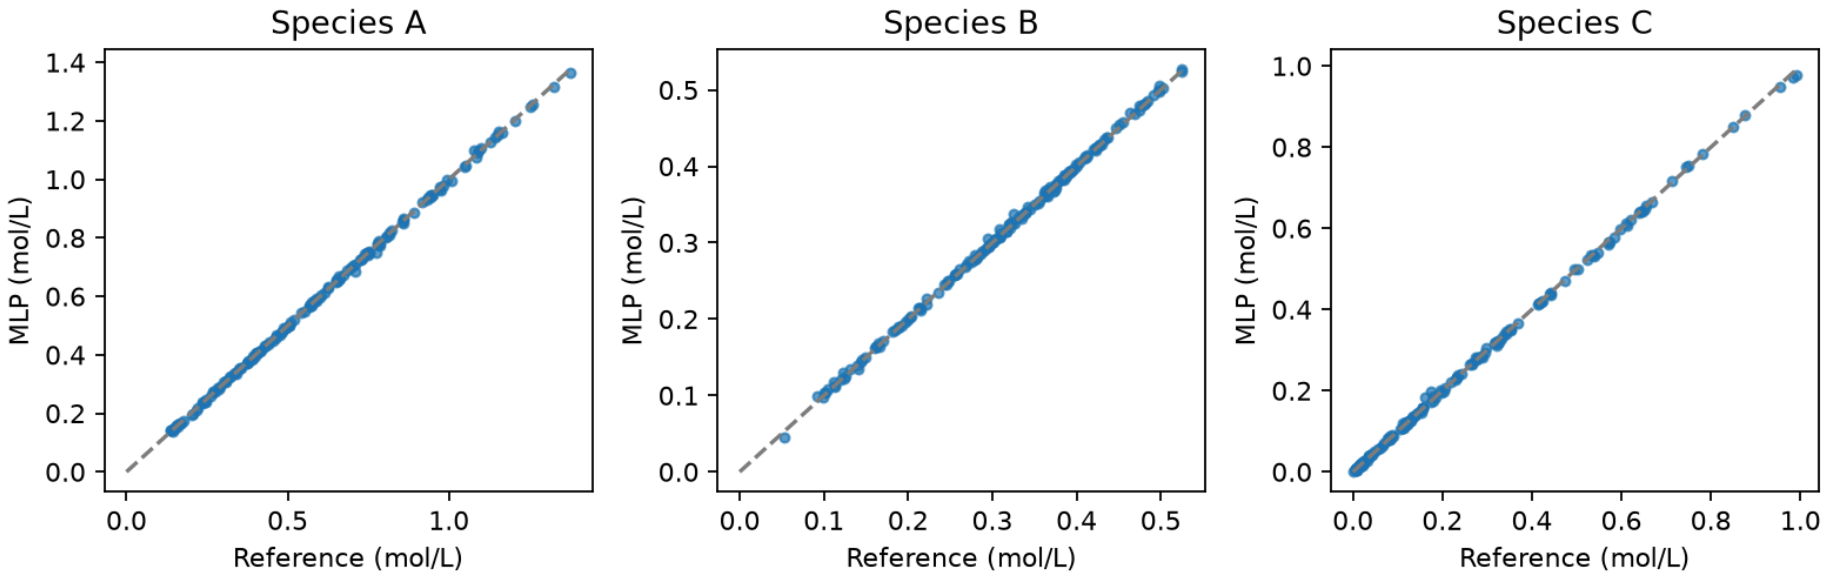
단순 경사하강이라면 $0.001\times2=0.002$를 뺍니다. Adam은 누적된 기울기 크기로 이동을 조정하므로 같은 학습률이어도 갱신량이 다릅니다. 이 계산의 $\varepsilon=10^{-8}$은 분모가 0이 되는 것을 막습니다.

PyTorch Adam의 갱신 정의

출력 성분별 평가

Test RMSE, mol/L	A	B	C
출력 scaling 적용	0.005275	0.002940	0.004423
출력 scaling 미적용	0.006634	0.003917	0.004162

이번 실행에서는 출력 scaling으로 A·B RMSE가 줄었고 C RMSE는 조금 커졌습니다. 각 성분의 변화를 따로 확인해야 전체 오차 하나에 가려진 차이를 볼 수 있습니다.



성분별 parity plot에서 각 출력의 오차를 확인한다.

표준화 출력에서 농도와 오차로

계산용 한 성분의 학습 평균 μ=0.4 mol/L, 표준편차 s=0.1 mol/L를 둡니다. 정답 농도 0.45는 z=(0.45−0.4)/0.1=0.5입니다.

항목	계산
신경망의 표준화 예측	$\hat{z}=0.3$
농도 복원	0.4+0.1×0.3=0.43 mol/L
표준화 오차	0.3−0.5=−0.2
농도 오차	0.43−0.45=−0.02 mol/L

```
prediction = y_mean + y_scale * standardized_prediction
component_rmse = np.sqrt(((prediction - truth)**2).mean(axis=0))
sum_residual = prediction.sum(axis=1) - feed
```

첫 줄은 각 출력 열에 해당 평균과 표준편차를 적용합니다. axis=0은 성분별 정확도, axis=1은 같은 조건의 세 성분 합을 계산합니다. 두 축을 바꾸면 다른 질문을 계산하게 됩니다.

농도 합 확인

$$r = \hat{C}_A + \hat{C}_B + \hat{C}_C - C_{\mathrm{Af}}$$

Test residual RMSE는 0.003781 mol/L. 성분별 오차로 예측 정확도를, 농도 합 residual로 해당 수지의 일관성을 평가

수지를 만족하는 기준값으로 학습해도 세 선형 출력의 합이 유입 농도와 같도록 강제되지는 않습니다.

유입 1.2 mol/L에서 예측이 [0.62, 0.41, 0.20] mol/L이면 합은 1.23 mol/L이고 r = 0.03 mol/L입니다.
몰분율을 예측할 때도 합이 1을 벗어날 수 있습니다.

성분 오차의 합이 합 잔차입니다. 오차 [0.02,−0.01,−0.01]은 합이 0이지만 성분은 틀립니다. 반대로 작은 양의 오차가 세 성분에 누적되면 총농도 오차가 커집니다.

4주차 예고: 농도 합 제약의 모델 반영

학습 후 출력을 보정하거나, 제약을 만족하는 변환을 학습 과정에 포함할 수 있습니다.

접근	보정이 들어가는 위치
학습 후 외부 mapping/projection	Raw predictor를 학습한 뒤 출력을 보정한다.
KKT-hPINN	입력과 raw 예측을 받는 고정 affine projection을 loss 전에 적용하며, 예측할 때도 적용한다.

$$x \rightarrow f_\theta \rightarrow \hat{y} \rightarrow \Pi_x \rightarrow \tilde{y} \rightarrow \text{loss}$$

KKT-hPINN은 투영한 출력으로 loss를 계산하고 투영층을 거쳐 역전파합니다. 투영 계수는 고정하지만 MLP 가중치는 이 변환을 반영해 학습합니다.

투영층은 지정한 선형 등식을 수치 연산 오차 범위에서 만족시키며, 비음수성에는 별도 제약이 필요합니다.

출처: Chen et al. (2024), DOI: 10.1016/j.compchemeng.2024.108764.

7. 필수 정상상태 실습 실행

정상상태 Notebook을 받습니다.

```
python -m pip install -r requirements.txt
python week02_lab.py --mode steady --output-dir week02-results
```

학습한 예측 모델의 성분별 RMSE와 농도 합 residual을 평가

8. 필수 연습문제와 제출물

1. C_A·C_B·C_C를 유도해 합을 확인하고, B 곡선이 단조롭지 않은 이유를 설명합니다.
2. 정상상태 MLP의 파라미터 1283개와 손으로 계산한 gradient 갱신을 확인
3. 출력 scaling 전후의 성분별 RMSE를 비교
4. 독립 입력에서 농도 합 residual과 최소 예측 농도를 살펴봅니다.

제출물: 정상상태 모델, 데이터 분할·scaling 정보, 확인한 gradient 갱신, 성분별 오차·일관성 평가

구현 설명은 PyTorch의 모델 구성, autograd, 학습을 참고합니다.

읽기자료

2주차 읽기자료 · 국문 PDF

KKT-hPINN 참고문헌: Chen, H., Constante Flores, G. E., & Li, C. (2024). Physics-informed neural networks with hard linear equality constraints. *Computers & Chemical Engineering*, 189, 108764.