


2주차: MLP로 다성분 정상상태 응답 학습하기

A가 줄어들면 B는 얼마나 만들어질까?

$A \rightarrow B \rightarrow C$ 에서 원하는 중간 생성물은 B다. 체류시간이 짧으면 B가 충분히 만들어지지 않고, 길면 더 많은 B가 C로 반응한다.

엔지니어는 각 조건에서 세 출구 농도를 알아야 한다. 전환율 하나로는 제품 조성을 설명할 수 없다.

한 모델이 A·B·C를 일관되게 예측할 수 있을까?



출력은 세 개, 오차의 크기도 다르다

세 농도의 단위는 같아도 변화 폭은 다르다. Scaling 없는 loss는 한 성분을 더 강조할 수 있다.

이번 주는 MLP가 출력을 계산하는 방법, 한 번의 gradient 갱신으로 파라미터가 바뀌는 과정, 성분별 평가를 배운다.

정상상태 MLP를 학습하고 확인하기

1. A·B·C의 정상상태 label을 유도한다.
2. 데이터를 scaling하고 forward·backpropagation·파라미터 갱신 한 번을 따라간다.
3. MLP를 학습하고 성분별 RMSE와 농도 합 residual을 비교한다.

1. CSTR의 연속반응 $A \rightarrow B \rightarrow C$

완전혼합·일정 부피·일정 밀도·등온 CSTR에서 1차 연속반응 $A \rightarrow B \rightarrow C$ 를 다룬다. 유입물은 A를 포함하며 B·C의 유입 농도는 0이다. 온도는 운전 입력이다. 농도 단위는 mol/L, 온도는 K, 시간은 min이며 물질수지는 다음과 같다.

$$\begin{aligned}\frac{dC_A}{dt} &= \frac{C_{Af} - C_A}{\tau} - k_1 C_A \\ \frac{dC_B}{dt} &= -\frac{C_B}{\tau} + k_1 C_A - k_2 C_B \\ \frac{dC_C}{dt} &= -\frac{C_C}{\tau} + k_2 C_B\end{aligned}$$

속도상수와 운전 영역

두 속도상수의 단위는 1/min이다. 온도 의존성은 다음 식을 사용한다.

$$k_1(T) = 0.2 \exp \left[6000 \left(\frac{1}{330} - \frac{1}{T} \right) \right]$$
$$k_2(T) = 0.1 \exp \left[5000 \left(\frac{1}{330} - \frac{1}{T} \right) \right]$$

항목	값·범위
기준 온도	330 K
기준 k_1 ; k_2	0.2; 0.1 /min
온도 민감도 파라미터	6000 K; 5000 K
온도 T	300–360 K
체류시간 τ	1–10 min
유입 A 농도	0.8–1.5 mol/L

세 수지는 A의 소모, B의 생성·소모, C의 생성을 나타낸다. 세 식을 더하면 반응 항이 상쇄된다.

2. 세 출력을 갖는 정상상태 mapping 유도

시간 미분을 0으로 놓고 각 식에 τ 를 곱한다. 농도 항을 모으면 다음 관계를 얻는다.

$$\begin{aligned}(1 + k_1\tau)C_A &= C_{Af} \\ (1 + k_2\tau)C_B &= k_1\tau C_A \\ C_C &= k_2\tau C_B\end{aligned}$$

A·B·C 농도 계산

A, B, C 순서로 풀면 다음과 같다.

$$\begin{aligned}C_A &= \frac{C_{Af}}{1 + k_1\tau} \\C_B &= \frac{k_1\tau C_{Af}}{(1 + k_1\tau)(1 + k_2\tau)} \\C_C &= k_2\tau C_B\end{aligned}$$

330 K, $\tau = 5$ min, 유입 농도 1.2 mol/L에서는 **[0.6, 0.4, 0.2] mol/L**이다. 세 농도의 합은 유입 농도와 같다. 이 세 출력을 정상상태 MLP의 label로 사용한다.


B 응답이 단조롭지 않은 이유

고정 온도에서 B의 수율과 이를 최대화하는 체류시간은 C_B 식에서 얻는다.

$$Y_B = \frac{C_B}{C_{Af}} = \frac{k_1 \tau}{(1 + k_1 \tau)(1 + k_2 \tau)}, \quad \tau^* = \frac{1}{\sqrt{k_1 k_2}}$$

세 성분의 농도 profile 비교

330 K에서 τ^* 는 약 7.07 min이다.
체류시간이 짧으면 B가 충분히
생성되지 않고, 길면 더 많은 B가 C로
반응한다.



330 K에서의 다성분 응답. B 농도는 중간 체류시간에서 최대가 된다.

3. 학습 데이터 구성

한 행의 입력은 $[T, \tau, C_{Af}]$, 출력은 $[C_A, C_B, C_C]$ 다. 입력·출력 배열의 shape은 모두 $(N, 3)$ 이다. 표의 운전 영역에서 train 400개, validation 120개, test 160개를 생성하고 정상상태 식으로 label을 계산한다.

세 농도는 단위가 같지만 변화 폭이 다르다. Train 데이터의 표준편차는 약 $[0.283, 0.110, 0.217]$ mol/L이다.

4. Forward 계산과 scaling

$3 \rightarrow 32 \rightarrow 32 \rightarrow 3$ MLP를 사용한다. Hidden layer에는 ReLU, 출력층에는 linear 연산을 둔다.

각 hidden layer는 입력의 가중합에 bias를 더한다. $\text{ReLU}(a) = \max(0, a)$ 는 양수 값을 그대로 두고 음수 값을 0으로 만든다. 농도 데이터에 맞춰 학습하는 parameter는 weight와 bias다.

$$h_1 = \text{ReLU}(W_1 \tilde{x} + b_1)$$

$$h_2 = \text{ReLU}(W_2 h_1 + b_2)$$

$$\hat{z} = W_3 h_2 + b_3$$

층	Weight shape	Bias shape	Parameter 수
입력 $\rightarrow$ hidden 1	32×3	32	128
Hidden 1 $\rightarrow$ hidden 2	32×32	32	1056
Hidden 2 $\rightarrow$ 출력	3×32	3	99
합계			1283

Scaling과 학습 loss

입력은 명시한 하한·상한으로 scaling한다. 각 출력은 train 평균 μ 와 표준편차 s 로 표준화하고, 예측 뒤 원래 단위로 되돌린다.

$$\tilde{x}_j = 2 \frac{x_j - l_j}{u_j - l_j} - 1$$
$$z_j = \frac{y_j - \mu_j}{s_j}, \quad \hat{y}_j = \mu_j + s_j \hat{z}_j$$

Loss는 표본과 표준화된 출력 성분에 걸쳐 제곱 오차를 평균한다.

$$L = \frac{1}{3N} \sum_{n=1}^N \sum_{j=1}^3 \left(\hat{z}_{n,j} - z_{n,j} \right)^2$$

농도 오차를 해당 성분의 train 변화 폭에 상대적으로 평가하는 셈이다. 표준편차가 작은 B의 원래 단위 제곱 오차에는 더 큰 가중치가 붙는다.

5. Backpropagation 한 번 계산하기

Bias가 모두 0인 $3 \rightarrow 2 \rightarrow 3$ 신경망에서 다음 값을 사용한다. 이번 계산의 loss는 $L = \frac{1}{2}\|\hat{y} - y\|^2$, learning rate는 0.1이다.

$$x = \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}, y = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}$$
$$W_1 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix}, W_2 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix}$$

Hidden pre-activation a , activation h , 예측값, 오차는 다음과 같다.

$$a = \begin{bmatrix} 1 \\ -1 \end{bmatrix}, h = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \hat{y} = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}, e = \begin{bmatrix} 1 \\ -1 \\ 1 \end{bmatrix}$$

Gradient와 파라미터 갱신

출력 오차를 출력층 가중치와 ReLU 미분을 거쳐 전달한다.

$$\delta_2 = e, \nabla_{W_2} L = eh^T = \begin{bmatrix} 1 & 0 \\ -1 & 0 \\ 1 & 0 \end{bmatrix}$$

$$\delta_1 = \left(W_2^T e \right) \odot \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 2 \\ 0 \end{bmatrix}$$


$$\nabla_{W_1} L = \delta_1 x^T = \begin{bmatrix} 2 & 0 & -2 \\ 0 & 0 & 0 \end{bmatrix}$$

Bias gradient는 각각 δ_1, δ_2 다. 모든 weight·bias를 $\text{parameter} \leftarrow \text{parameter} - 0.1 \times \text{gradient}$ 로 갱신한다. 다음 forward의 출력은 **[0.26, 0.14, 0.26]**, loss는 **1.5**에서 **0.4374**로 감소한다. Notebook에서 autograd로 이 gradient를 확인한다.

6. 정상상태 모델 학습과 평가

Adam, learning rate 0.001, batch 64, 최대 1400 epoch를 사용한다. 매 epoch 뒤 validation loss를 계산하고 최소값의 가중치를 저장한다. 한 batch의 학습은 다음 연산으로 구성된다.

```
prediction = model(inputs)
loss = loss_function(prediction, targets)
optimizer.zero_grad()
loss.backward()
optimizer.step()
```




Train·validation loss. 아래 예측 지표는 mol/L 단위로 되돌린 뒤 계산한다.

출력 성분별 평가

Test RMSE, mol/L	A	B	C
출력 scaling 적용	0.005275	0.002940	0.004423
출력 scaling 미적용	0.006634	0.003917	0.004162

이 비교에서는 출력 scaling으로 A·B RMSE가 감소하고, C RMSE는 조금 증가했다. 세 오차를 하나로 합치기보다 성분별로 확인한다.



성분별 parity plot에서 각 출력의 오차를 확인한다.

농도 합 확인

농도 합 residual도 계산한다.

$$r = \hat{C}_A + \hat{C}_B + \hat{C}_C - C_{Af}$$

Test residual RMSE는 **0.003781 mol/L**이다. 성분별 예측 오차와 농도 합 residual은 모델의 서로 다른 성질을 보여준다.

세 linear output은 자유롭게 예측된다. 수지를 만족하는 label로 학습해도 예측 농도 합이 유입 농도와 같도록 강제되지는 않는다.

유입 **1.2 mol/L**에서 예측이 **[0.62, 0.41, 0.20] mol/L**이면 합은 **1.23 mol/L**, **r = 0.03 mol/L**이다. 물분율을 예측하는 모델에서도 합이 1과 다른 값이 나올 수 있다.

예측 오차가 작다는 것과 반드시 지켜야 할 등식을 만족한다는 것은 다르다.

4주차 예고: 제약을 모델 안에 넣으면?

학습 후 예측을 보정할 수도 있고, 제약을 지키는 변환을 학습 계산 안에 넣을 수도 있다.

접근	보정이 들어가는 위치
학습 후 외부 mapping/projection	Raw predictor를 학습한 뒤 출력을 보정한다.
KKT-hPINN	입력과 raw 예측을 받는 고정 affine projection을 loss 전에 적용하며, 예측할 때도 적용한다.

$$x \rightarrow f_{\theta} \rightarrow \hat{y} \rightarrow \Pi_x \rightarrow \tilde{y} \rightarrow \text{loss}$$

KKT-hPINN은 projection을 거친 출력으로 loss를 계산하고, projection을 통해 역전파한다. Layer의 계수는 고정되어 있고, MLP의 weight는 이 변환을 반영하여 학습한다.

4주차에서 projection·KKT 조건을 유도하고 rank 가정과 gradient를 확인한다. 보장 범위는 명시한 선형 등식의 만족(수치 연산 오차 범위)이며, 비음수성은 별도 제약이 필요하다.

출처: Chen et al. (2024), [DOI: 10.1016/j.compchemeng.2024.108764](https://doi.org/10.1016/j.compchemeng.2024.108764). 공개 원문: 3절과 Remark 3.

7. 필수 정상상태 실습 실행

[정상상태 Notebook](#) 또는 [실습 묶음](#)을 받는다. 묶음에는 후반부의 선택 자료도 보존했다.

```
python -m pip install -r requirements.txt
python week02_lab.py --mode steady --output-dir week02-results
```

학습한 predictor의 성분별 RMSE와 농도 합 residual을 평가한다. 기록된 운전점 선택 결과는 후반부 최적화 내용이다.

8. 필수 연습문제와 제출물

1. $C_A \cdot C_B \cdot C_C$ 를 유도하고 합을 확인한다. B 곡선이 단조롭지 않은 이유를 설명한다.
2. 정상상태 MLP의 **1283개** 파라미터와 손 계산한 gradient 갱신을 확인한다.
3. 출력 scaling 적용 전후의 성분별 RMSE를 비교한다.
4. 독립 입력에서 농도 합 residual과 최소 예측 농도를 살펴본다.

정상상태 모델, 분할·scaling 정보, 확인한 gradient 갱신, 성분별 오차·일관성 평가를 제출한다.

원문 해설: PyTorch [모델 구성](#), [autograd](#), [학습](#).

읽기자료

[2주차 읽기자료](#)와 [국문 PDF](#)에서 세 출력 mapping, 파라미터 수, scaling, gradient 갱신, 학습 loop와 독립 진단을 읽는다.

KKT-hPINN 참고문헌: Chen, H., Constante Flores, G. E., & Li, C. (2024). [Physics-informed neural networks with hard linear equality constraints](#). *Computers & Chemical Engineering*, **189**, 108764.

동적 농도 데이터 생성

같은 수지식으로 $\Delta t = 0.2 \text{ min}$, 30 min 길이의 궤적을 생성한다. 입력 구간은 150개, 농도 시점은 151개다. 한 궤적 안에서 유입 농도·체류시간은 고정하고 온도를 구간 사이에서 바꾼다. 각 초기 농도 벡터의 합은 유입 농도와 같다.

세 수지를 더하면 전체 농도의 시간 변화를 얻는다.

$$\frac{d(C_A + C_B + C_C)}{dt} = \frac{C_{Af} - (C_A + C_B + C_C)}{\tau}$$

이 초기 조건과 고정 유입 농도에서 기준 농도의 합은 궤적 전체에 걸쳐 C_{Af} 를 유지한다.

Train 60개, validation 15개, test 20개 궤적을 생성한다. 상태전이 표본 수는 각각 9000, 2250, 3000개다. 궤적 전체를 세 집합에 배정한다. 각 행은 현재 농도, 운전 입력, 다음 농도를 포함한다.

동적 MLP 학습


현재 세 농도와 $[T, \tau, C_{Af}]$ 를 합친 여섯 값을 입력한다. $6 \rightarrow 32 \rightarrow 32 \rightarrow 3$ 구조이며 parameter는 1379개다. 세 출력의 학습 target은 농도 변화량 $\Delta c = c_{next} - c_{current}$ 다. 입력과 변화량 모두 train 통계량으로 표준화한다.

$$v_k = \begin{bmatrix} C_{A_k} \\ C_{B_k} \\ C_{C_k} \\ T_k \\ \tau_k \\ C_{Af} \end{bmatrix}$$

$$\hat{c}_{k+1} = c_k + \mu_{\Delta} + s_{\Delta} \odot g_{\theta}(\tilde{v}_k)$$

μ_{Δ} 와 s_{Δ} 로 변화량을 mol/L 단위로 복원한다. 이를 현재 농도에 더하면 다음 상태를 얻는다. Adam, learning rate 0.001, batch 512, 최대 800 epoch로 학습하고 validation 최소값의 가중치를 저장한다.

동적 모델 학습 곡선



동적 loss는 표준화된 농도 변화량에서 계산한다.

One-step 예측과 시계열 rollout


One-step 평가에서는 각 시점의 기준 농도를 입력한다. Rollout에서는 지정한 초기 농도로 시작한 뒤 직전 예측값을 다음 입력으로 사용한다.

$$\text{one-step: } \hat{c}_{k+1} = f_{\theta}(c_k, u_k)$$

$$\text{rollout: } \hat{c}_{k+1} = f_{\theta}(\hat{c}_k, u_k)$$

두 평가 모두 미래 운전 입력은 주어진 계획을 사용한다. 온도 330 K 유지와 10 min에 330 → 345 K로 바꾸는 계획을 비교한다. 두 계획의 τ 는 5 min, 유입 농도는 1.2 mol/L, 초기 농도는 [1.2, 0, 0] mol/L다.

두 온도 계획의 전체 시계열



실선은 기준 농도, 점선은 MLP rollout이다. 온도 계획에 따라 세 성분의 시간 응답이 달라진다.


One-step과 rollout 오차

Test RMSE, mol/L	A	B	C
One-step	0.001170	0.001288	0.001163
30 min rollout	0.009465	0.009629	0.010425

물리적 확인	One-step	Rollout
농도 합 RMSE, mol/L	0.000051	0.002014
최소 예측 농도, mol/L	-0.001152	-0.005166

Rollout은 이미 예측한 상태에서 다음 값을 계산하므로 오차가 더 크다. 최소 농도에서는 작은 음수 예측도 확인된다. 전체 궤적에서 성분별 오차와 농도 합을 함께 살핀다.

예측 horizon에 따른 오차



Test 궤적 20개의 시간별 오차. 점선은 성분별 one-step RMSE다.

최종 B 농도 비교

30 min의 B 농도, mol/L	기준 모델	MLP rollout
330 K 유지	0.400091	0.399819
330 → 345 K step	0.420021	0.411526


두 계산 모두 온도 step 계획의 마지막 B 농도가 더 높다. MLP는 step 계획의 마지막 농도를 작게 예측하며, 시계열 비교에서 차이가 생기는 구간을 확인할 수 있다.

후반부 미리보기: B 생산을 위한 운전점 선택

유입 농도를 1.2 mol/L로 고정하고 예측 B 농도를 최대화한다. 온도 간격 0.5 K, 체류시간 간격 0.1 min의 grid를 평가한다. 예측한 각 성분 농도가 0과 유입 농도 사이인 후보를 사용하고, 선택한 운전점을 기준 mapping으로 확인한다.

항목	결과
MLP가 선택한 온도·체류시간	360.000000 K; 1.700000 min
예측 B 농도	0.451111 mol/L
선택한 지점의 기준 B 농도	0.455285 mol/L
기준 grid 최대점의 온도·체류시간	360.000000 K; 1.800000 min
기준 grid의 최대 B 농도	0.455382 mol/L
MLP 선택점의 기준 B 수율	0.379404

후반부 미리보기: 선택한 운전점 비교



MLP가 선택한 체류시간은 1.7 min, 기준 grid는 1.8 min이다. 두 지점의 기준 B 농도를 비교한다.