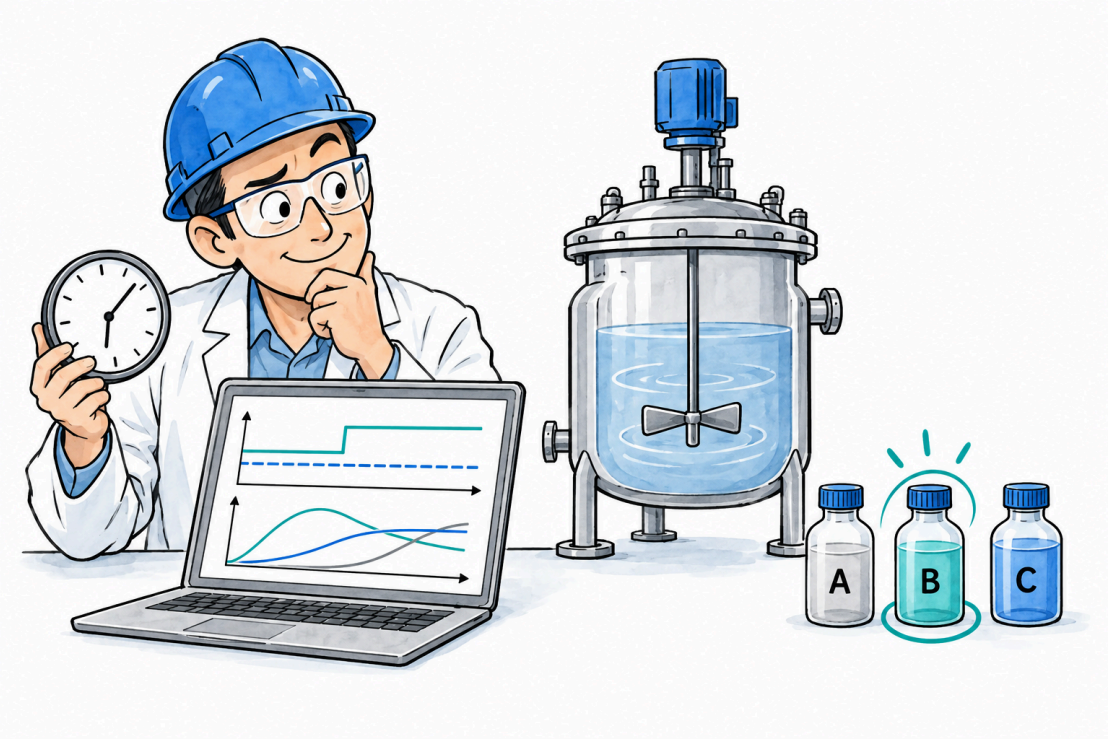
2주차: MLP로 다성분 정상상태 응답 학습하기

연속반응의 전환율과 생성물 조성

A → B → C에서 원하는 중간 생성물은 B입니다. 체류시간이 짧으면 B가 충분히 만들어지지 않고, 길면 더 많은 B가 C로 반응합니다.

전환율 하나로는 제품 조성을 알 수 없으므로 엔지니어는 각 조건의 세 출구 농도를 모두 예측해야 합니다.

한 모델로 A·B·C를 일관되게 예측할 수 있을까요?



성분별 예측 오차

세 농도의 단위는 같아도 변화 폭은 다르므로, 크기를 조정하지 않은 손실함수는 한 성분의 오차를 더 크게 반영할 수 있습니다.

이번 주에는 MLP의 출력 계산, gradient 한 번으로 파라미터가 바뀌는 과정과 성분별 평가를 다뤄봅니다.

정상상태 MLP를 학습하고 확인하기

1. A·B·C의 정상상태 기준값을 유도합니다.
2. 데이터 크기를 조정하고 순전파·역전파·파라미터 갱신을 한 번씩 계산
3. MLP를 학습해 성분별 RMSE와 농도 합 residual을 비교

1. CSTR의 연속반응 A → B → C

기준 공정: 완전혼합·일정 부피·일정 밀도·등온 CSTR의 1차 연속반응 A → B → C. 유입: A 포함, B·C 농도 0. 운전 입력: 온도. 단위: 농도 mol/L, 온도 K, 시간 min

$$\frac{dC_A}{dt} = \frac{C_{Af} - C_A}{\tau} - k_1 C_A$$

$$\frac{dC_B}{dt} = -\frac{C_B}{\tau} + k_1 C_A - k_2 C_B$$

$$\frac{dC_C}{dt} = -\frac{C_C}{\tau} + k_2 C_B$$

B 수지에는 생성과 소모가 모두 들어갑니다. A에서 생기는 $k_1 C_A$는 양수, 다음 반응으로 사라지는 $k_2 C_B$와 탱크 밖으로 나가는 C_B/τ는 음수입니다. B의 최대점은 이 경쟁에서 생깁니다.

속도상수와 운전 영역

두 속도상수의 단위는 1/min이며, 온도에 따라 아래 식으로 계산

$$k_1\left(T\right) = 0.2\exp\left[6000\left(\frac{1}{330} - \frac{1}{T}\right)\right]$$
$$k_2\left(T\right) = 0.1\exp\left[5000\left(\frac{1}{330} - \frac{1}{T}\right)\right]$$

항목	값·범위
기준 온도	330 K
기준 k_1; k_2	0.2; 0.1 /min
온도 민감도 파라미터	6000 K; 5000 K
온도 T	300–360 K
체류시간 τ	1–10 min
유입 A 농도	0.8–1.5 mol/L

세 수지는 각각 A의 소모, B의 생성·소모, C의 생성을 나타냅니다. 세 식을 더하면 반응 항이 상쇄됩니다.

2. 세 출력을 갖는 정상상태 mapping 유도

시간 미분을 0으로 놓고 각 식에 τ를 곱한 뒤 농도 항을 모읍니다.

$$(1 + k_1\tau)\, C_A = C_{\mathrm{Af}}$$
$$(1 + k_2\tau)\, C_B = k_1\tau C_A$$
$$C_C = k_2\tau C_B$$

첫 식은 A만 포함하므로 바로 풀 수 있습니다. 그 A를 두 번째 식에 넣어 B를 구하고, B를 마지막 식에 넣어 C를 구합니다. 이 순서 때문에 세 미지수를 동시에 반복 계산할 필요가 없습니다.

A·B·C 농도 계산

A를 먼저 구하고 B, C에 차례로 대입합니다.

$$C_A = \frac{C_{\mathrm{Af}}}{1 + k_1\tau}$$

$$C_B = \frac{k_1\tau C_{\mathrm{Af}}}{(1 + k_1\tau)(1 + k_2\tau)}$$

$$C_C = k_2\tau C_B$$

330 K, τ = 5 min, 유입 농도 1.2 mol/L에서 농도는 [0.6, 0.4, 0.2] mol/L. 합은 유입 농도와 같으며, 이 세 농도를 정상상태 MLP의 기준값으로 사용

수치 대입은 A=1.2/2=0.6, B=(0.2×5×0.6)/1.5=0.4, C=0.1×5×0.4=0.2 순서입니다. B 계산에서는 분모의 유출 항 1과 다음 반응 항 0.5를 모두 남겨야 합니다.

중간 생성물 B의 비단조 응답

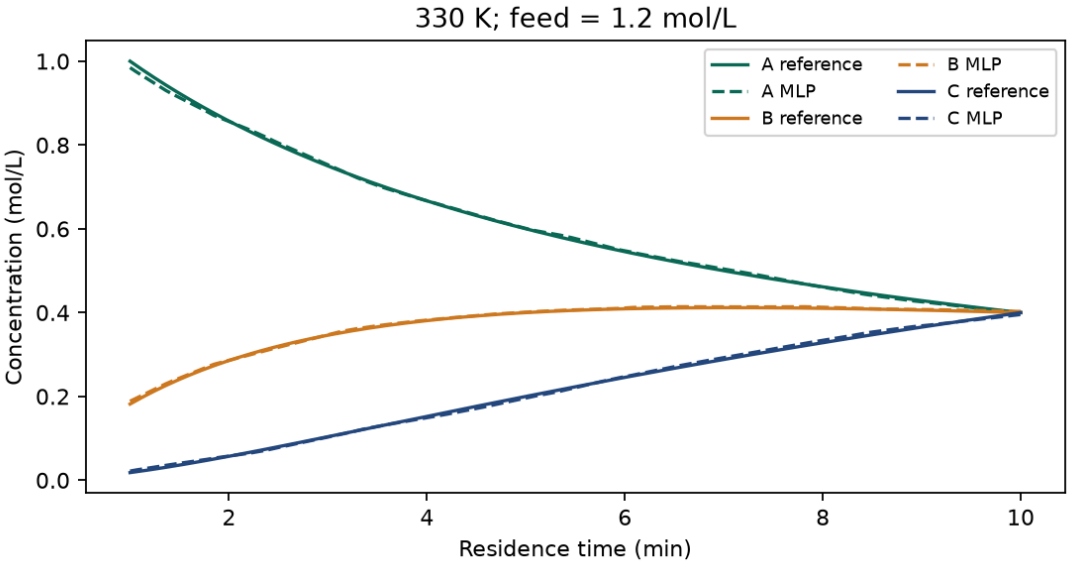
온도가 고정되면 C_B 식에서 B의 수율과 그 수율을 최대화하는 체류시간을 구할 수 있습니다.

$$Y_B = \frac{C_B}{C_{\mathrm{Af}}} = \frac{k_1\tau}{\left(1+k_1\tau\right)\left(1+k_2\tau\right)}, \quad \tau^* = \frac{1}{\sqrt{k_1 k_2}}$$

분모를 $D=1+(k_1+k_2)\tau+k_1k_2\tau^2$로 두면 미분의 분자는 $k_1(D-\tau D')=k_1(1-k_1k_2\tau^2)$입니다. 양의 분모 D^2는 부호를 바꾸지 않습니다. 따라서 $\tau=1/\sqrt{(k_1k_2)}$ 전에는 증가하고 이후에는 감소합니다.

세 성분의 농도 profile 비교

330 K에서 τ*는 약 7.07 min. 짧은 체류시간에서는 B 생성이 부족하고, 체류시간이 길어지면 더 많은 B가 C로 반응합니다.



330 K에서의 다성분 응답. B 농도는 중간 체류시간에서 최대가 된다.

3. 학습 데이터 구성

한 행의 입력은 [T, τ, C_Af], 출력은 [C_A, C_B, C_C]이며 두 배열의 크기는 모두 (N, 3). 표의 운전 영역에서 train 400개, validation 120개, test 160개를 생성하고 정상상태 식으로 기준값을 계산

Train 데이터에서 세 농도의 표준편차는 약 [0.283, 0.110, 0.217] mol/L로, 단위가 같아도 변화 폭은 다릅니다.

한 행의 A·B·C는 같은 입력에서 계산한 하나의 묶음입니다. 성분별로 행을 따로 섞으면 입력과 정답의 대응이 깨집니다. 분할과 순서 섞기는 입력 행과 출력 행에 함께 적용합니다.

4. Forward 계산과 scaling

MLP 구조: 3 → 32 → 32 → 3. ReLU 은닉층과 선형 출력층

은닉층 계산: 가중합 + bias → ReLU(a) = max(0, a). 양수는 통과, 음수는 0. 농도 데이터로 학습하는 파라미터: 가중치와 bias

$$h_1 = \mathrm{ReLU}\left(W_1 \tilde{\mathrm{x}} + b_1\right)$$
$$h_2 = \mathrm{ReLU}\left(W_2 h_1 + b_2\right)$$
$$\hat{z} = W_3 h_2 + b_3$$

층	Weight shape	Bias shape	Parameter 수
입력 → hidden 1	32 × 3	32	128
Hidden 1 → hidden 2	32 × 32	32	1056
Hidden 2 → 출력	3 × 32	3	99
합계			**1283**

한 뉴런은 입력 열 전체를 가중합해 숫자 하나를 만듭니다. 첫 층의 뉴런 32개가 각각 입력 3개의 가중치와 편향 하나를 가져 32×(3+1)=128개입니다. 은닉층은 이 계산을 여러 특징에 반복합니다.

Scaling과 학습 loss

입력은 명시한 하한·상한으로 크기를 조정합니다. 출력은 train 평균 μ와 표준편차 s로 표준화하고, 예측한 뒤 원래 단위로 복원

$$\tilde{x}_j = 2\frac{x_j - l_j}{u_j - l_j} - 1$$

$$z_j = \frac{y_j - \mu_j}{s_j}, \quad \hat{y}_j = \mu_j + s_j \hat{z}_j$$

손실함수는 표본과 표준화된 출력 성분 전체의 제곱 오차를 평균합니다.

$$L = \frac{1}{3N} \sum_{n=1}^{N} \sum_{j=1}^{3} \left(\hat{z}_{n,j} - z_{n,j} \right)^2$$

각 농도 오차를 해당 성분의 train 변화 폭에 상대적으로 평가하므로, 표준편차가 작은 B의 원래 단위 제곱 오차에는 더 큰 가중치가 붙습니다.

같은 0.01 mol/L 오차라도 A의 표준화 오차는 0.01/0.283≈0.0353, B는 0.01/0.110≈0.0909입니다. 제곱하면 B의 손실 기여가 약 6.62배입니다. 출력 scaling은 단위 변환과 함께 학습에서 강조하는 성분도 바꿉니다.

5. Backpropagation 한 번 계산하기

계산 예제: bias가 모두 0인 3 → 2 → 3 신경망. 손실함수: $L = \frac{1}{2}\|\hat{y} - y\|^2$. 학습률: 0.1

$$x = \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}, y = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}$$

$$W_1 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix}, W_2 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix}$$

은닉층의 활성화 전 값 a와 활성화 값 h, 예측값과 오차를 구합니다.

$$a = \begin{bmatrix} 1 \\ -1 \end{bmatrix}, h = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \hat{y} = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}, e = \begin{bmatrix} 1 \\ -1 \\ 1 \end{bmatrix}$$

첫 은닉 뉴런은 입력 첫 성분 1을 읽고, 두 번째는 셋째 성분 −1을 읽습니다. ReLU 뒤에는 [1,0]만 남습니다. 출력층은 이 두 숫자를 각각 [첫째,둘째,두 값의 합]으로 조합하므로 [1,0,1]이 됩니다.

Gradient와 파라미터 갱신

출력 오차를 출력층 가중치와 ReLU 미분을 거쳐 전달합니다.

$$\delta_2 = e, \nabla_{W_2} L = eh^T = \begin{bmatrix} 1 & 0 \\ -1 & 0 \\ 1 & 0 \end{bmatrix}$$

$$\delta_1 = \left({W_2}^T e \right) \odot \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 2 \\ 0 \end{bmatrix}$$

$$\nabla_{W_1} L = \delta_1 x^T = \begin{bmatrix} 2 & 0 & -2 \\ 0 & 0 & 0 \end{bmatrix}$$

Bias gradient는 각각 δ_1, δ_2입니다. 모든 가중치와 bias를 parameter ← parameter − 0.1 × gradient로 갱신하면 다음 순전파 출력은 [0.26, 0.14, 0.26]이고, loss는 1.5에서 0.4374로 줄어듭니다. Notebook의 autograd 결과와 손계산을 대조합니다.

첫 은닉값은 A와 C 출력에 각각 가중치 1로 연결되어 있어 두 오차 1+1=2를 받습니다. 두 번째 은닉값의 pre-activation은 음수라 ReLU 미분이 0입니다. 따라서 그 뉴런의 입력 가중치와 편향은 이번 단계에서 움직이지 않습니다.

가중치 갱신 뒤의 두 번째 순전파

학습률 0.1로 가중치와 편향을 모두 갱신합니다. 첫 은닉 가중치 [1,0,0]에서 0.1×[2,0,−2]를 빼면 [0.8,0,0.2], 편향은 −0.2가 됩니다.

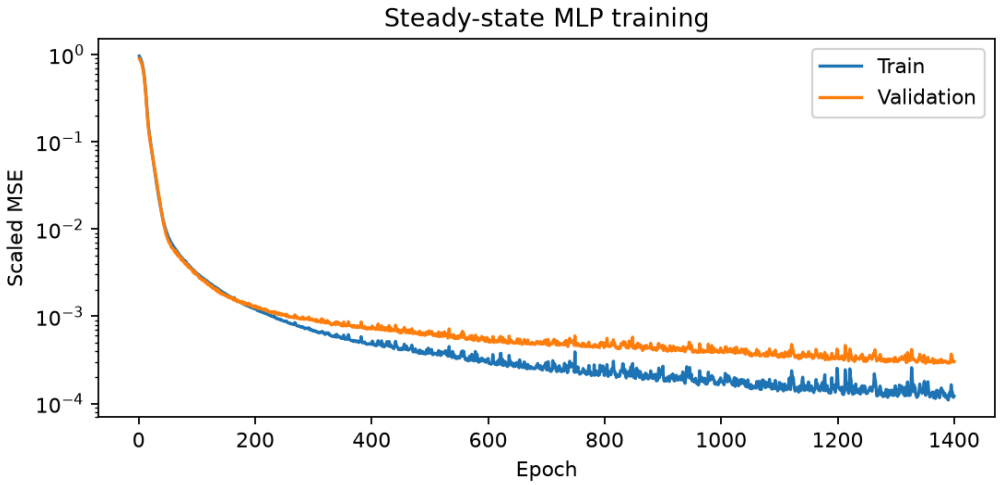
중간값	갱신 뒤 계산
첫 은닉 pre-activation	0.8×1+0×0+0.2×(−1)−0.2=0.4
두 번째 은닉 pre-activation	−1
ReLU 출력	[0.4,0]
출력 A, C	0.9×0.4−0.1=0.26
출력 B	0.1×0.4+0.1=0.14

새 오차는 [0.26,−0.86,0.26]입니다. 손실은 (0.0676+0.7396+0.0676)/2=0.4374로 줄지만 B는 여전히 목표 1보다 작습니다. 한 번의 감소가 학습 완료를 뜻하지는 않습니다.

6. 정상상태 모델 학습과 평가

학습 설정: Adam, 학습률 0.001, batch 64, 최대 1400 epoch. 가중치 선택: 매 epoch의 validation loss 중 최솟값

```
prediction = model(inputs)
loss = loss_function(prediction, targets)
optimizer.zero_grad()
loss.backward()
optimizer.step()
```



Train·validation loss. 아래 예측 지표는 mol/L 단위로 되돌린 뒤 계산한다.

학습 루프의 값과 변경 시점

```
prediction = model(inputs)
loss = loss_function(prediction, targets)
optimizer.zero_grad()
loss.backward()
optimizer.step()
```

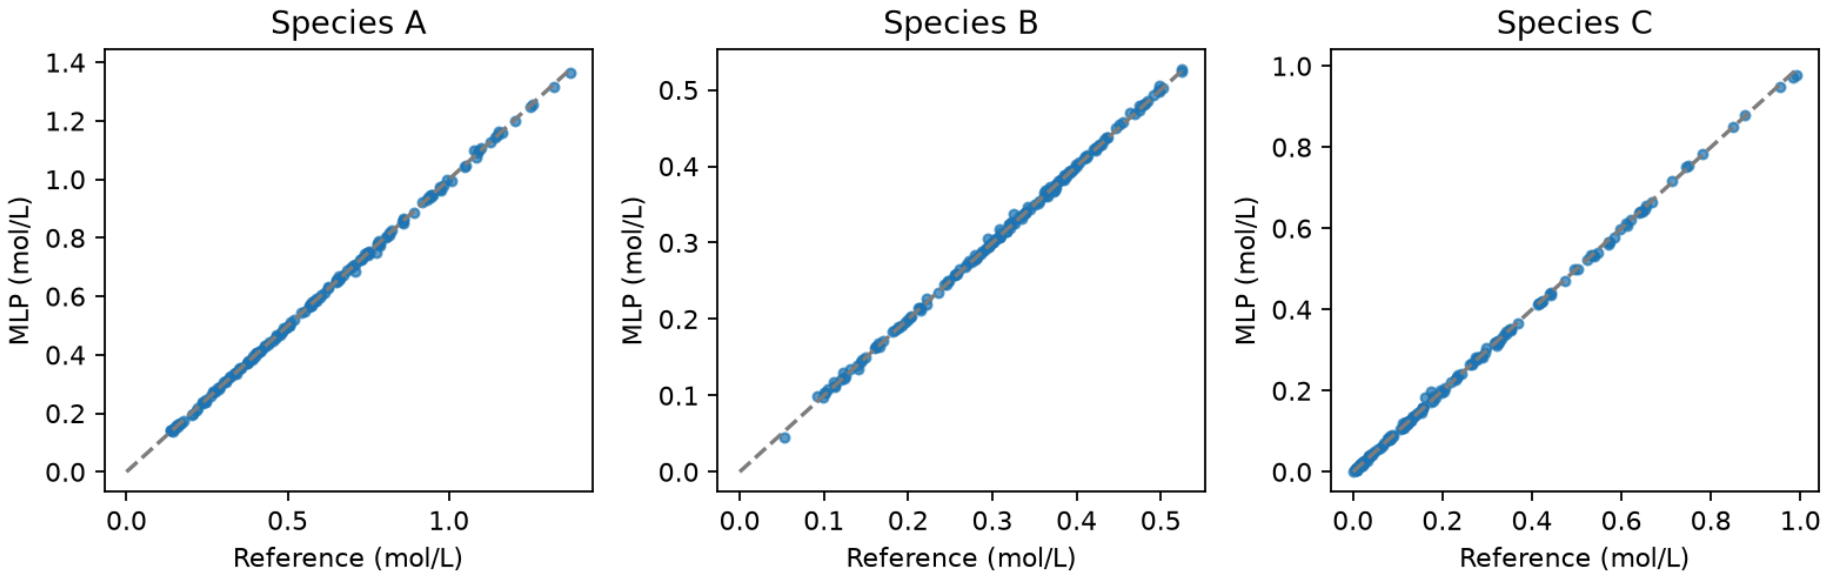
줄	만들어지거나 바뀌는 값
model(inputs)	현재 가중치로 batch의 출력 계산
loss_function	출력과 정답 차이를 스칼라 손실로 축약
zero_grad	이전 batch의 기울기 제거
backward	현재 손실의 가중치·편향별 기울기
step	기울기와 optimizer 상태로 파라미터 갱신

손 계산은 단순 gradient descent였고 실제 학습은 Adam입니다. Adam은 과거 기울기 정보도 사용하므로 같은 0.1배 빼기와 수치가 같지 않습니다. step 뒤의 성능을 보려면 갱신된 가중치로 순전파를 다시 수행합니다.

출력 성분별 평가

Test RMSE, mol/L	A	B	C
출력 scaling 적용	0.005275	0.002940	0.004423
출력 scaling 미적용	0.006634	0.003917	0.004162

이번 실행에서는 출력 scaling으로 A·B RMSE가 줄었고 C RMSE는 조금 커졌습니다. 각 성분의 변화를 따로 확인해야 전체 오차 하나에 가려진 차이를 볼 수 있습니다.



성분별 parity plot에서 각 출력의 오차를 확인한다.

표준화 출력에서 농도와 오차로

계산용 한 성분의 학습 평균 μ=0.4 mol/L, 표준편차 s=0.1 mol/L를 둡니다. 정답 농도 0.45는 z=(0.45−0.4)/0.1=0.5입니다.

항목	계산
신경망의 표준화 예측	$\hat{z}=0.3$
농도 복원	0.4+0.1×0.3=0.43 mol/L
표준화 오차	0.3−0.5=−0.2
농도 오차	0.43−0.45=−0.02 mol/L

```
prediction = y_mean + y_scale * standardized_prediction
component_rmse = np.sqrt(((prediction - truth)**2).mean(axis=0))
sum_residual = prediction.sum(axis=1) - feed
```

첫 줄은 각 출력 열에 해당 평균과 표준편차를 적용합니다. axis=0은 성분별 정확도, axis=1은 같은 조건의 세 성분 합을 계산합니다. 두 축을 바꾸면 다른 질문을 계산하게 됩니다.

농도 합 확인

$$r = \hat{C}_A + \hat{C}_B + \hat{C}_C - C_{\mathrm{Af}}$$

Test residual RMSE는 0.003781 mol/L. 성분별 오차로 예측 정확도를, 농도 합 residual로 해당 수지의 일관성을 평가

수지를 만족하는 기준값으로 학습해도 세 선형 출력의 합이 유입 농도와 같도록 강제되지는 않습니다.

유입 1.2 mol/L에서 예측이 [0.62, 0.41, 0.20] mol/L이면 합은 1.23 mol/L이고 r = 0.03 mol/L입니다.
몰분율을 예측할 때도 합이 1을 벗어날 수 있습니다.

성분 오차의 합이 합 잔차입니다. 오차 [0.02,−0.01,−0.01]은 합이 0이지만 성분은 틀립니다. 반대로 작은 양의 오차가 세 성분에 누적되면 총농도 오차가 커집니다.

4주차 예고: 농도 합 제약의 모델 반영

학습 후 출력을 보정하거나, 제약을 만족하는 변환을 학습 과정에 포함할 수 있습니다.

접근	보정이 들어가는 위치
학습 후 외부 mapping/projection	Raw predictor를 학습한 뒤 출력을 보정한다.
KKT-hPINN	입력과 raw 예측을 받는 고정 affine projection을 loss 전에 적용하며, 예측할 때도 적용한다.

$$x \rightarrow f_\theta \rightarrow \hat{y} \rightarrow \Pi_x \rightarrow \tilde{y} \rightarrow \text{loss}$$

KKT-hPINN은 투영한 출력으로 loss를 계산하고 투영층을 거쳐 역전파합니다. 투영 계수는 고정하지만 MLP 가중치는 이 변환을 반영해 학습합니다.

투영층은 지정한 선형 등식을 수치 연산 오차 범위에서 만족시키며, 비음수성에는 별도 제약이 필요합니다.

출처: Chen et al. (2024), DOI: 10.1016/j.compchemeng.2024.108764.

7. 필수 정상상태 실습 실행

정상상태 Notebook을 받습니다.

```
python -m pip install -r requirements.txt
python week02_lab.py --mode steady --output-dir week02-results
```

학습한 예측 모델의 성분별 RMSE와 농도 합 residual을 평가

8. 필수 연습문제와 제출물

1. C_A·C_B·C_C를 유도해 합을 확인하고, B 곡선이 단조롭지 않은 이유를 설명합니다.
2. 정상상태 MLP의 파라미터 1283개와 손으로 계산한 gradient 갱신을 확인
3. 출력 scaling 전후의 성분별 RMSE를 비교
4. 독립 입력에서 농도 합 residual과 최소 예측 농도를 살펴봅니다.

제출물: 정상상태 모델, 데이터 분할·scaling 정보, 확인한 gradient 갱신, 성분별 오차·일관성 평가

구현 설명은 PyTorch의 모델 구성, autograd, 학습을 참고합니다.

읽기자료

2주차 읽기자료 · 국문 PDF

KKT-hPINN 참고문헌: Chen, H., Constante Flores, G. E., & Li, C. (2024). Physics-informed neural networks with hard linear equality constraints. *Computers & Chemical Engineering*, 189, 108764.