


2주차: MLP로 다성분 정상상태 응답 학습하기

A가 줄어들면 B는 얼마나 만들어질까?

$A \rightarrow B \rightarrow C$ 에서 원하는 중간 생성물은 B다. 체류시간이 짧으면 B가 충분히 만들어지지 않고, 길면 더 많은 B가 C로 반응한다.

엔지니어는 각 조건에서 세 출구 농도를 알아야 한다. 전환율 하나로는 제품 조성을 설명할 수 없다.

한 모델이 A·B·C를 일관되게 예측할 수 있을까?



출력은 세 개, 오차의 크기도 다르다

세 농도의 단위는 같아도 변화 폭은 다르다. Scaling 없는 loss는 한 성분을 더 강조할 수 있다.

이번 주는 MLP가 출력을 계산하는 방법, 한 번의 gradient 갱신으로 파라미터가 바뀌는 과정, 성분별 평가를 배운다.

정상상태 MLP를 학습하고 확인하기

1. A·B·C의 정상상태 label을 유도한다.
2. 데이터를 scaling하고 forward·backpropagation·파라미터 갱신 한 번을 따라간다.
3. MLP를 학습하고 성분별 RMSE와 농도 합 residual을 비교한다.

1. CSTR의 연속반응 $A \rightarrow B \rightarrow C$

완전혼합·일정 부피·일정 밀도·등온 CSTR에서 1차 연속반응 $A \rightarrow B \rightarrow C$ 를 다룬다. 유입물은 A를 포함하며 B·C의 유입 농도는 0이다. 온도는 운전 입력이다. 농도 단위는 mol/L, 온도는 K, 시간은 min이며 물질수지는 다음과 같다.

$$\begin{aligned}\frac{dC_A}{dt} &= \frac{C_{Af} - C_A}{\tau} - k_1 C_A \\ \frac{dC_B}{dt} &= -\frac{C_B}{\tau} + k_1 C_A - k_2 C_B \\ \frac{dC_C}{dt} &= -\frac{C_C}{\tau} + k_2 C_B\end{aligned}$$

속도상수와 운전 영역

두 속도상수의 단위는 1/min이다. 온도 의존성은 다음 식을 사용한다.

$$k_1(T) = 0.2 \exp \left[6000 \left(\frac{1}{330} - \frac{1}{T} \right) \right]$$
$$k_2(T) = 0.1 \exp \left[5000 \left(\frac{1}{330} - \frac{1}{T} \right) \right]$$

항목	값·범위
기준 온도	330 K
기준 k_1 ; k_2	0.2; 0.1 /min
온도 민감도 파라미터	6000 K; 5000 K
온도 T	300–360 K
체류시간 τ	1–10 min
유입 A 농도	0.8–1.5 mol/L

세 수지는 A의 소모, B의 생성·소모, C의 생성을 나타낸다. 세 식을 더하면 반응 항이 상쇄된다.

2. 세 출력을 갖는 정상상태 mapping 유도

시간 미분을 0으로 놓고 각 식에 τ 를 곱한다. 농도 항을 모으면 다음 관계를 얻는다.

$$\begin{aligned}(1 + k_1\tau)C_A &= C_{Af} \\ (1 + k_2\tau)C_B &= k_1\tau C_A \\ C_C &= k_2\tau C_B\end{aligned}$$

A·B·C 농도 계산

A, B, C 순서로 풀면 다음과 같다.

$$\begin{aligned}C_A &= \frac{C_{Af}}{1 + k_1\tau} \\C_B &= \frac{k_1\tau C_{Af}}{(1 + k_1\tau)(1 + k_2\tau)} \\C_C &= k_2\tau C_B\end{aligned}$$

330 K, $\tau = 5$ min, 유입 농도 1.2 mol/L에서는 **[0.6, 0.4, 0.2] mol/L**이다. 세 농도의 합은 유입 농도와 같다. 이 세 출력을 정상상태 MLP의 label로 사용한다.


B 응답이 단조롭지 않은 이유

고정 온도에서 B의 수율과 이를 최대화하는 체류시간은 C_B 식에서 얻는다.

$$Y_B = \frac{C_B}{C_{Af}} = \frac{k_1 \tau}{(1 + k_1 \tau)(1 + k_2 \tau)}, \quad \tau^* = \frac{1}{\sqrt{k_1 k_2}}$$

세 성분의 농도 profile 비교

330 K에서 τ^* 는 약 7.07 min이다.
체류시간이 짧으면 B가 충분히
생성되지 않고, 길면 더 많은 B가 C로
반응한다.



330 K에서의 다성분 응답. B 농도는 중간 체류시간에서 최대가 된다.

3. 학습 데이터 구성

한 행의 입력은 $[T, \tau, C_{Af}]$, 출력은 $[C_A, C_B, C_C]$ 다. 입력·출력 배열의 shape은 모두 $(N, 3)$ 이다. 표의 운전 영역에서 train 400개, validation 120개, test 160개를 생성하고 정상상태 식으로 label을 계산한다.

세 농도는 단위가 같지만 변화 폭이 다르다. Train 데이터의 표준편차는 약 $[0.283, 0.110, 0.217]$ mol/L이다.

4. Forward 계산과 scaling

$3 \rightarrow 32 \rightarrow 32 \rightarrow 3$ MLP를 사용한다. Hidden layer에는 ReLU, 출력층에는 linear 연산을 둔다.

각 hidden layer는 입력의 가중합에 bias를 더한다. $\text{ReLU}(a) = \max(0, a)$ 는 양수 값을 그대로 두고 음수 값을 0으로 만든다. 농도 데이터에 맞춰 학습하는 parameter는 weight와 bias다.

$$h_1 = \text{ReLU}(W_1 \tilde{x} + b_1)$$

$$h_2 = \text{ReLU}(W_2 h_1 + b_2)$$

$$\hat{z} = W_3 h_2 + b_3$$

층	Weight shape	Bias shape	Parameter 수
입력 $\rightarrow$ hidden 1	32×3	32	128
Hidden 1 $\rightarrow$ hidden 2	32×32	32	1056
Hidden 2 $\rightarrow$ 출력	3×32	3	99
합계			1283

Scaling과 학습 loss

입력은 명시한 하한·상한으로 scaling한다. 각 출력은 train 평균 μ 와 표준편차 s 로 표준화하고, 예측 뒤 원래 단위로 되돌린다.

$$\tilde{x}_j = 2 \frac{x_j - l_j}{u_j - l_j} - 1$$
$$z_j = \frac{y_j - \mu_j}{s_j}, \quad \hat{y}_j = \mu_j + s_j \hat{z}_j$$

Loss는 표본과 표준화된 출력 성분에 걸쳐 제곱 오차를 평균한다.

$$L = \frac{1}{3N} \sum_{n=1}^N \sum_{j=1}^3 \left(\hat{z}_{n,j} - z_{n,j} \right)^2$$

농도 오차를 해당 성분의 train 변화 폭에 상대적으로 평가하는 셈이다. 표준편차가 작은 B의 원래 단위 제곱 오차에는 더 큰 가중치가 붙는다.

5. Backpropagation 한 번 계산하기

Bias가 모두 0인 $3 \rightarrow 2 \rightarrow 3$ 신경망에서 다음 값을 사용한다. 이번 계산의 loss는 $L = \frac{1}{2}\|\hat{y} - y\|^2$, learning rate는 0.1이다.

$$x = \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}, y = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}$$
$$W_1 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix}, W_2 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix}$$

Hidden pre-activation a , activation h , 예측값, 오차는 다음과 같다.

$$a = \begin{bmatrix} 1 \\ -1 \end{bmatrix}, h = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \hat{y} = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}, e = \begin{bmatrix} 1 \\ -1 \\ 1 \end{bmatrix}$$

Gradient와 파라미터 갱신

출력 오차를 출력층 가중치와 ReLU 미분을 거쳐 전달한다.


$$\delta_2 = e, \nabla_{W_2} L = e h^T = \begin{bmatrix} 1 & 0 \\ -1 & 0 \\ 1 & 0 \end{bmatrix}$$
$$\delta_1 = \left(W_2^T e \right) \odot \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 2 \\ 0 \end{bmatrix}$$
$$\nabla_{W_1} L = \delta_1 x^T = \begin{bmatrix} 2 & 0 & -2 \\ 0 & 0 & 0 \end{bmatrix}$$

Bias gradient는 각각 δ_1, δ_2 다. 모든 weight·bias를 $\text{parameter} \leftarrow \text{parameter} - 0.1 \times \text{gradient}$ 로 갱신한다. 다음 forward의 출력은 **[0.26, 0.14, 0.26]**, loss는 **1.5**에서 **0.4374**로 감소한다. Notebook에서 autograd로 이 gradient를 확인한다.

6. 정상상태 모델 학습과 평가

Adam, learning rate 0.001, batch 64, 최대 1400 epoch를 사용한다. 매 epoch 뒤 validation loss를 계산하고 최소값의 가중치를 저장한다. 한 batch의 학습은 다음 연산으로 구성된다.

```
prediction = model(inputs)
loss = loss_function(prediction, targets)
optimizer.zero_grad()
loss.backward()
optimizer.step()
```




Train·validation loss. 아래 예측 지표는 mol/L 단위로 되돌린 뒤 계산한다.

출력 성분별 평가

Test RMSE, mol/L	A	B	C
출력 scaling 적용	0.005275	0.002940	0.004423
출력 scaling 미적용	0.006634	0.003917	0.004162

이 비교에서는 출력 scaling으로 A·B RMSE가 감소하고, C RMSE는 조금 증가했다. 세 오차를 하나로 합치기보다 성분별로 확인한다.



성분별 parity plot에서 각 출력의 오차를 확인한다.

농도 합 확인

농도 합 residual도 계산한다.

$$r = \hat{C}_A + \hat{C}_B + \hat{C}_C - C_{Af}$$

Test residual RMSE는 **0.003781 mol/L**이다. 성분별 예측 오차와 농도 합 residual은 모델의 서로 다른 성질을 보여준다.

세 linear output은 자유롭게 예측된다. 수지를 만족하는 label로 학습해도 예측 농도 합이 유입 농도와 같도록 강제되지는 않는다.

유입 **1.2 mol/L**에서 예측이 **[0.62, 0.41, 0.20] mol/L**이면 합은 **1.23 mol/L**, **r = 0.03 mol/L**이다. 물분율을 예측하는 모델에서도 합이 1과 다른 값이 나올 수 있다.

예측 오차가 작다는 것과 반드시 지켜야 할 등식을 만족한다는 것은 다르다.

4주차 예고: 제약을 모델 안에 넣으면?

학습 후 예측을 보정할 수도 있고, 제약을 지키는 변환을 학습 계산 안에 넣을 수도 있다.

접근	보정이 들어가는 위치
학습 후 외부 mapping/projection	Raw predictor를 학습한 뒤 출력을 보정한다.
KKT-hPINN	입력과 raw 예측을 받는 고정 affine projection을 loss 전에 적용하며, 예측할 때도 적용한다.

$$x \rightarrow f_{\theta} \rightarrow \hat{y} \rightarrow \Pi_x \rightarrow \tilde{y} \rightarrow \text{loss}$$

KKT-hPINN은 projection을 거친 출력으로 loss를 계산하고, projection을 통해 역전파한다. Layer의 계수는 고정되어 있고, MLP의 weight는 이 변환을 반영하여 학습한다.

4주차에서 projection·KKT 조건을 유도하고 rank 가정과 gradient를 확인한다. 보장 범위는 명시한 선형 등식의 만족(수치 연산 오차 범위)이며, 비음수성은 별도 제약이 필요하다.

출처: Chen et al. (2024), [DOI: 10.1016/j.compchemeng.2024.108764](https://doi.org/10.1016/j.compchemeng.2024.108764).

7. 필수 정상상태 실습 실행

[정상상태 Notebook](#)을 받는다.

```
python -m pip install -r requirements.txt  
python week02_lab.py --mode steady --output-dir week02-results
```

학습한 predictor의 성분별 RMSE와 농도 합 residual을 평가한다.

8. 필수 연습문제와 제출물

1. $C_A \cdot C_B \cdot C_C$ 를 유도하고 합을 확인한다. B 곡선이 단조롭지 않은 이유를 설명한다.
2. 정상상태 MLP의 **1283개** 파라미터와 손 계산한 gradient 갱신을 확인한다.
3. 출력 scaling 적용 전후의 성분별 RMSE를 비교한다.
4. 독립 입력에서 농도 합 residual과 최소 예측 농도를 살펴본다.

정상상태 모델, 분할·scaling 정보, 확인한 gradient 갱신, 성분별 오차·일관성 평가를 제출한다.

원문 해설: PyTorch [모델 구성](#), [autograd](#), [학습](#).

읽기자료

[2주차 읽기자료](#)와 [국문 PDF](#)에서 세 출력 mapping, 파라미터 수, scaling, gradient 갱신, 학습 loop와 독립 진단을 읽는다.

KKT-hPINN 참고문헌: Chen, H., Constante Flores, G. E., & Li, C. (2024). [Physics-informed neural networks with hard linear equality constraints](#). *Computers & Chemical Engineering*, **189**, 108764.