# 2주차 읽기자료: 정상상태 MLP 학습과 평가

## 1. 하나의 반응기, 세 정상상태 출력

1차 연속반응 A → B → C의 시간 미분을 각각 0으로 놓고 A, B, C 순서로 정상 농도를 구합니다.

$$C_A = \frac{C_{\mathrm{Af}}}{1 + k_1\tau}$$

$$C_B = \frac{k_1\tau C_{\mathrm{Af}}}{(1 + k_1\tau)(1 + k_2\tau)}$$

$$C_C = k_2\tau C_B$$

330 K에서 첫 번째와 두 번째 반응의 속도상수는 0.2/min, 0.1/min입니다. 체류시간 5 min·유입 농도 1.2 mol/L에서 농도는 [0.6, 0.4, 0.2] mol/L이고 합은 1.2입니다. 이 세 값이 정상상태 학습 데이터 한 행의 기준 출력입니다.

입력 [T, τ, C_Af]와 출력 [C_A, C_B, C_C]의 한 쌍은 하나의 정상상태 운전 조건에 대응합니다.

# 2. 학습 전에 파라미터 수 계산하기

완전연결층(dense layer)은 입력·출력 쌍마다 가중치 하나, 출력마다 bias 하나를 둡니다. 정상상태 MLP의 구조는 3 → 32 → 32 → 3입니다.

| Layer | 개수 |
|---|---|
| 첫 hidden layer | 3 × 32 + 32 = 128 |
| 두 번째 hidden layer | 32 × 32 + 32 = 1056 |
| Output layer | 32 × 3 + 3 = 99 |
| 합계 | **1283** |

$$h_1 = \mathrm{ReLU}\left(W_1 \tilde{\mathrm{x}} + b_1\right)$$
$$h_2 = \mathrm{ReLU}\left(W_2 h_1 + b_2\right)$$
$$\hat{z} = W_3 h_2 + b_3$$

ReLU는 은닉층의 활성화 전 값마다 max(0, 값)을 적용합니다. 선형 출력층은 음수 농도도 반환할 수 있으므로 비음수성과 농도 합의 일관성을 따로 평가해야 합니다.

# 3. Scaling은 loss의 강조점을 바꾼다

입력 scaling에는 명시한 bounds를 사용합니다. 출력 표준화의 평균과 표준편차는 train 데이터에서만 계산하며, 농도 오차를 보고할 때는 물리 단위로 복원합니다.

$$\tilde{x}_j = 2\frac{x_j - l_j}{u_j - l_j} - 1$$

$$z_j = \frac{y_j - \mu_j}{s_j}, \quad \hat{y}_j = \mu_j + s_j \hat{z}_j$$

$$L = \frac{1}{3N} \sum_{n=1}^{N} \sum_{j=1}^{3} \left( \hat{z}_{n,j} - z_{n,j} \right)^2$$

원래 단위의 제곱 오차에는 train 표준편차 제곱의 역수가 가중치로 붙습니다. A의 표준편차가 약 0.283, B가 0.110이면 같은 제곱 오차에 B는 A보다 약 6.62배의 가중치를 받습니다.

이 가중치가 더 좋은 예측을 보장하지는 않으므로 성분별 test RMSE와 농도 합 residual을 비교합니다. 평균 방식은 PyTorch 공식 MSE 정의에서 확인합니다.

# 4. Backward 한 번, 파라미터 갱신 한 번

3 → 2 → 3 신경망의 초기값은 `W1 = [[1, 0, 0], [0, 0, 1]]`, `W2 = [[1, 0], [0, 1], [1, 1]]`이며 bias는 모두 0입니다. 입력 [1, 0, −1]의 은닉층 활성화 전 값은 [1, −1], ReLU 출력은 [1, 0], 예측은 [1, 0, 1]입니다. 기준값 [0, 1, 0]에 대한 오차는 [1, −1, 1]입니다.

$$\delta_2 = e, \nabla_{W_2} L = eh^T = \begin{bmatrix} 1 & 0 \\ -1 & 0 \\ 1 & 0 \end{bmatrix}$$

$$\delta_1 = \left( {W_2}^T e \right) \odot \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 2 \\ 0 \end{bmatrix}$$

$$\nabla_{W_1} L = \delta_1 x^T = \begin{bmatrix} 2 & 0 & -2 \\ 0 & 0 & 0 \end{bmatrix}$$

출력 가중치의 gradient는 오차와 은닉층 활성화 전치의 곱입니다. 은닉층 오차는 출력 가중치와 ReLU 미분을 거쳐 전달되며, 활성화 전 값이 음수인 성분에서는 gradient가 0이 됩니다.

Bias gradient는 해당 오차 벡터입니다. 학습률 0.1로 가중치와 bias를 모두 갱신하면 다음 예측은 [0.26, 0.14, 0.26]이고, loss ½‖예측 − target‖²는 1.5에서 0.4374로 줄어듭니다.

PyTorch autograd는 이 chain rule을 자동으로 계산합니다. Notebook에서 손계산과 대조합니다.

# 5. 학습 loop를 계산 순서로 읽기

한 batch에서 예측과 loss를 계산한 뒤, 이전에 누적된 파라미터 gradient를 지웁니다. 이어 현재 loss를 미분하고 optimizer로 파라미터를 갱신합니다.

```
prediction = model(inputs)
loss = loss_function(prediction, targets)
optimizer.zero_grad()
loss.backward()
optimizer.step()
```

`loss.backward()`는 gradient를 계산하고 `optimizer.step()`은 파라미터를 바꿉니다. Gradient를 지우지 않으면 다음 backward 결과가 기존 값에 누적됩니다.

Epoch 뒤 validation loss를 평가해 가장 작은 값의 가중치를 보관합니다. Test는 학습과 모델 선택에 사용하지 않으며, 예측 지표는 출력 표준화를 되돌린 후 계산합니다.

구현 설명은 PyTorch의 학습 loop, 모델 구성을 참고합니다.

# 6. 독립 예측을 진단하기

기준값이 [0.6, 0.4, 0.2] mol/L이고 예측 모델이 [0.62, 0.39, 0.19] mol/L를 반환한다고 가정합니다.

성분별 오차는 [0.02, −0.01, −0.01] mol/L입니다. 두 농도 합은 모두 1.2이므로 합 residual은 0이지만 각 성분의 오차는 남아 있습니다.

Test 보고서에는 어떤 지표를 넣어야 할까요? 모델 선택에는 어떤 데이터를 사용해야 할까요?

답 확인: 물리 단위의 A·B·C RMSE, 농도 합 residual과 최소 예측 농도를 보고합니다. Train으로 학습하고 validation으로 선택하며 test는 두 단계에 사용하지 않습니다.

2주차 필수 실습에서 같은 지표를 확인합니다.