2주차 읽기자료: 정상상태 MLP 학습과 평가

1. CSTR의 세 성분 정상상태 출력

1차 연속반응 A → B → C의 시간 미분을 각각 0으로 놓고 A, B, C 순서로 정상 농도를 구합니다.

$$C_A = \frac{C_{\mathrm{Af}}}{1 + k_1\tau}$$
$$C_B = \frac{k_1\tau C_{\mathrm{Af}}}{(1 + k_1\tau)\,(1 + k_2\tau)}$$
$$C_C = k_2\tau C_B$$

330 K에서 첫 번째와 두 번째 반응의 속도상수는 0.2/min, 0.1/min입니다. 체류시간 5 min·유입 농도 1.2 mol/L에서 농도는 [0.6, 0.4, 0.2] mol/L이고 합은 1.2입니다. 이 세 값이 정상상태 학습 데이터 한 행의 기준 출력입니다.

입력 [T, τ, C_Af]와 출력 [C_A, C_B, C_C]의 한 쌍은 하나의 정상상태 운전 조건에 대응합니다.

2. 학습 전에 파라미터 수 계산하기

완전연결층(dense layer)은 입력·출력 쌍마다 가중치 하나, 출력마다 bias 하나를 둡니다. 정상상태 MLP의 구조는 3 → 32 → 32 → 3입니다.

Layer	개수
첫 hidden layer	3 × 32 + 32 = 128
두 번째 hidden layer	32 × 32 + 32 = 1056
Output layer	32 × 3 + 3 = 99
합계	**1283**

$$h_1 = \mathrm{ReLU}\left(W_1 \tilde{\mathrm{x}} + b_1 \right)$$
$$h_2 = \mathrm{ReLU}\left(W_2 h_1 + b_2 \right)$$
$$\hat{z} = W_3 h_2 + b_3$$

ReLU는 은닉층의 활성화 전 값마다 max(0, 값)을 적용합니다. 선형 출력층은 음수 농도도 반환할 수 있으므로 비음수성과 농도 합의 일관성을 따로 평가해야 합니다.

3. 출력 scaling과 성분별 loss 가중치

입력 scaling에는 명시한 bounds를 사용합니다. 출력 표준화의 평균과 표준편차는 train 데이터에서만 계산하며, 농도 오차를 보고할 때는 물리 단위로 복원합니다.

$$\tilde{\mathrm{x}}_j = 2\frac{x_j - l_j}{u_j - l_j} - 1$$

$$z_j = \frac{y_j - \mu_j}{s_j}, \quad \hat{y}_j = \mu_j + s_j \hat{z}_j$$

$$L = \frac{1}{3N} \sum_{n=1}^{N} \sum_{j=1}^{3} \left(\hat{z}_{n,j} - z_{n,j} \right)^2$$

원래 단위의 제곱 오차에는 train 표준편차 제곱의 역수가 가중치로 붙습니다. A의 표준편차가 약 0.283, B가 0.110이면 같은 제곱 오차에 B는 A보다 약 6.62배의 가중치를 받습니다.

성분별 test RMSE와 농도 합 residual로 출력 scaling 전후를 비교합니다. 평균 방식은 PyTorch 공식 MSE 정의에서 확인합니다.

4. 역전파와 파라미터 갱신 예제

3 → 2 → 3 신경망의 초기값은 `W1 = [[1, 0, 0], [0, 0, 1]]`, `W2 = [[1, 0], [0, 1], [1, 1]]`이며 bias는 모두 0입니다. 입력 [1, 0, −1]의 은닉층 활성화 전 값은 [1, −1], ReLU 출력은 [1, 0], 예측은 [1, 0, 1]입니다. 기준값 [0, 1, 0]에 대한 오차는 [1, −1, 1]입니다.

$$\delta_2 = e, \nabla_{W_2} L = eh^T = \begin{bmatrix} 1 & 0 \\ -1 & 0 \\ 1 & 0 \end{bmatrix}$$

$$\delta_1 = \left({W_2}^T e \right) \odot \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 2 \\ 0 \end{bmatrix}$$

$$\nabla_{W_1} L = \delta_1 x^T = \begin{bmatrix} 2 & 0 & -2 \\ 0 & 0 & 0 \end{bmatrix}$$

출력 가중치의 gradient는 오차와 은닉층 활성화 전치의 곱입니다. 은닉층 오차는 출력 가중치와 ReLU 미분을 거쳐 전달되며, 활성화 전 값이 음수인 성분에서는 gradient가 0이 됩니다.

Bias gradient는 해당 오차 벡터입니다. 학습률 0.1로 가중치와 bias를 모두 갱신하면 다음 예측은 [0.26, 0.14, 0.26]이고, loss ½‖예측 − target‖²는 1.5에서 0.4374로 줄어듭니다.

PyTorch autograd는 이 chain rule을 자동으로 계산합니다. Notebook에서 손계산과 대조합니다.

5. 학습 loop를 계산 순서로 읽기

한 batch에서 예측과 loss를 계산한 뒤, 이전에 누적된 파라미터 gradient를 지웁니다. 이어 현재 loss를 미분하고 optimizer로 파라미터를 갱신합니다.

```
prediction = model(inputs)
loss = loss_function(prediction, targets)
optimizer.zero_grad()
loss.backward()
optimizer.step()
```

`loss.backward()`는 gradient를 계산하고 `optimizer.step()`은 파라미터를 바꿉니다. Gradient를 지우지 않으면 다음 backward 결과가 기존 값에 누적됩니다.

Epoch 뒤 validation loss를 평가해 가장 작은 값의 가중치를 보관합니다. Test는 학습과 모델 선택에 사용하지 않으며, 예측 지표는 출력 표준화를 되돌린 후 계산합니다.

구현 설명은 PyTorch의 학습 loop, 모델 구성을 참고합니다.

6. 독립 예측을 진단하기

기준값이 [0.6, 0.4, 0.2] mol/L이고 예측 모델이 [0.62, 0.39, 0.19] mol/L를 반환한다고 가정합니다.

성분별 오차는 [0.02, −0.01, −0.01] mol/L입니다. 두 농도 합은 모두 1.2이므로 합 residual은 0이지만 각 성분의 오차는 남아 있습니다.

Test 보고서에는 어떤 지표를 넣어야 할까요? 모델 선택에는 어떤 데이터를 사용해야 할까요?

답 확인: 물리 단위의 A·B·C RMSE, 농도 합 residual과 최소 예측 농도를 보고합니다. Train으로 학습하고 validation으로 선택하며 test는 두 단계에 사용하지 않습니다.

2주차 필수 실습에서 같은 지표를 확인합니다.