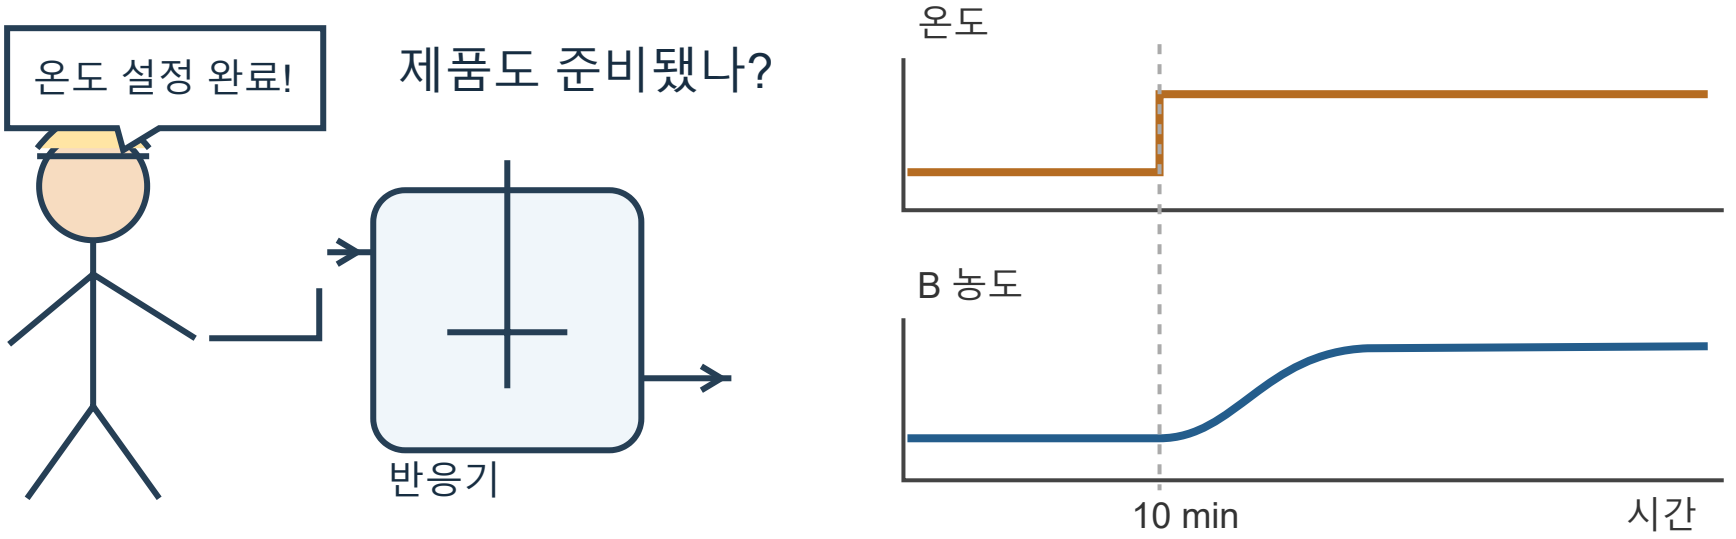
3주차: 동적 응답 예측과 rollout

온도 변경에 따른 제품 농도의 과도응답

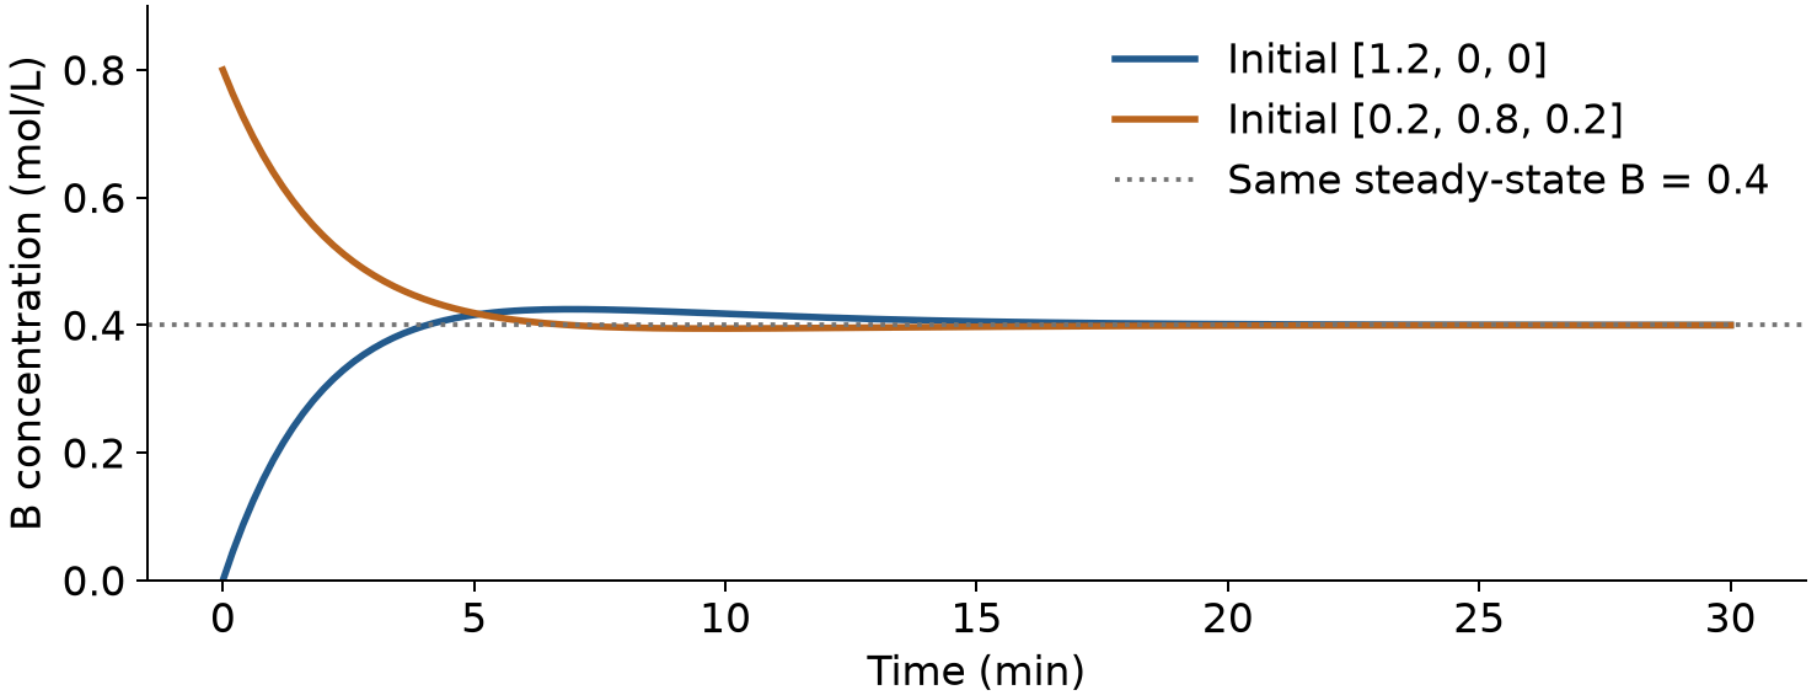
공정 엔지니어가 10분에 반응기 온도를 바꿉니다. 출구 유체가 곧바로 제품 탱크에 들어간다면 앞으로 20분 동안 B 농도는 어떻게 변할까요?



새 정상상태까지의 과도응답

제품 전환이나 기동 중 목표 조성에 도달하기 전에 나온 유체는 따로 모으거나 다시 처리해야 할 수 있습니다. 최종 농도만으로는 이 과도 구간을 설명할 수 없습니다.

온도가 같아도 탱크 안의 현재 조성이 다르면 다음 응답이 달라질 수 있습니다. 짧은 상태전이를 학습하고 반복 적용해 전체 궤적을 예측해봅니다.



T = 330 K, τ = 5 min, C_Af = 1.2 mol/L. 초기 상태만 다르다.

상태전이 모델의 학습과 rollout 평가

1. 현재 상태, 주어진 미래 입력, 고정 조건(context)과 표본 간격을 정의합니다.
2. 농도 변화량을 학습하는 상태전이 MLP를 만듭니다.
3. 독립 test 궤적에서 one-step 예측과 30분 rollout을 비교합니다.

같은 모델의 두 평가에서 성분별 오차, 예측 거리(horizon)에 따른 오차와 두 온도 계획의 궤적을 제출합니다. RNN/LSTM과 encoder-decoder는 선택 확장입니다.

정상상태 mapping과 상태전이 mapping

2주차: [T, τ, C_Af] → 정상상태에 도달한 뒤의 조성.

3주차: 현재 조성 + 해당 구간 입력 + context → 한 구간 뒤의 조성.

$$c_{k+1} = F_{\Delta t}\left(c_k, u_k; q\right)$$

이 관계식을 반복 적용하면 궤적을 얻습니다. 전이에 필요한 상태를 입력에 포함하면 feedforward MLP로도 동적 상태전이를 학습할 수 있습니다.

상태·미래 입력·고정 context

기호	의미	단위·역할
$c_k = [C_{A,k}, C_{B,k}, C_{C,k}]$	현재 반응기 조성	mol/L; 상태
$u_k = T_k$	k번째 구간의 온도	K; 주어진 입력
$q = [\tau, C_{Af}]$	체류시간·유입 농도	min, mol/L; 궤적별 고정
$\Delta t = 0.2$	Sampling interval	min; 이 모델에서 고정

Rollout 전에 c_0와 전체 온도 입력열을 정합니다. 실습에서는 온도 계획이 주어집니다.

기준 CSTR

완전 혼합·일정 부피·동일한 유입 및 유출 유량을 가정하는 이상적 반응기입니다. 1:1 화학양론의 1차 연속반응 A → B → C를 사용하며 유입에는 A만 포함됩니다. 온도는 주어지고 에너지수지는 포함하지 않습니다.

$$\frac{dC_A}{dt} = \frac{C_{Af} - C_A}{\tau} - k_1 C_A$$

$$\frac{dC_B}{dt} = k_1 C_A - \frac{C_B}{\tau} - k_2 C_B$$

$$\frac{dC_C}{dt} = k_2 C_B - \frac{C_C}{\tau}$$

$k_1(T) = 0.2 \exp[6000(1/330 - 1/T)]$, $k_2(T) = 0.1 \exp[5000(1/330 - 1/T)]$이며 단위는 min^{-1}입니다. 330 K에서 $k_1 = 0.2$, $k_2 = 0.1$ min^{-1}입니다.

연속 공정을 일정 간격으로 관찰하기

각 구간 [t_k, t_k + Δt)에서 T_k를 일정하게 유지하고 수지를 적분해 c_k+1을 구합니다. 입력이 바뀌는 순간에도 상태는 연속입니다.

30 min / 0.2 min = 상태전이 150개이며, 초기값을 포함한 관찰 상태는 151개입니다. 10분 온도 변경은 index 50 구간에서 시작합니다.

학습한 관계식은 0.2분 전이를 예측합니다. 반복 횟수를 늘리면 예측 거리가 길어지고 표본 간격은 그대로 유지됩니다.

기준 모델의 구간 응답

구간 입력이 일정하면 수지는 상태에 대해 affine합니다. dc/dt = Mc + b로 나타낼 때 정상상태 c∗는 Mc∗ + b = 0을 만족합니다.

$$F_{\Delta t}\left(c, u; q\right) = c^{*} + e^{M\Delta t}\left(c - c^{*}\right)$$

실습은 이 식의 해석해로 정한 Δt의 기준값을 생성합니다. M과 성분별 식의 유도는 읽기자료에서 확인합니다.

c_0 = [1.2, 0, 0], T = 330 K, τ = 5 min, feed = 1.2 mol/L이면 $c_1 \approx$ [1.153870, 0.045672, 0.000458] mol/L입니다.

궤적 생성과 상태전이 데이터 구성

300-360 K, τ = 1-10 min, feed = 0.8-1.5 mol/L를 사용합니다. 무작위 온도 계획은 5분 구간 6개로 구성하며, 각 궤적의 초기 조성은 비음수이고 합은 유입 농도입니다.

분할	궤적 수	상태전이 행 수
Train	60	9000
Validation	15	2250
Test	20	3000

학습 데이터의 상태·입력·목표값

항목	구성
입력 v_k	[C_A,k, C_B,k, C_C,k, T_k, τ, C_Af]
다음 상태 label	기준 구간 응답으로 계산한 c_k+1
변화량 target	Δc_k = c_k+1 − c_k
식별 정보	split, 궤적 ID, t_k

$$\Delta c_k = c_{k+1} - c_k$$

$$\hat{c}_{k+1} = c_k + \mu_\Delta + s_\Delta \odot g_\theta\left(\tilde{v}_k\right)$$

학습 대상은 mol/L 단위의 농도 변화량입니다.

상태전이 MLP와 scaling

6 → 32 → 32 → 3 MLP에 ReLU 은닉층과 선형 출력층을 사용합니다. 파라미터 수는 (6×32 + 32) + (32×32 + 32) + (32×3 + 3) = 1379개입니다.

입력과 변화량의 평균·표준편차는 train 행으로 계산하며, 같은 통계량을 validation·test·rollout 상태에 적용합니다.

MLP가 예측한 표준화 변화량을 mol/L로 복원해 현재 상태에 더합니다.

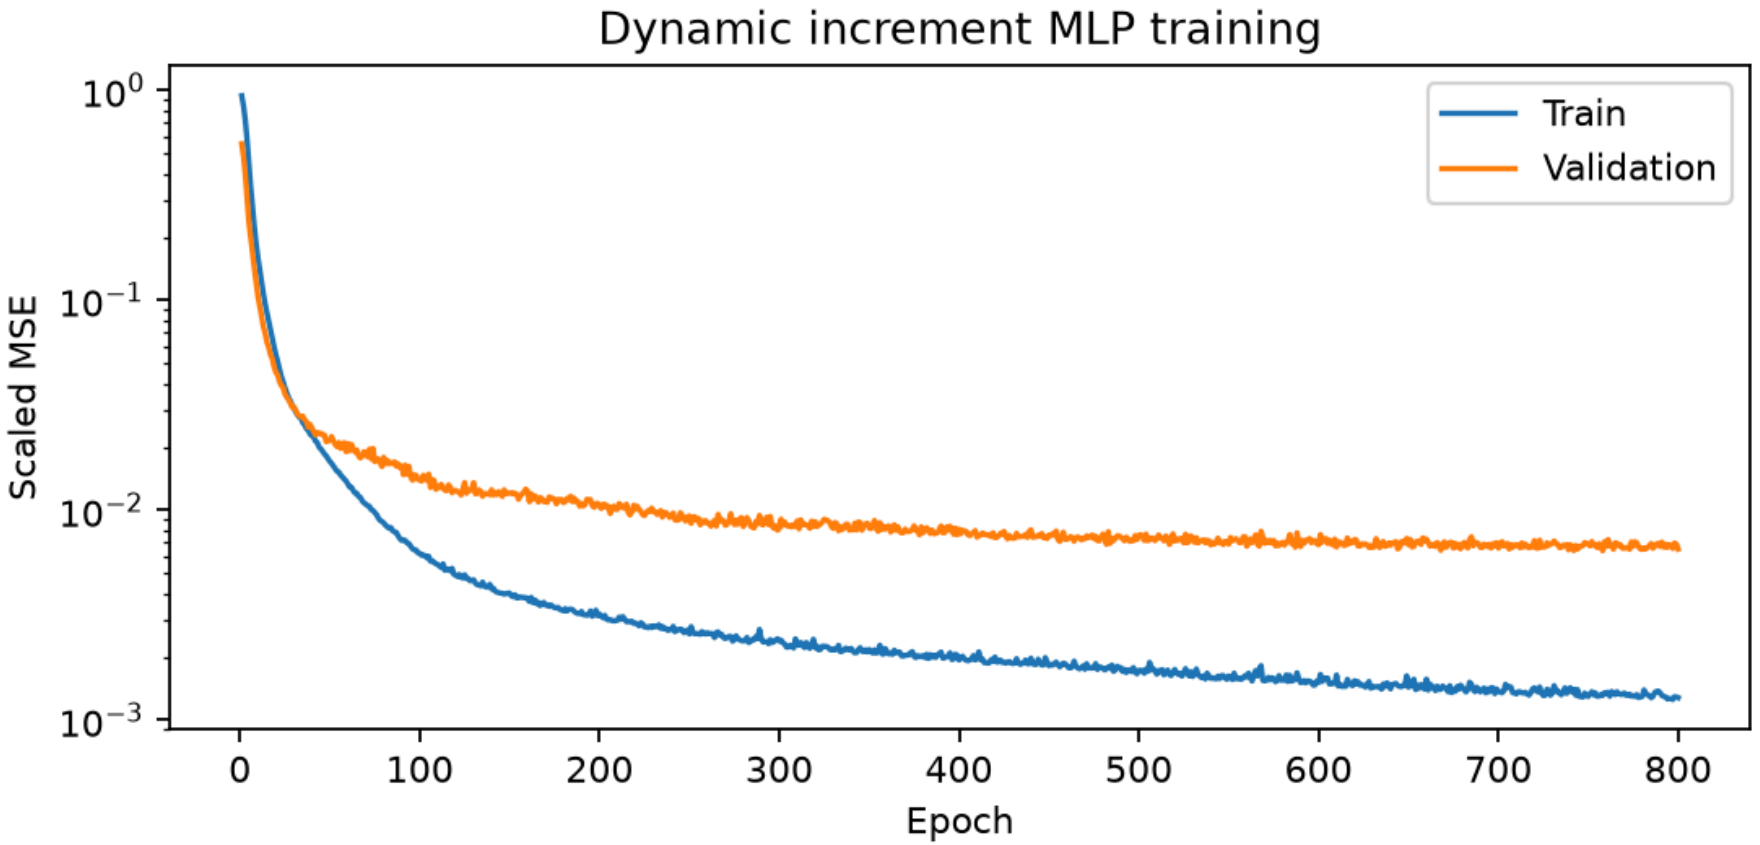
기준 현재 상태에서 학습하기

각 train 입력에는 기준 현재 상태를 넣고, 표준화 변화량의 평균제곱 오차를 최소화합니다.

$$L_1 = \frac{1}{3N}\sum_n \sum_j \left(g_\theta(\tilde{\mathrm{v}}_n)_j - \Delta\tilde{\mathrm{c}}_{n,j} \right)^2$$

Adam을 학습률 0.001, batch size 512, 최대 800 epoch로 실행합니다. Validation loss가 가장 작은 가중치를 보관한 뒤 test 궤적을 평가합니다.

학습 곡선


Dynamic increment MLP training
Train
Validation
Scaled MSE
10^{0}
10^{-1}
10^{-2}
10^{-3}
0
100
200
300
400
500
600
700
800
Epoch

One-step 평가와 rollout 평가

$$\text{one-step:}\hat{c}_{k+1} = f_\theta\left(c_k, u_k; q\right)$$

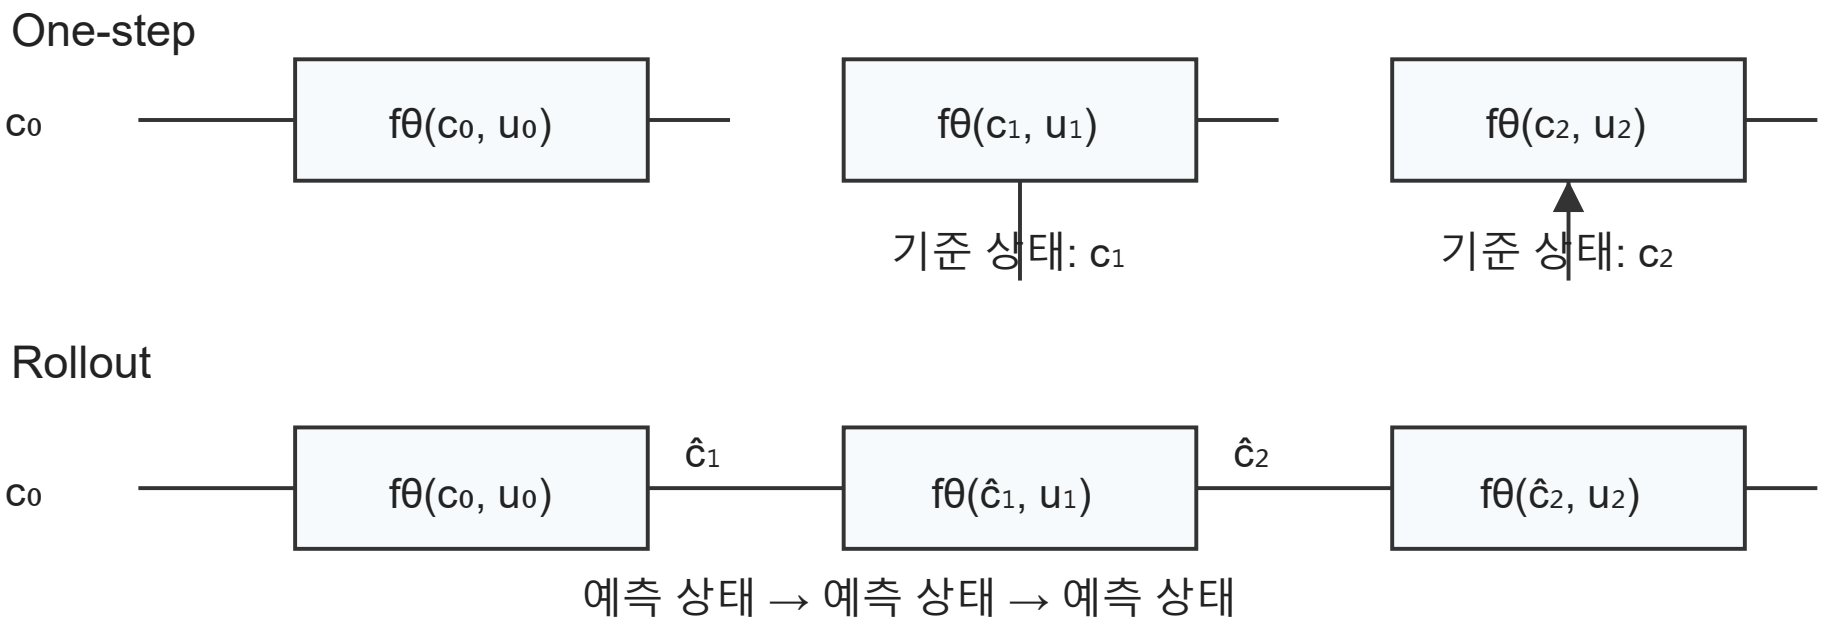
$$\text{rollout:}\hat{c}_{k+1} = f_\theta\left(\hat{c}_k, u_k; q\right), \hat{c}_0 = c_0$$

One-step에서는 매 시각 기준 상태를 입력으로 새로 넣습니다.

Rollout에서는 c_0에서 시작해 예측 상태를 다음 전이에 계속 넣습니다. 두 평가의 미래 입력과 context는 동일하게 유지합니다.

One-step은 매 시각 기준 상태를 다시 받으므로, 초기 상태에서 한 번만 시작하는 예측보다 더 많은 상태 정보를 사용합니다.

기준 상태 입력과 예측 상태 입력



다단계 rollout의 반복 계산

```
pred = np.empty((len(controls) + 1, 3))
pred[0] = initial_state
for k, control in enumerate(controls):
    pred[k + 1] = dynamic_step(
        model, scaling, pred[k:k+1], control[None, :]
    )[0]
```

초기화 후에는 기준 상태를 반복문에 넣지 않고 예측 상태 150개를 평가합니다.

한 단계 오차의 전달식

e_k = ĉ_k − c_k로 정의하고, 기준 상태에서 계산한 예측값을 더했다 빼봅니다.

$$e_{k+1} = f_\theta\left(\hat{c}_k, u_k\right) - f_\theta\left(c_k, u_k\right) + \delta_k$$
$$\delta_k = f_\theta\left(c_k, u_k\right) - F_{\Delta t}\left(c_k, u_k\right)$$

첫 번째 차이는 기존 상태 오차가 학습된 관계식을 거쳐 전달되는 부분입니다. δ_k는 기준 상태에서의 한 단계 예측 오차로, 작더라도 매번 다음 예측에 더해집니다.

One-step 편향의 누적 예제

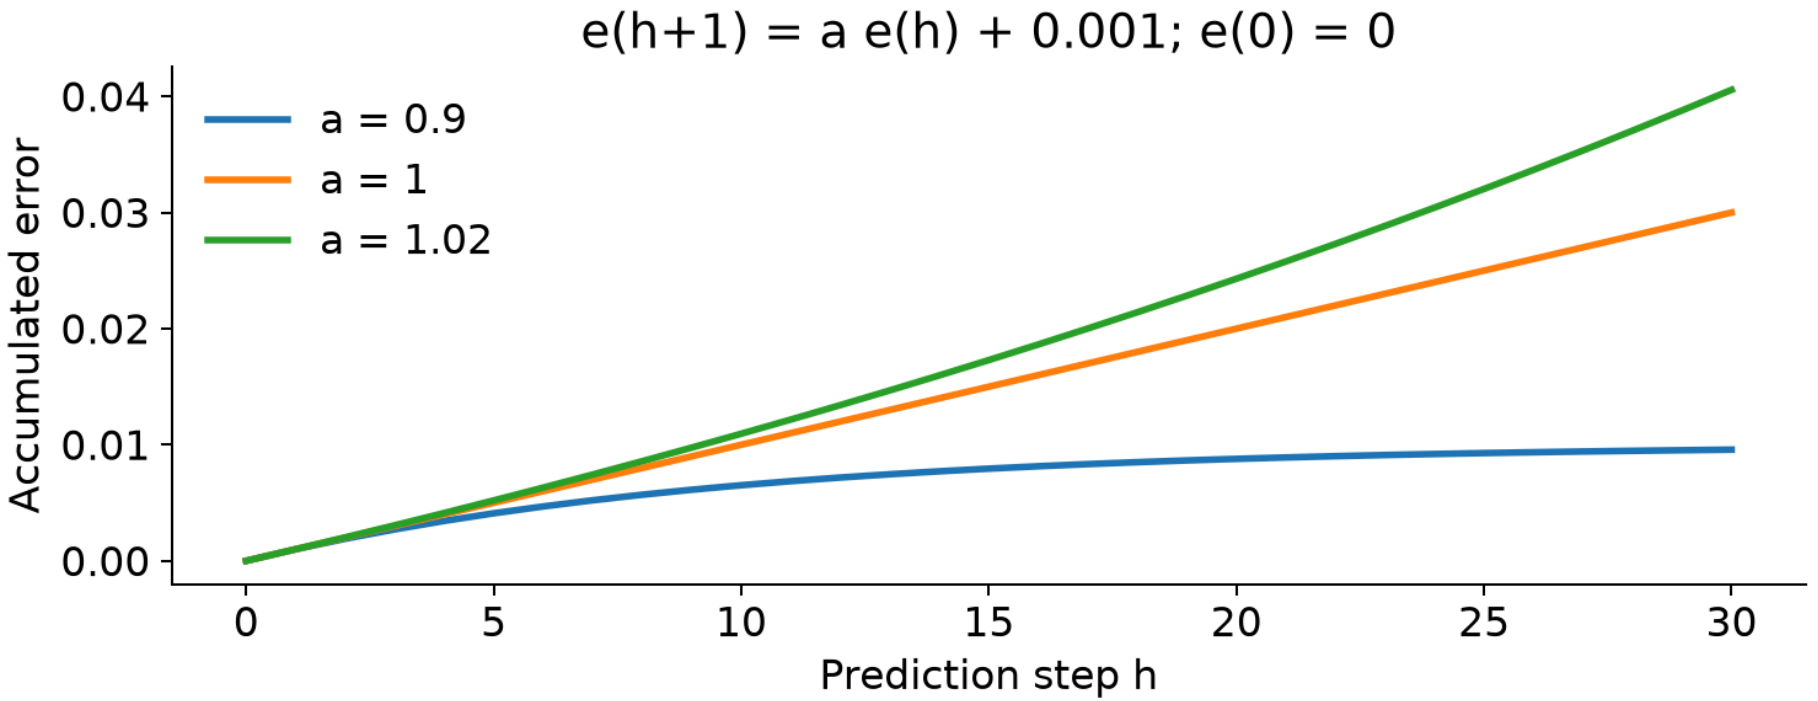
한 변수 예제에서 기준 관계식을 F(c) = 0.9c, 학습 모델을 f(c) = 0.9c + 0.001로 두고 $e_0 = 0$에서 시작합니다.

$$e_{h+1} = 0.9e_h + 0.001$$

$$e_h = 0.001\frac{1 - 0.9^h}{1 - 0.9}$$

One-step bias는 0.001이지만 10번 반복한 오차는 약 0.00651입니다. 수축하는 관계식에서는 누적이 제한되며, 상태 민감도가 달라지면 예측 거리에 따른 오차도 달라집니다.

상태 민감도와 오차 전파



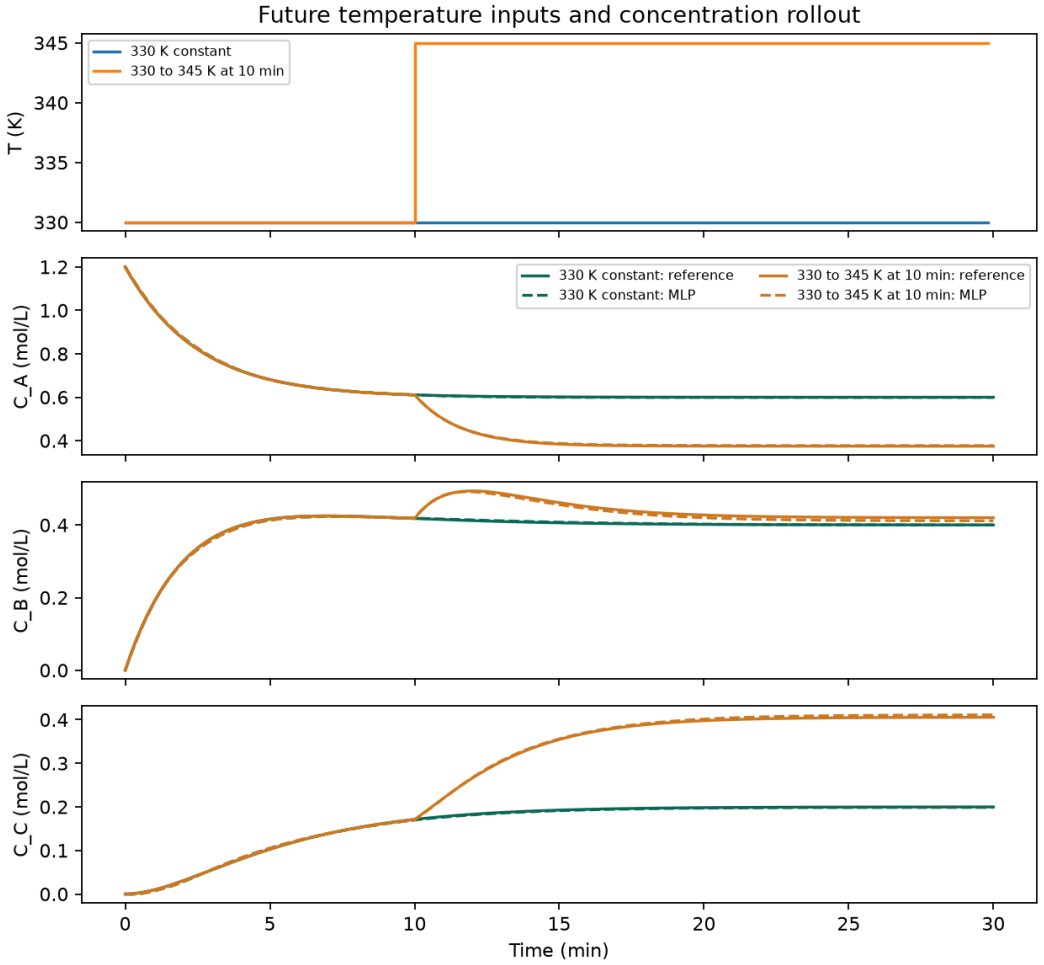
실제 rollout 오차는 증가하거나 완만해지거나 부호가 바뀔 수 있습니다.

주어진 두 온도 계획

조건	일정 온도 계획	온도 변경 계획
초기 조성, mol/L	[1.2, 0, 0]	[1.2, 0, 0]
τ; C_Af	5 min; 1.2 mol/L	5 min; 1.2 mol/L
$0 \le t < 10$ min	330 K	330 K
$10 \le t \le 30$ min	330 K	345 K

동일한 온도 계획에서 기준 궤적과 MLP rollout을 비교합니다. 두 곡선이 달라지기 시작하는 시점과 새 정상상태 응답에 접근하는 과정을 살펴봅니다.

전체 시간에 걸친 A·B·C 농도



물리 단위에서 오차 비교하기

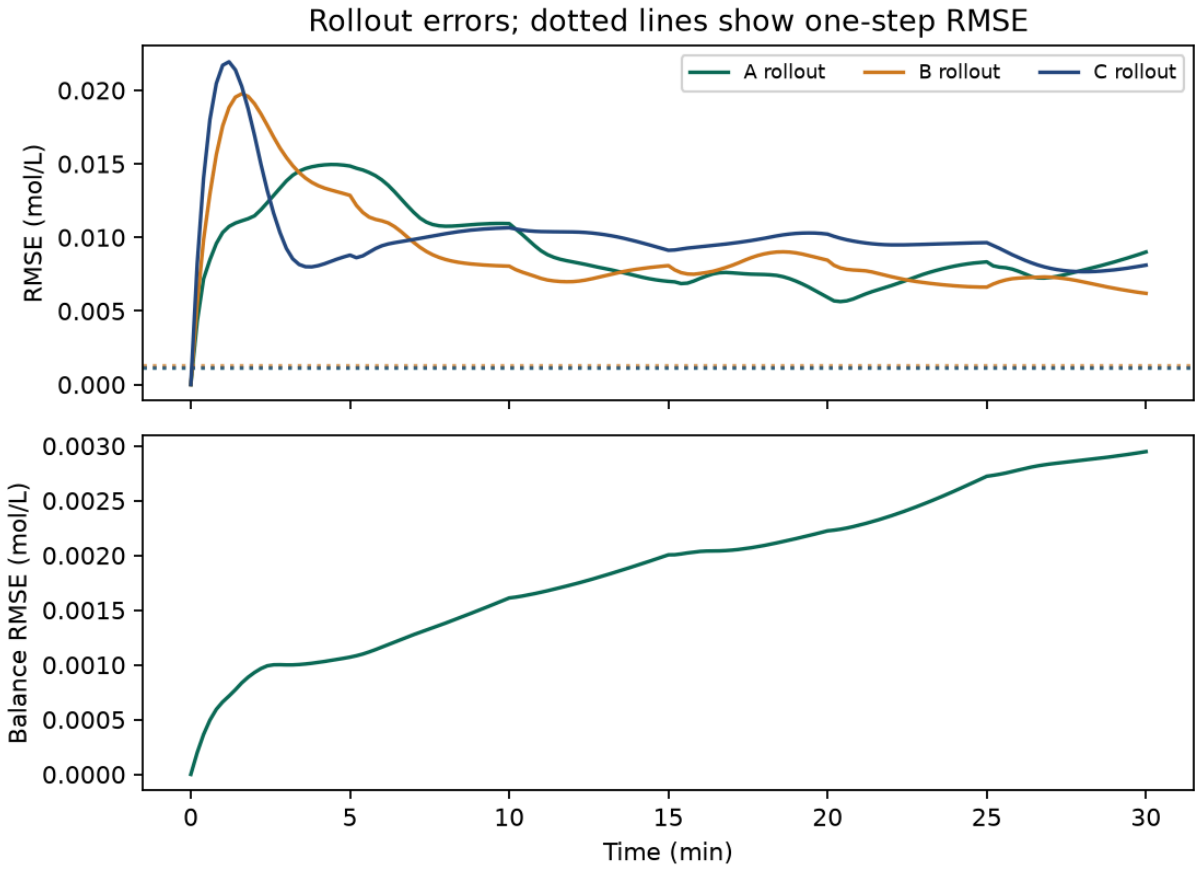
RMSE, mol/L	A	B	C
One-step	0.001170	0.001288	0.001163
Rollout	0.009465	0.009629	0.010425

독립 test 궤적 20개에서 궤적당 예측 시각 150개를 평가한 결과입니다. 이번 실행에서는 rollout 오차가 더 큽니다. 예측 3000개의 성분별 RMSE를 계산하고 각 예측 거리의 오차도 따로 확인합니다.

$$\mathrm{RMSE}_{j,h} = \sqrt{\frac{1}{N}\sum_{n}\left(\hat{C}_{n,h,j} - C_{n,h,j}\right)^2}$$

n은 test 궤적, h는 상태전이 횟수, j는 성분을 뜻합니다.

Horizon에 따른 오차 읽기



궤적을 따라 물리적 일관성 확인하기

$$S = C_A + C_B + C_C, \frac{dS}{dt} = \frac{C_{\mathrm{Af}} - S}{\tau}$$

$$S_{k+1} = C_{\mathrm{Af}} + \left(S_k - C_{\mathrm{Af}}\right) e^{-\Delta t / \tau}$$

$S_0 = C_{Af}$이고 유입 농도가 고정이면 기준 농도 합은 유입 농도와 같습니다. 학습 모델의 출력에는 이 관계가 자동으로 강제되지 않습니다.

진단, mol/L	One-step	Rollout
농도 합 residual RMSE	0.000051	0.002014
최소 예측 농도	-0.001152	-0.005166

온도 계획별 최종 B 농도 비교

30분 B 농도, mol/L	기준 모델	MLP rollout
일정 330 K	0.400091	0.399819
10분에 330 → 345 K	0.420021	0.411526

두 계산 모두 온도 변경 계획의 30분 B 농도가 더 높습니다. MLP는 그 최종 농도를 약 0.00850 mol/L 낮게 예측합니다.

시간에 따라 적용되는 제품 규격을 확인할 때는 마지막 표본과 함께 해당 구간 전체를 살펴야 합니다.

실습 실행과 제출

실습 묶음에서 기준 모델, 저장된 학습 모델, scaling, 그림과 Notebook을 받습니다.

```
python -m pip install -r requirements.txt
python week03_lab.py --output-dir week03-results
# 선택: 같은 데이터 구성으로 다시 학습하기
python week03_lab.py --train --output-dir week03-retrained
```

상태·입력 정의, 데이터 분할·scaling, one-step·rollout RMSE, 예측 거리에 따른 오차 그림과 두 온도 계획의 궤적을 제출합니다.

연습문제와 읽기자료

1. dS/dt를 유도하고 S가 유입 농도와 같게 유지되는 조건을 적습니다.
2. 첫 0.2분 전이를 계산해 forward Euler와 비교합니다.
3. 두 평가에서 같은 MLP에 서로 다른 상태를 입력하는 이유를 설명합니다.
4. 입력 계획은 유지한 채 초기 상태를 바꿔 기준 궤적과 예측 궤적을 비교합니다.

읽기자료에서 유도·계산 예·코드와 답을 확인합니다. 오차 전달식을 계산하고 multi-step 학습 목적함수는 선택 내용으로 다룹니다.

선택 확장: RNN·LSTM의 은닉 상태

필수 예제는 세 농도 상태와 주어진 온도를 모두 입력으로 받습니다. 필요한 상태가 측정에서 빠져 있다면 과거 관측과 입력으로 그 상태를 추정하는 방법이 도움이 될 수 있습니다.

$$h_k = \varphi\left(W_x x_k + W_h h_{k-1} + b\right)$$
$$\hat{y}_k = W_y h_k + b_y$$

RNN은 학습된 은닉 상태를 갱신하고 LSTM은 gate를 사용한 메모리 갱신을 추가합니다. 비교할 때는 궤적 분할과 예측에 제공하는 미래 정보를 같게 둡니다.

구현은 PyTorch RNN·LSTM을 참고합니다.

선택 확장: encoder와 궤적 decoder

Encoder는 과거 관측과 입력열을 상태 표현으로 요약합니다.

Decoder는 그 표현과 주어진 미래 입력 계획으로 미래 농도열을 예측합니다. 각 미래 입력이 해당 예측 단계에 전달되도록 구성합니다.

Sutskever·Vinyals·Le (2014)의 1-2절에서 sequence-to-sequence 아이디어를 읽습니다.

논문 원문.