



3주차: 동적 응답 예측과 rollout

온도를 바꿨다. 제품도 바로 바뀔까?


공정 엔지니어가 10분에 반응기 온도를 바꾼다. 출구 유체는 곧바로 제품 탱크로 들어간다. 앞으로 20분 동안 B 농도는 어떻게 변할까?



새 정상상태로 가는 과정이 중요하다

제품 전환이나 기동 중 목표 조성에 도달하기 전에 나온 유체는 따로 모으거나 다시 처리해야 할 수 있다. 최종 농도만 알아서는 이 구간을 설명할 수 없다.

온도가 같아도 현재 조성은 다를 수 있다. 탱크 안에 이미 들어 있는 물질이 다음 응답에 영향을 준다. 짧은 상태전이를 학습하고 반복해 전체 궤적을 예측해보자.



$T = 330 \text{ K}$, $\tau = 5 \text{ min}$, $C_{Af} = 1.2 \text{ mol/L}$. 초기 상태만 다르다.

이번 주에 만들 것

1. 현재 상태, 주어진 미래 입력, 고정 context, sampling interval을 정의한다.
2. 농도 변화량을 학습하는 상태전이 MLP를 만든다.
3. 독립 test 궤적에서 one-step 예측과 30분 rollout을 비교한다.

같은 모델의 두 평가에서 성분별 오차, horizon에 따른 오차, 두 온도 계획의 궤적을 제출한다.
RNN/LSTM과 encoder-decoder는 선택 확장이다.

정상상태 mapping에서 상태전이 mapping으로

2주차: $[T, \tau, C_{Af}] \rightarrow$ 정상상태에 도달한 뒤의 조성.

3주차: 현재 조성 + 해당 구간의 입력 + context $\rightarrow$ 한 구간 뒤의 조성.

$$c_{k+1} = F_{\Delta t}(c_k, u_k; q)$$

이 mapping을 반복 적용하면 궤적이 된다. 상태전이에 필요한 상태를 입력에 담으면 feedforward MLP로도 동적 전이를 학습할 수 있다.

상태·미래 입력·고정 context

기호	의미	단위·역할
$c_k = [C_{A,k}, C_{B,k}, C_{C,k}]$	현재 반응기 조성	mol/L; 상태
$u_k = T_k$	k번째 구간의 온도	K; 주어진 입력
$q = [\tau, C_{Af}]$	체류시간·유입 농도	min, mol/L; 궤적별 고정
$\Delta t = 0.2$	Sampling interval	min; 이 모델에서 고정

Rollout 전에 c_0 와 전체 온도 sequence를 정한다. 온도 계획은 실습에서 주어진다.

기준 CSTR

완전 혼합, 일정 부피, 같은 유입·유출 유량을 갖는 이상적 반응기다. 1:1 화학양론의 1차 연속반응 $A \rightarrow B \rightarrow C$ 를 사용한다. 유입에는 A만 있다. 온도는 주어져서 에너지수지는 포함하지 않는다.

$$\begin{aligned}\frac{dC_A}{dt} &= \frac{C_{Af} - C_A}{\tau} - k_1 C_A \\ \frac{dC_B}{dt} &= k_1 C_A - \frac{C_B}{\tau} - k_2 C_B \\ \frac{dC_C}{dt} &= k_2 C_B - \frac{C_C}{\tau}\end{aligned}$$

$k_1(T) = 0.2 \exp[6000(1/330 - 1/T)]$, $k_2(T) = 0.1 \exp[5000(1/330 - 1/T)]$ 이고 단위는 min^{-1} 다. 330 K에서 $k_1 = 0.2$, $k_2 = 0.1 \text{ min}^{-1}$ 다.

연속 공정을 일정 간격으로 관찰하기

각 구간 $[t_k, t_k + \Delta t)$ 에서 T_k 를 일정하게 유지한다. 그 구간의 수지를 적분한 결과가 c_{k+1} 이다. 입력이 바뀌는 순간에도 상태는 연속이다.

$30 \text{ min} / 0.2 \text{ min} =$ 상태전이 150개, 관찰 상태 151개다. 10분 온도 변경은 index 50 구간에서 시작한다.

학습한 mapping은 0.2분 전이를 예측한다. 반복 횟수를 늘리면 horizon이 길어지고, sampling interval은 그대로다.

이 교육 모델의 구간 응답 계산

구간 입력이 일정하면 수지는 상태에 대해 affine하다. $dc/dt = Mc + b$ 로 쓰면 정상상태 c^* 는 $Mc^* + b = 0$ 을 만족한다.

$$F_{\Delta t}(c, u; q) = c^* + e^{M\Delta t}(c - c^*)$$

실습은 이 식을 해석적으로 계산해 정한 Δt 의 label을 생성한다. 읽기자료에서 M과 각 성분의 식을 유도한다.

$c_0 = [1.2, 0, 0]$, $T = 330$ K, $\tau = 5$ min, feed = 1.2 mol/L이면 $c_1 \approx [1.153870, 0.045672, 0.000458]$ mol/L다.

궤적을 만든 뒤 상태전이 행을 만든다

300–360 K, $\tau = 1\text{--}10$ min, feed = 0.8–1.5 mol/L를 사용한다. 무작위 온도 계획은 5분짜리 block 6개다. 궤적별 초기 조성은 비음수이며 합은 유입 농도다.

분할	궤적 수	상태전이 행 수
Train	60	9000
Validation	15	2250
Test	20	3000

학습 데이터 한 행에는 무엇이 들어갈까?

항목	구성
입력 v_k	$[C_{A,k}, C_{B,k}, C_{C,k}, T_k, \tau, C_{Af}]$
다음 상태 label	기준 구간 응답으로 계산한 c_{k+1}
변화량 target	$\Delta c_k = c_{k+1} - c_k$
식별 정보	split, 궤적 ID, t_k

$$\Delta c_k = c_{k+1} - c_k$$
$$\hat{c}_{k+1} = c_k + \mu_{\Delta} + s_{\Delta} \odot g_{\theta}(\tilde{v}_k)$$

Target은 **mol/L** 단위의 변화량이다.

상태전이 MLP와 scaling

$6 \rightarrow 32 \rightarrow 32 \rightarrow 3$, ReLU hidden layer, linear output을 쓴다. 파라미터 수는 $(6 \times 32 + 32) + (32 \times 32 + 32) + (32 \times 3 + 3) = 1379$ 개다.

입력과 변화량의 평균·표준편차를 train 행으로 계산한다. 같은 통계량을 validation·test·rollout 상태에 적용한다.

MLP가 표준화된 변화량을 예측하면 mol/L로 복원해 현재 상태에 더한다. 변화량 모델도 변화가 0인 응답을 표현할 수 있지만, 구조만으로 정확도나 물리적 일관성이 보장되지는 않는다.


기준 현재 상태에서 학습하기

각 train 입력에는 기준 현재 상태가 들어간다. 표준화한 변화량의 평균제곱 오차를 최소화한다.

$$L_1 = \frac{1}{3N} \sum_n \sum_j \left(g_{\theta}(\tilde{v}_n)_j - \Delta \tilde{c}_{n,j} \right)^2$$

Adam: learning rate 0.001, batch size 512, 최대 800 epoch. Validation loss가 가장 작은 가중치를 보관한다.
Test 궤적은 이 선택 뒤에 사용한다.

학습 곡선



같은 모델을 평가하는 두 방법

$$\text{one-step: } \hat{c}_{k+1} = f_{\theta}(c_k, u_k; q)$$

$$\text{rollout: } \hat{c}_{k+1} = f_{\theta}(\hat{c}_k, u_k; q), \hat{c}_0 = c_0$$


One-step: 매 시각 기준 상태를 입력으로 새로 넣는다.

Rollout: c_0 에서 시작한 뒤 예측 상태를 다음 전이에 계속 넣는다. 두 평가의 미래 입력과 context는 같게 둔다.


One-step 결과에는 처음 한 번만 시작하는 예측보다 많은 상태 정보가 제공된다.

다음 입력 상태가 어디서 오는가

One-step



Rollout



두 그림은 같은 고정된 상태전이 모델을 쓴다.

Rollout은 짧고 명확한 반복문이다

초기 상태와 미래 입력 구간 150개가 주어졌을 때:

```
pred = np.empty((len(controls) + 1, 3))
pred[0] = initial_state
for k, control in enumerate(controls):
    pred[k + 1] = dynamic_step(
        model, scaling, pred[k:k+1], control[None, :])
    )
```

초기화 뒤에는 기준 상태가 이 반복문에 들어오지 않는다. 예측 상태 150개를 평가한다.

한 단계의 오차는 어떻게 이어질까?

$e_k = \hat{c}_k - c_k$ 로 두고, 기준 상태에서 계산한 예측값을 더했다 빼보자.

$$\begin{aligned}e_{k+1} &= f_{\theta}(\hat{c}_k, u_k) - f_{\theta}(c_k, u_k) + \delta_k \\ \delta_k &= f_{\theta}(c_k, u_k) - F_{\Delta t}(c_k, u_k)\end{aligned}$$

첫 번째 차이는 기준 상태 오차가 학습된 mapping을 거쳐 전달되는 부분이다. δ_k 는 기준 상태에서의 한 단계 예측 오차다. 작은 δ_k 도 다음 예측마다 들어간다.

작은 one-step 오차도 쌓일 수 있다


한 변수 예로 기준 mapping을 $F(c) = 0.9c$, 학습 모델을 $f(c) = 0.9c + 0.001$ 로 두자. $e_0 = 0$ 에서 시작한다.

$$e_{h+1} = 0.9e_h + 0.001$$

$$e_h = 0.001 \frac{1 - 0.9^h}{1 - 0.9}$$

One-step bias는 0.001이지만 10번 반복하면 오차는 약 **0.00651**이다. 수축하는 mapping은 누적을 제한한다. 상태에 대한 민감도가 다르면 horizon별 오차도 달라진다.

상태에 대한 민감도도 중요하다




이 그림은 한 변수 예제의 계산이다. 실제 rollout 오차는 증가하거나 완만해지거나 부호가 바뀔 수 있다.

주어진 두 온도 계획

조건	일정 온도 계획	온도 변경 계획
초기 조성, mol/L	[1.2, 0, 0]	[1.2, 0, 0]
τ ; C_Af	5 min; 1.2 mol/L	5 min; 1.2 mol/L
$0 \leq t < 10$ min	330 K	330 K
$10 \leq t \leq 30$ min	330 K	345 K

같은 계획에서 기준 궤적과 MLP rollout을 비교한다. 어느 시점부터 곡선이 달라지는지, 새 정상상태 응답에 어떻게 다가가는지 살펴보자.

전체 시간에 걸친 A·B·C 농도



물리 단위에서 오차 비교하기


RMSE, mol/L	A	B	C
One-step	0.001170	0.001288	0.001163
Rollout	0.009465	0.009629	0.010425

독립 test 궤적 20개, 궤적당 예측 시각 150개를 평가한 결과다. 이 실행에서는 rollout 오차가 더 크다. 예측 3000개의 성분별 RMSE를 계산하고, 각 horizon도 따로 살핀다.

$$\text{RMSE}_{j,h} = \sqrt{\frac{1}{N} \sum_n \left(\hat{C}_{n,h,j} - C_{n,h,j} \right)^2}$$

n은 test 궤적, h는 상태전이 횟수, j는 성분을 뜻한다.

Horizon에 따른 오차 읽기



궤적을 따라 물리적 일관성 확인하기

$$S = C_A + C_B + C_C, \frac{dS}{dt} = \frac{C_{Af} - S}{\tau}$$
$$S_{k+1} = C_{Af} + (S_k - C_{Af})e^{-\Delta t / \tau}$$

$S_0 = C_{Af}$ 이고 유입 농도가 고정이면 기준 농도 합은 유입 농도와 같다. 학습 모델의 출력에는 이 관계가 자동으로 강제되지 않는다.

진단, mol/L	One-step	Rollout
농도 합 residual RMSE	0.000051	0.002014
최소 예측 농도	-0.001152	-0.005166

처음의 엔지니어 질문으로 돌아가기

30분 B 농도, mol/L	기준 모델	MLP rollout
일정 330 K	0.400091	0.399819
10분에 330 → 345 K	0.420021	0.411526

두 계산에서 온도 변경 계획의 30분 B 농도가 더 높다. MLP는 그 최종 농도를 약 0.00850 mol/L 낮게 예측한다. 전체 궤적을 보면 정상상태 최종값만으로는 보이지 않는 과도 구간을 확인할 수 있다.

시간에 따라 적용되는 제품 규격을 확인하려면 마지막 표본뿐 아니라 해당 구간을 살펴야 한다.

실습 실행과 제출

실습 묶음에 기준 모델, 저장된 학습 모델, scaling, 그림과 Notebook을 담았다.

```
python -m pip install -r requirements.txt
python week03_lab.py --output-dir week03-results
# 선택: 같은 데이터 구성으로 다시 학습하기
python week03_lab.py --train --output-dir week03-retrained
```

상태·입력 정의, 분할·scaling, one-step·rollout RMSE, horizon 그림, 두 온도 계획의 궤적을 제출한다.

연습문제와 직접 제공 읽기자료

1. dS/dt 를 유도하고 S 가 유입 농도와 같게 유지되는 조건을 적는다.
2. 첫 0.2분 전이를 계산하고 forward Euler와 비교한다.
3. 두 평가에서 같은 MLP에 서로 다른 상태 입력이 들어가는 이유를 설명한다.
4. 입력 계획은 유지하고 초기 상태를 바꿔 기준·예측 궤적을 비교한다.

읽기자료에서 유도·계산 예·코드·답 확인을 직접 제공한다. 오차 전달식을 풀고 multi-step 학습 목적함수도 선택 내용으로 설명한다.

선택 확장: hidden state가 도움이 될 때

핵심 예제는 농도 상태 세 개와 주어진 온도를 모두 입력으로 받는다. 측정에서 필요한 상태가 빠지면, 과거 관측과 입력으로 그 상태를 추정하는 접근이 도움이 될 수 있다.

$$h_k = \varphi(W_x x_k + W_h h_{k-1} + b)$$
$$\hat{y}_k = W_y h_k + b_y$$

RNN은 학습된 hidden state를 갱신한다. LSTM은 gate를 이용한 memory 갱신을 추가한다. 같은 궤적 분할과 미래 예측 정보를 제공해 비교한다.

구현: PyTorch [RNN](#)·[LSTM](#).

선택 확장: encoder와 궤적 decoder

Encoder: 과거 관측·입력 sequence를 상태 표현으로 요약한다.

Decoder: 그 표현과 주어진 미래 입력 계획으로 미래 농도 sequence를 예측한다. 각 미래 입력이 해당 예측 단계에 전달되도록 구성한다.

Sutskever·Vinyals·Le (2014)의 1-2절에서 sequence-to-sequence 아이디어를 읽는다.

[논문 원문](#) · 추가 유도는 직접 제공한 읽기자료에 있다.