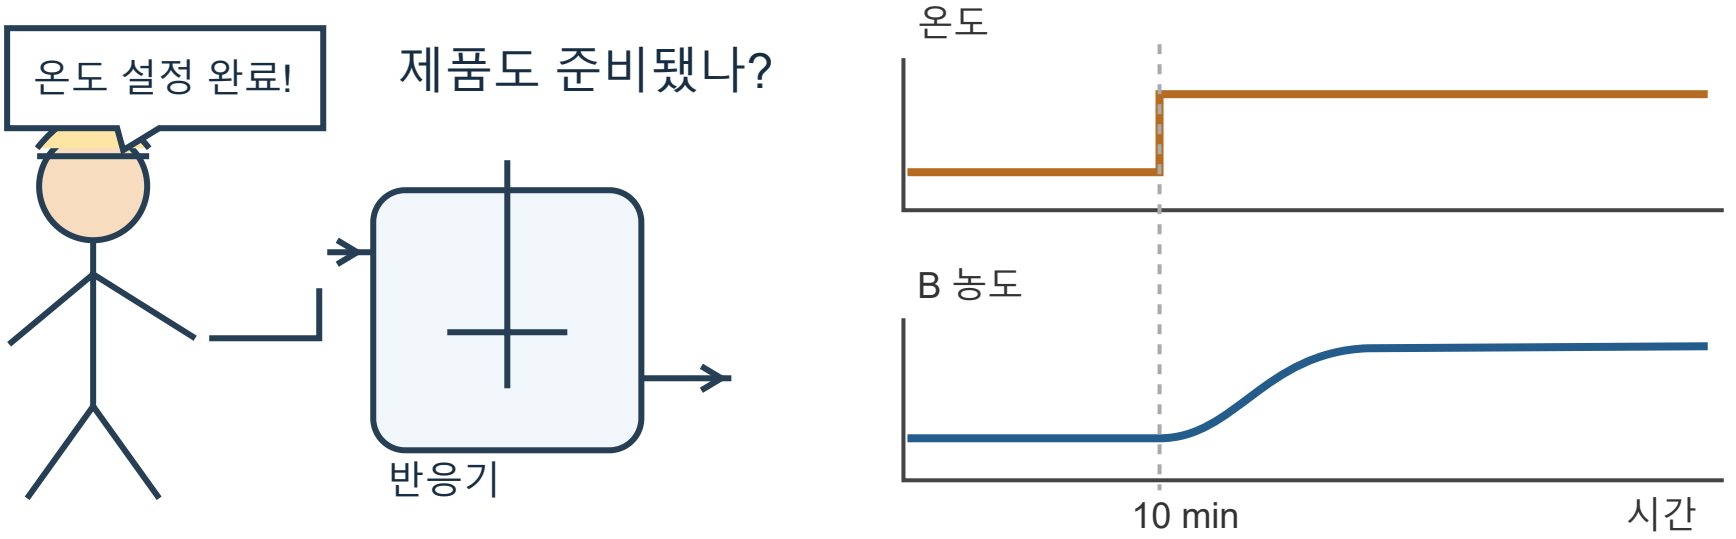
3주차: 동적 응답 예측과 rollout

온도 변경에 따른 제품 농도의 과도응답

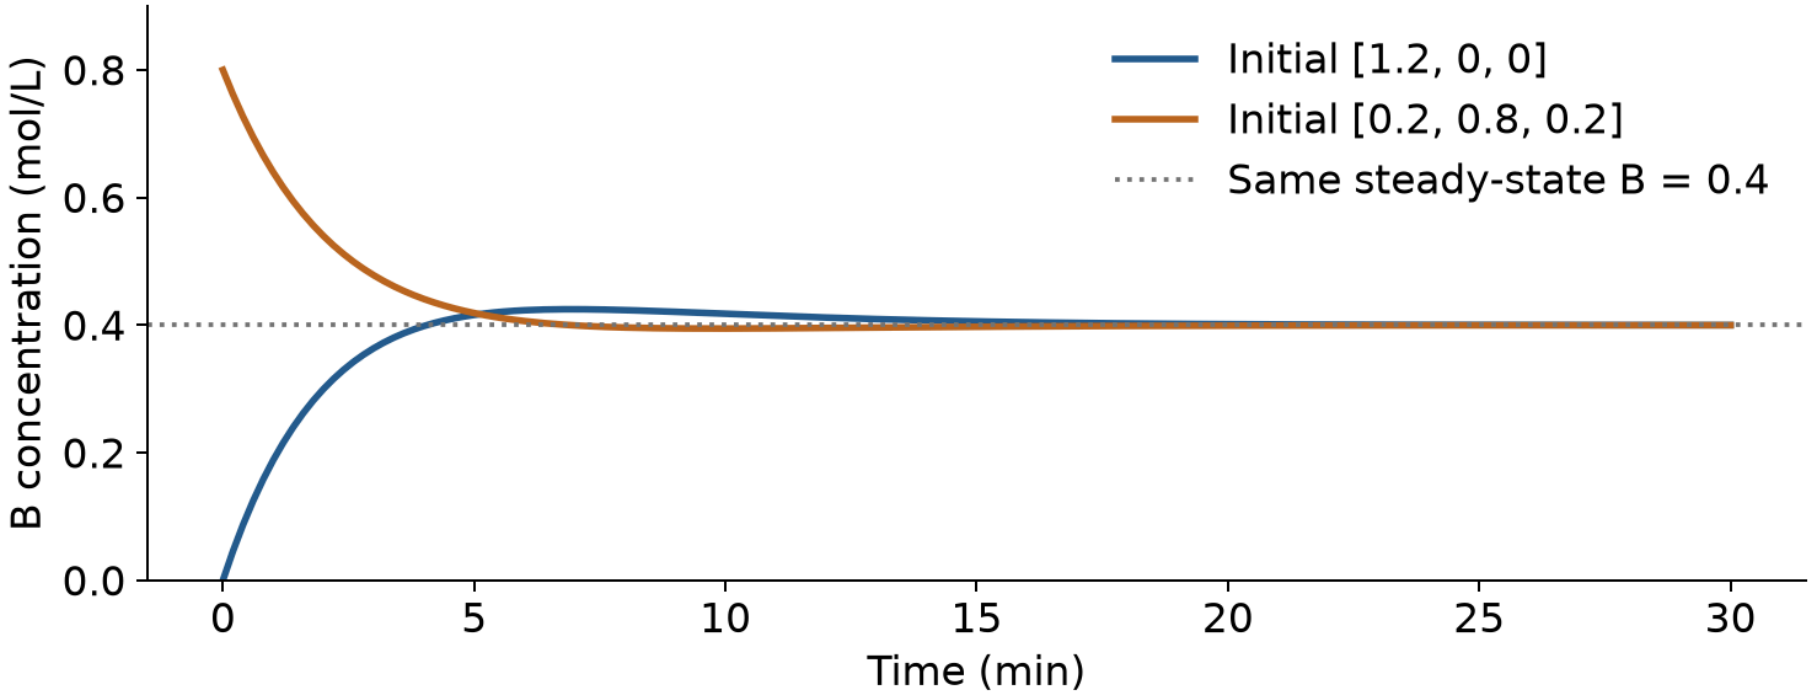
공정 엔지니어가 10분에 반응기 온도를 바꿉니다. 출구 유체가 곧바로 제품 탱크에 들어간다면 앞으로 20분 동안 B 농도는 어떻게 변할까요?



새 정상상태까지의 과도응답

제품 전환이나 기동 중 목표 조성에 도달하기 전에 나온 유체는 따로 모으거나 다시 처리해야 할 수 있습니다. 최종 농도만으로는 이 과도 구간을 설명할 수 없습니다.

온도가 같아도 탱크 안의 현재 조성이 다르면 다음 응답이 달라질 수 있습니다. 짧은 상태전이를 학습하고 반복 적용해 전체 궤적을 예측해봅니다.



T = 330 K, τ = 5 min, C_Af = 1.2 mol/L. 초기 상태만 다르다.

상태전이 모델의 학습과 rollout 평가

1. 현재 상태, 주어진 미래 입력, 고정 조건(context)과 표본 간격을 정의합니다.
2. 농도 변화량을 학습하는 상태전이 MLP를 만듭니다.
3. 독립 test 궤적에서 one-step 예측과 30분 rollout을 비교

제출물: 같은 모델의 두 평가에서 성분별 오차, 예측 거리(horizon)에 따른 오차, 두 온도 계획의 궤적. 선택 확장: RNN/LSTM과 encoder-decoder

정상상태 mapping과 상태전이 mapping

2주차: [T, τ, C_Af] → 정상상태에 도달한 뒤의 조성.

3주차: 현재 조성 + 해당 구간 입력 + context → 한 구간 뒤의 조성.

$$c_{k+1} = F_{\Delta t}\left(c_k, u_k; q\right)$$

이 관계식을 반복 적용하면 궤적을 얻습니다. 전이에 필요한 상태를 입력에 포함하면 feedforward MLP로도 동적 상태전이를 학습할 수 있습니다.

평형 농도만 예측하는 모델에는 탱크에 지금 얼마나 A와 B가 남았는지 전달할 수 없습니다. 전이 모델은 그 현재 상태를 입력에 포함하므로 같은 온도에서도 출발 조성에 따라 다른 다음 상태를 계산합니다.

상태·미래 입력·고정 context

기호	의미	단위·역할
$c_k = [C_{A,k}, C_{B,k}, C_{C,k}]$	현재 반응기 조성	mol/L; 상태
$u_k = T_k$	k번째 구간의 온도	K; 주어진 입력
$q = [\tau, C_{Af}]$	체류시간·유입 농도	min, mol/L; 궤적별 고정
$\Delta t = 0.2$	Sampling interval	min; 이 모델에서 고정

Rollout 전에 c_0와 전체 온도 입력열을 정합니다. 실습에서는 온도 계획이 주어집니다.

기준 CSTR

완전 혼합·일정 부피·동일한 유입 및 유출 유량을 가정하는 이상적 반응기입니다. 1:1 화학양론의 1차 연속반응 A → B → C를 사용하며 유입에는 A만 포함됩니다. 온도는 주어지고 에너지수지는 포함하지 않습니다.

$$\frac{dC_A}{dt} = \frac{C_{Af} - C_A}{\tau} - k_1 C_A$$

$$\frac{dC_B}{dt} = k_1 C_A - \frac{C_B}{\tau} - k_2 C_B$$

$$\frac{dC_C}{dt} = k_2 C_B - \frac{C_C}{\tau}$$

$k_1(T) = 0.2 \exp[6000(1/330 - 1/T)]$, $k_2(T) = 0.1 \exp[5000(1/330 - 1/T)]$이며 단위는 min^{-1}. 330 K에서 $k_1 = 0.2$, $k_2 = 0.1\ \text{min}^{-1}$

연속 공정을 일정 간격으로 관찰하기

각 구간 [t_k, t_k + Δt)에서 T_k를 일정하게 유지하고 수지를 적분해 c_k+1을 구합니다. 입력이 바뀌는 순간에도 상태는 연속

30 min / 0.2 min = 상태전이 150개. 초기값을 포함한 관찰 상태: 151개. 10분 온도 변경 시작: index 50 구간

학습한 관계식은 0.2분 전이를 예측. 반복 횟수를 늘리면 예측 거리가 길어지고 표본 간격은 그대로 유지됩니다.

온도 변경 시각 10 min 직전의 상태가 변경 직후 계산의 시작점입니다. 온도는 즉시 바뀐다고 가정해도 농도를 새 평형값으로 덮어쓰지 않습니다. 이후 0.2 min 동안 새 반응속도로 이동한 양을 계산합니다.

기준 모델의 구간 응답

구간 입력이 일정하면 수지는 상태에 대해 affine합니다. dc/dt = Mc + b로 나타낼 때 정상상태 c∗는 Mc∗ + b = 0을 만족합니다.

$$F_{\Delta t}\left(c, u; q\right) = c^{*} + e^{M\Delta t}\left(c - c^{*}\right)$$

실습은 이 식의 해석해로 정한 Δt의 기준값을 생성합니다.

c_0 = [1.2, 0, 0], T = 330 K, τ = 5 min, feed = 1.2 mol/L이면 $c_1 \approx$ [1.153870, 0.045672, 0.000458] mol/L입니다.

평형값을 빼면 일정한 유입 항이 사라져 편차만 남습니다. 행렬 지수는 각 편차가 줄고 A의 편차가 B와 C로 전달되는 효과를 함께 계산합니다. 입력이 바뀌면 평형점과 행렬을 새로 계산하되 현재 상태는 이어받습니다.

첫 0.2 min의 농도 변화

초기 조성 [1.2,0,0]에서 A의 유입·유출 차이는 0이고 반응 소모는 0.24 mol/(L·min)입니다. B는 같은 속도로 생기며 C는 아직 B가 없어 순간 생성속도가 0입니다.

항목	계산	mol/L
Euler의 A	1.2−0.2×0.24	1.152000
정확한 A	0.6+0.6 exp(−0.08)	1.153870
B의 평형 편차 항	0.4−0.4 exp(−0.06)	0.023294
A에서 B로 전달	0.12[exp(−0.08)−exp(−0.06)]/(−0.1)	0.022378
정확한 B	0.023294+0.022378	0.045672
정확한 C	1.2−1.153870−0.045672	0.000458

Euler는 시작 순간의 속도를 구간 전체에 사용합니다. 실제 구간 안에서는 A가 줄고 B가 생겨 C 생성도 시작되므로 정확한 구간 해와 차이가 납니다.

궤적 생성과 상태전이 데이터 구성

입력 범위: 300-360 K, τ = 1-10 min, feed = 0.8-1.5 mol/L. 무작위 온도 계획: 5분 구간 6개. 각 궤적의 초기 조성: 비음수, 합은 유입 농도

분할	궤적 수	상태전이 행 수
Train	60	9000
Validation	15	2250
Test	20	3000

인접한 두 전이 행은 같은 궤적의 상태를 공유합니다. 행을 무작위로 나누면 거의 같은 궤적 일부가 학습과 시험에 동시에 들어갑니다. 궤적 단위로 먼저 분할하면 새 온도 계획과 초기 상태에 대한 평가를 유지할 수 있습니다.

학습 데이터의 상태·입력·목표값

항목	구성
입력 v_k	[C_A,k, C_B,k, C_C,k, T_k, τ, C_Af]
다음 상태 label	기준 구간 응답으로 계산한 c_k+1
변화량 target	Δc_k = c_k+1 − c_k
식별 정보	split, 궤적 ID, t_k

$$\Delta c_k = c_{k+1} - c_k$$

$$\hat{c}_{k+1} = c_k + \mu_\Delta + s_\Delta \odot g_\theta\left(\tilde{v}_k\right)$$

학습 대상: mol/L 단위의 농도 변화량

첫 행은 [1.2,0,0,330,5,1.2]이고 정답 증가량은 약 [−0.046130,0.045672,0.000458] mol/L입니다. 상태 전체 대신 작은 변화량을 학습하지만, 복원할 때 현재 상태에 더해야 다음 상태가 됩니다.

상태전이 MLP와 scaling

MLP 구조: 6 → 32 → 32 → 3. ReLU 은닉층과 선형 출력층. 파라미터 수: (6×32 + 32) + (32×32 + 32) + (32×3 + 3) = 1379개

입력과 변화량의 평균·표준편차는 train 행으로 계산하며, 같은 통계량을 validation·test·rollout 상태에 적용

MLP가 예측한 표준화 변화량을 mol/L로 복원해 현재 상태에 더합니다.

훈련 평균과 표준편차는 모델이 입력을 해석하는 좌표계입니다. rollout에서 예측 상태의 통계로 다시 계산하면 같은 물리 상태가 다른 숫자로 변환되어 학습한 함수와 입력 좌표가 어긋납니다.

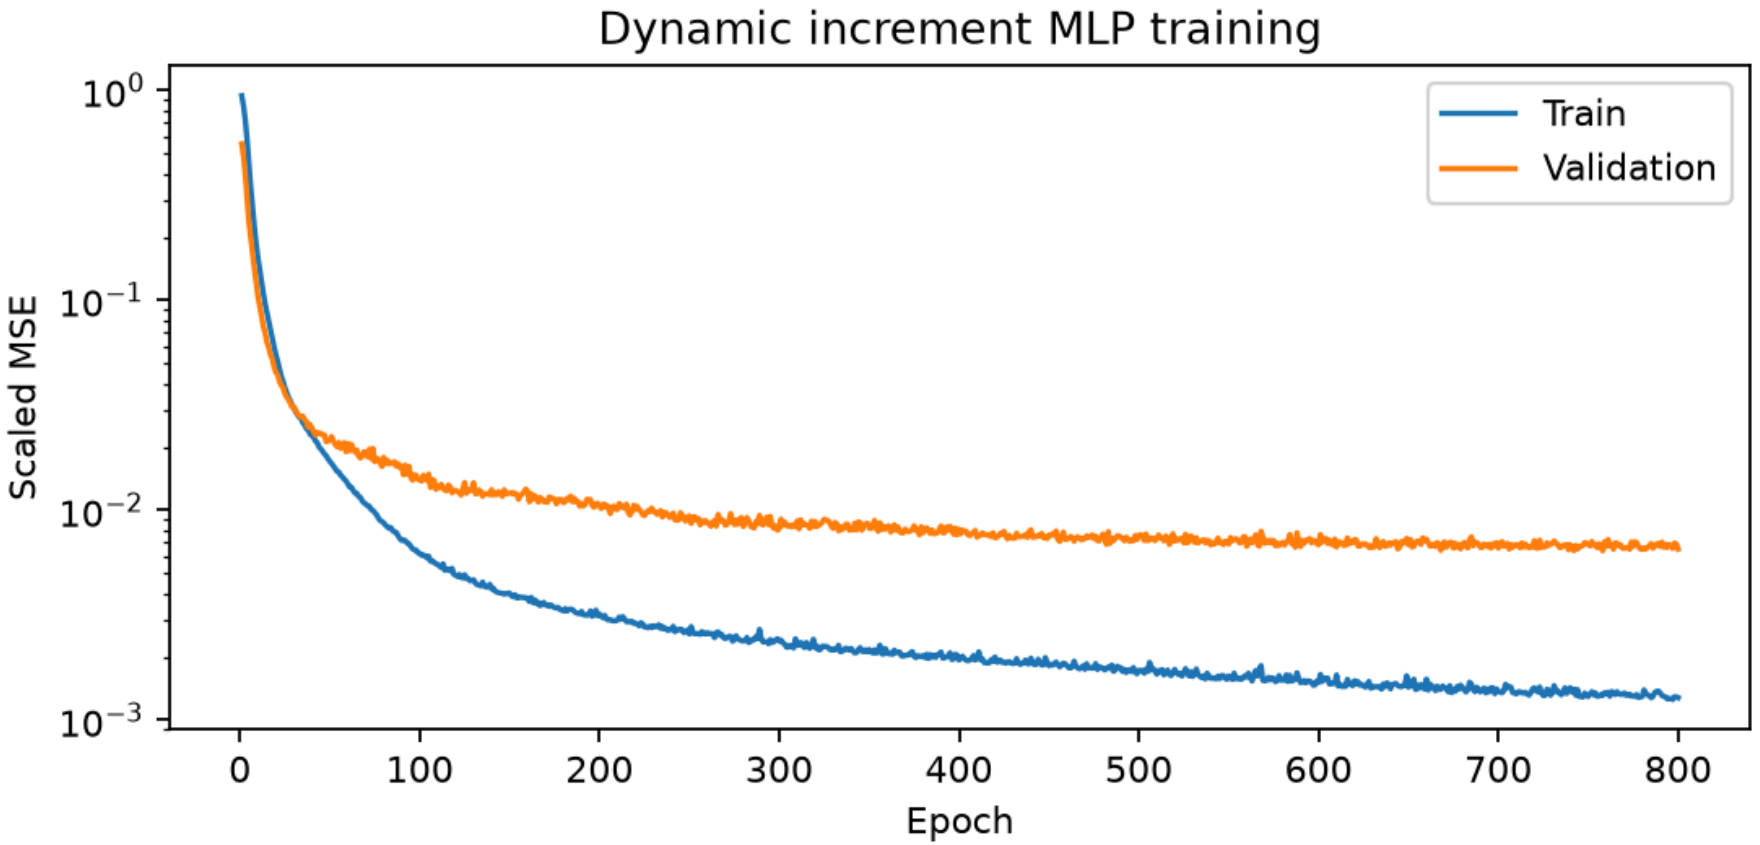
기준 현재 상태에서 학습하기

각 train 입력에는 기준 현재 상태를 넣고, 표준화 변화량의 평균제곱 오차를 최소화

$$L_1 = \frac{1}{3N}\sum_n \sum_j \left(g_\theta(\tilde{\mathrm{v}}_n)_j - \Delta\tilde{\mathrm{c}}_{n,j} \right)^2$$

학습 설정: Adam, 학습률 0.001, batch size 512, 최대 800 epoch. 가중치 선택: 최소 validation loss. 이후 test 궤적 평가

학습 곡선



가로축은 학습 epoch, 세로축은 표준화 증가량의 손실입니다. 검증 손실이 가장 작은 가중치를 선택합니다. 이 곡선이 낮아져도 예측 상태를 반복 입력하는 rollout 오차가 작다는 결론은 나오지 않으므로 다음 평가에서 별도로 확인합니다.

One-step 평가와 rollout 평가

$$\text{one-step:}\hat{c}_{k+1} = f_\theta\left(c_k, u_k; q\right)$$

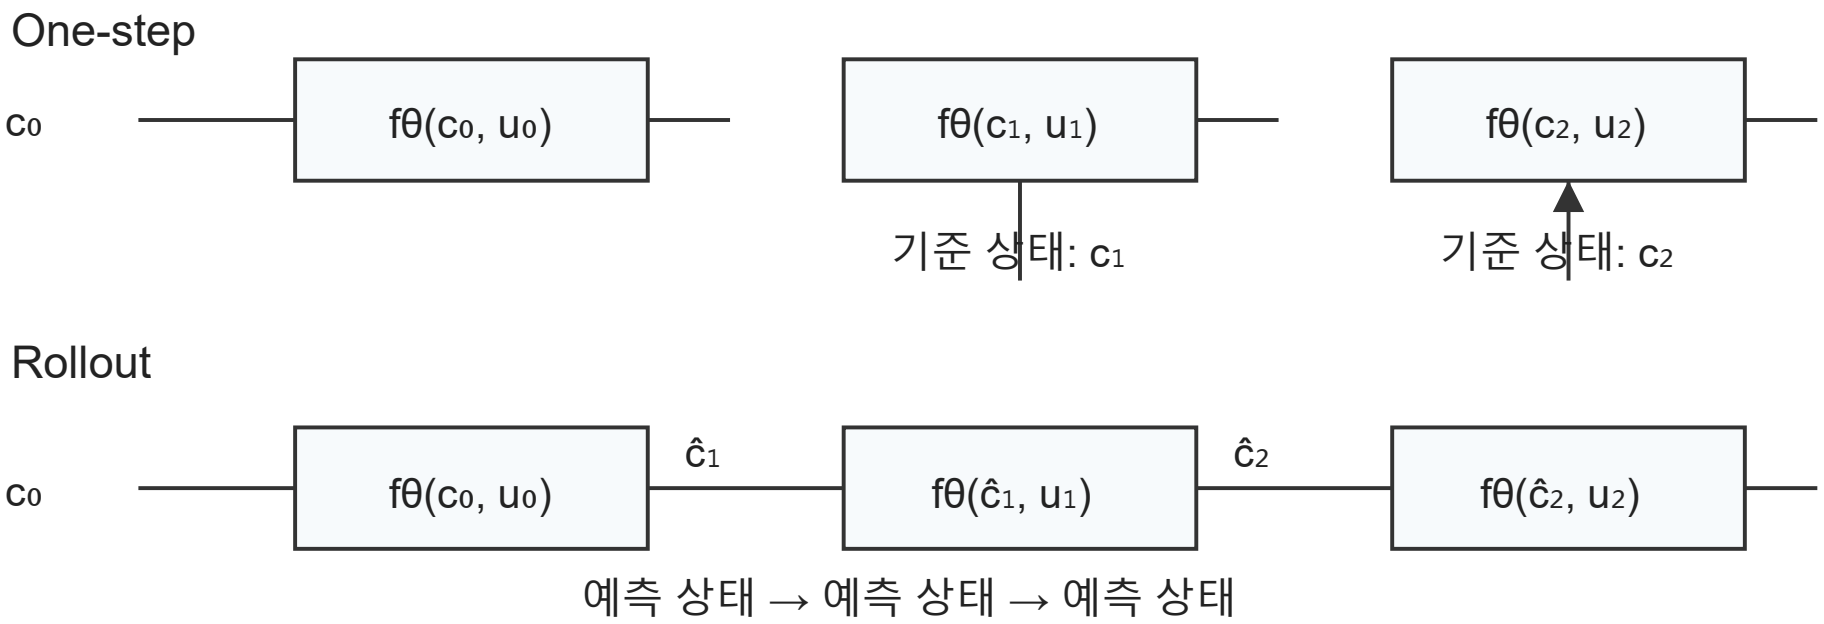
$$\text{rollout:}\hat{c}_{k+1} = f_\theta\left(\hat{c}_k, u_k; q\right), \hat{c}_0 = c_0$$

One-step에서는 매 시각 기준 상태를 입력으로 새로 넣습니다.

Rollout에서는 c_0에서 시작해 예측 상태를 다음 전이에 계속 넣습니다. 두 평가의 미래 입력과 context는 동일하게 유지

One-step은 매 시각 기준 상태를 다시 받으므로, 초기 상태에서 한 번만 시작하는 예측보다 더 많은 상태 정보를 사용합니다.

기준 상태 입력과 예측 상태 입력



두 경로의 첫 계산은 같은 초기 상태를 사용합니다. 두 번째부터 one-step은 실제 c_1을, rollout은 첫 예측 $\hat{c}_1$을 사용합니다. 그림의 피드백 화살표는 첫 오차가 다음 입력에 들어가는 지점을 나타냅니다.

다단계 rollout의 반복 계산

```
pred = np.empty((len(controls) + 1, 3))
pred[0] = initial_state
for k, control in enumerate(controls):
    pred[k + 1] = dynamic_step(
        model, scaling, pred[k:k+1], control[None, :]
    )[0]
```

초기화 후에는 기준 상태를 반복문에 넣지 않고 예측 상태 150개를 평가합니다.

pred[k:k+1]은 (1,3) 행렬을 유지하고 control[None,:]도 행 하나를 만듭니다. dynamic_step 결과의 첫 행 [0]을 다음 상태 칸에 넣습니다. pred[k]를 읽고 pred[k+1]에 쓰므로 이전 예측이 다음 반복의 입력으로 이어집니다.

한 단계 오차의 전달식

e_k = ĉ_k − c_k로 정의하고, 기준 상태에서 계산한 예측값을 더했다 빼봅니다.

$$e_{k+1} = f_\theta\left(\hat{c}_k, u_k\right) - f_\theta\left(c_k, u_k\right) + \delta_k$$
$$\delta_k = f_\theta\left(c_k, u_k\right) - F_{\Delta t}\left(c_k, u_k\right)$$

첫 번째 차이는 기존 상태 오차가 학습된 관계식을 거쳐 전달되는 부분. δ_k는 기준 상태에서의 한 단계 예측 오차로, 작더라도 매번 다음 예측에 더해집니다.

예측 상태에서의 모델값과 기준 상태에서의 모델값을 먼저 비교하면 입력 오차의 영향을 분리할 수 있습니다. 기준 상태에서 모델과 공정을 비교한 나머지가 새로 생기는 국소 오차 δ입니다. 두 차이를 더하면 원래 다음 상태 오차가 됩니다.

One-step 편향의 누적 예제

한 변수 예제에서 기준 관계식을 F(c) = 0.9c, 학습 모델을 f(c) = 0.9c + 0.001로 두고 $e_0 = 0$에서 시작합니다.

$$e_{h+1} = 0.9e_h + 0.001$$

$$e_h = 0.001\frac{1 - 0.9^h}{1 - 0.9}$$

One-step bias는 0.001이지만 10번 반복한 오차는 약 0.00651. 수축하는 관계식에서는 누적이 제한되며, 상태 민감도가 달라지면 예측 거리에 따른 오차도 달라집니다.

두 평가 방식의 중간 상태

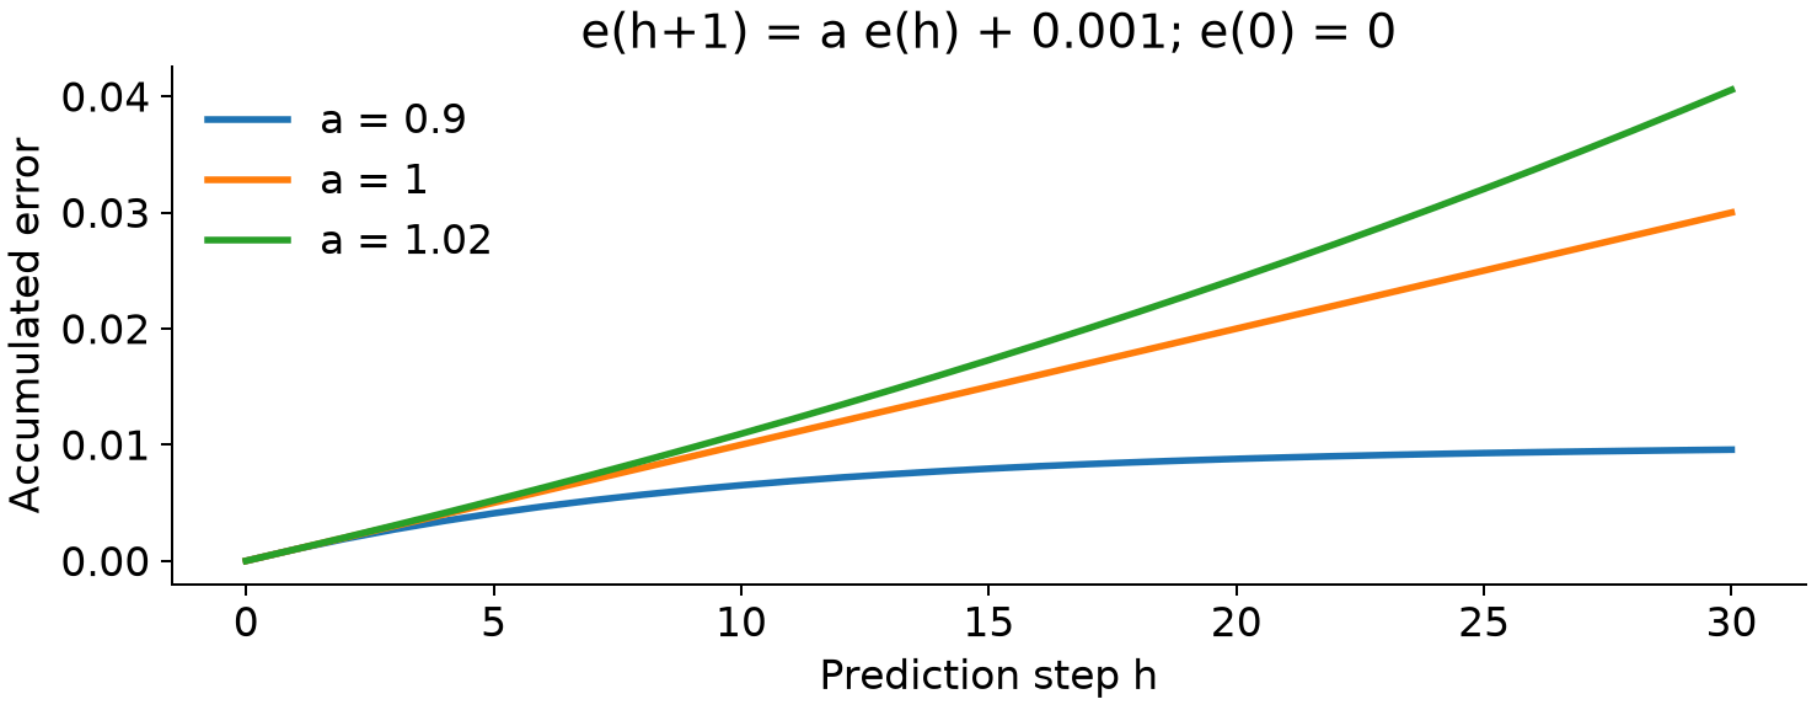
기준 $F(c)=0.9c$, 모델 $f(c)=0.9c+0.001$, 초기값 $c_0=1$을 사용합니다. 수치는 이 스칼라 식의 계산값입니다.

단계	기준 c	one-step 예측	rollout 예측	rollout 오차
0	1	초기 상태	1	0
1	0.9	0.901	0.901	0.001
2	0.81	0.811	0.8119	0.0019
3	0.729	0.730	0.73171	0.00271

```
state = 1.0
for step in range(3):
    state = 0.9 * state + 0.001
    print(step + 1, state)
```

두 번째 rollout은 $0.9\times0.901+0.001$을 계산합니다. one-step은 기준 0.9를 다시 받아 $0.9\times0.9+0.001$을 계산하므로 이전 오차를 물려받지 않습니다.

상태 민감도와 오차 전파



실제 rollout 오차는 증가하거나 완만해지거나 부호가 바뀔 수 있습니다.

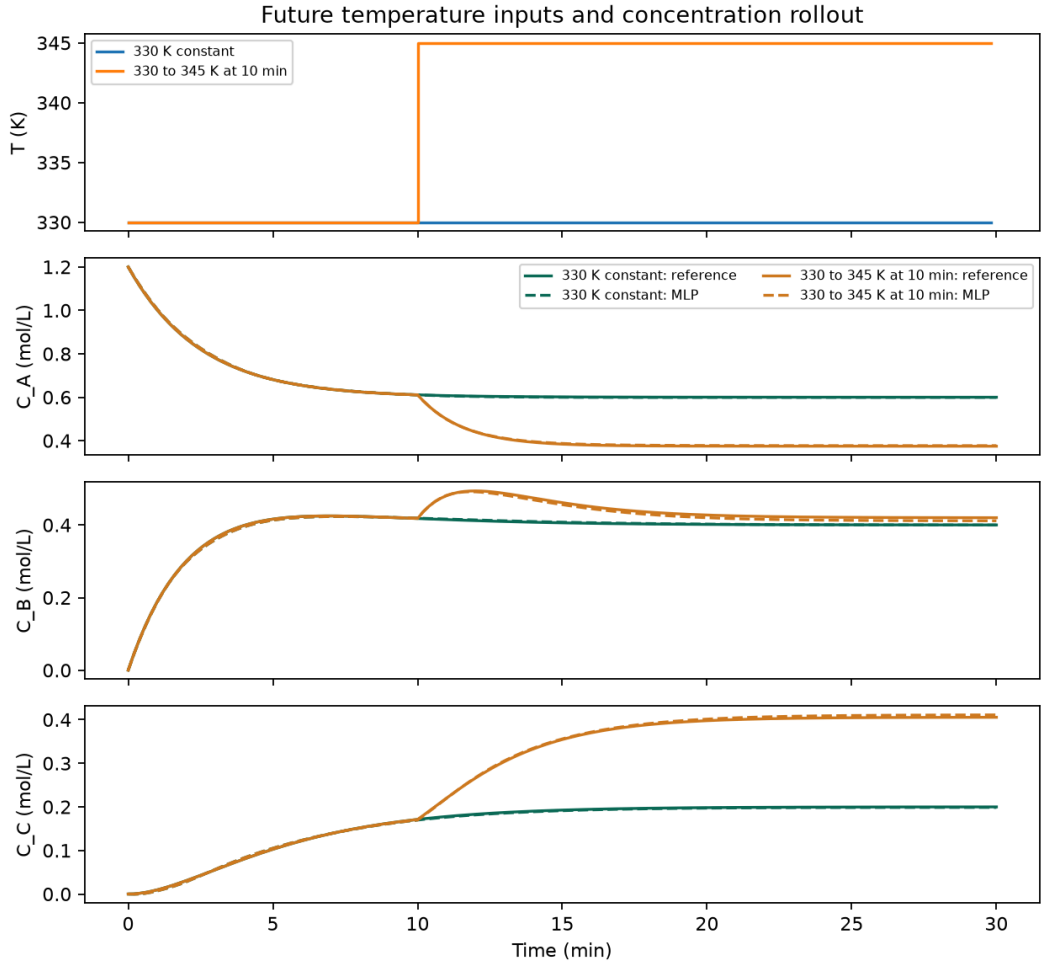
한 단계의 민감도가 0.9이면 기존 오차의 90%가 다음 단계로 넘어옵니다. 1이면 기존 오차가 그대로 남고 새 편향이 계속 더해집니다. 1보다 크면 오차가 증폭될 수 있습니다. 실제 다변수 모델에서는 방향과 상태에 따라 민감도가 달라집니다.

주어진 두 온도 계획

조건	일정 온도 계획	온도 변경 계획
초기 조성, mol/L	[1.2, 0, 0]	[1.2, 0, 0]
τ; C_Af	5 min; 1.2 mol/L	5 min; 1.2 mol/L
$0 \le t < 10$ min	330 K	330 K
$10 \le t \le 30$ min	330 K	345 K

동일한 온도 계획에서 기준 궤적과 MLP rollout을 비교. 두 곡선이 달라지기 시작하는 시점과 새 정상상태 응답에 접근하는 과정을 살펴봅니다.

전체 시간에 걸친 A·B·C 농도



온도 변경 뒤의 농도는 연속적으로 이동합니다. A가 줄고 B가 생기는 속도와 B가 C로 넘어가는 속도를 함께 봅니다. 동일한 시간에서 기준 궤적과 예측 궤적의 수직 차이가 해당 성분의 rollout 오차입니다.

물리 단위에서 오차 비교하기

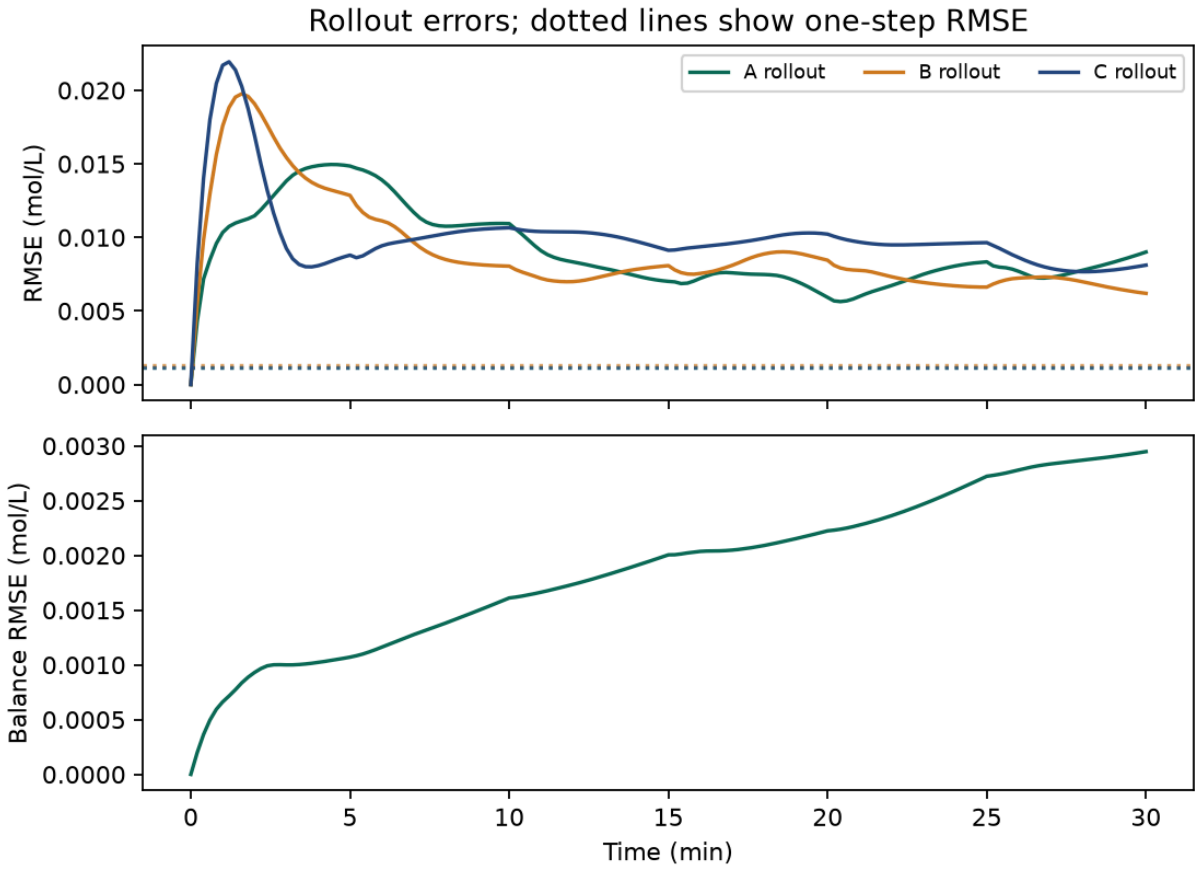
RMSE, mol/L	A	B	C
One-step	0.001170	0.001288	0.001163
Rollout	0.009465	0.009629	0.010425

독립 test 궤적 20개에서 궤적당 예측 시각 150개를 평가한 결과. 이번 실행에서는 rollout 오차가 더 큽니다. 예측 3000개의 성분별 RMSE를 계산하고 각 예측 거리의 오차도 따로 확인

$$\mathrm{RMSE}_{j,h} = \sqrt{\frac{1}{N}\sum_{n}\left(\hat{C}_{n,h,j} - C_{n,h,j}\right)^2}$$

n은 test 궤적, h는 상태전이 횟수, j는 성분을 뜻합니다.

Horizon에 따른 오차 읽기



h=1은 초기 상태에서 한 번 예측한 오차입니다. h=150은 30 min까지 반복한 오차입니다. 각 h에서 시험 궤적 20개를 평균하므로 시간에 따른 오차 축적을 볼 수 있습니다. 모든 시점을 한 번에 평균한 RMSE에는 이 모양이 사라집니다.

궤적을 따라 물리적 일관성 확인하기

$$S = C_A + C_B + C_C, \frac{dS}{dt} = \frac{C_{\mathrm{Af}} - S}{\tau}$$

$$S_{k+1} = C_{\mathrm{Af}} + \left(S_k - C_{\mathrm{Af}}\right) e^{-\Delta \mathrm{t} / \tau}$$

$S_0 = C_Af$이고 유입 농도가 고정이면 기준 농도 합은 유입 농도와 같습니다. 학습 모델의 출력에는 이 관계가 자동으로 강제되지 않습니다.

진단, mol/L	One-step	Rollout
농도 합 residual RMSE	0.000051	0.002014
최소 예측 농도	-0.001152	-0.005166

증가량의 복원과 총농도 검사

현재 상태가 [0.6,0.4,0.2] mol/L이고, 증가량 평균 [0,0,0], scale=[0.02,0.01,0.01] mol/L, 모델 출력 [−0.5,0.6,0.4]라고 둡니다.

순서	값
표준화 출력	[−0.5,0.6,0.4]
scale 곱한 증가량	[−0.010,0.006,0.004] mol/L
현재 상태에 더하기	[0.590,0.406,0.204] mol/L
총농도	0.590+0.406+0.204=1.200 mol/L

```
increment = d_mean + d_scale * standardized_increment
next_state = state + increment
```

이 계산 예의 증가량 합은 0입니다. 일반 MLP에는 그 조건을 강제하지 않았으므로 실제 예측마다 합과 음수 성분을 검사합니다. 초기 총농도가 유입 농도와 다르면 비교 대상은 고정 1.2가 아니라 정확한 총농도 전이식입니다.

온도 계획별 최종 B 농도 비교

30분 B 농도, mol/L	기준 모델	MLP rollout
일정 330 K	0.400091	0.399819
10분에 330 → 345 K	0.420021	0.411526

두 계산 모두 온도 변경 계획의 30분 B 농도가 더 높습니다. MLP는 그 최종 농도를 약 0.00850 mol/L 낮게 예측

시간에 따라 적용되는 제품 규격을 확인할 때는 마지막 표본과 함께 해당 구간 전체를 살펴야 합니다.

실습 실행과 제출

실습 묶음에서 기준 모델, 저장된 학습 모델, scaling, 그림과 Notebook을 받습니다.

```
python -m pip install -r requirements.txt
python week03_lab.py --output-dir week03-results
# 선택: 같은 데이터 구성으로 다시 학습하기
python week03_lab.py --train --output-dir week03-retrained
```

제출물: 상태·입력 정의, 데이터 분할·scaling, one-step·rollout RMSE, 예측 거리에 따른 오차 그림, 두 온도 계획의 궤적

연습문제와 읽기자료

1. dS/dt를 유도하고 S가 유입 농도와 같게 유지되는 조건을 적습니다.
2. 첫 0.2분 전이를 계산해 forward Euler와 비교
3. 두 평가에서 같은 MLP에 서로 다른 상태를 입력하는 이유를 설명합니다.
4. 입력 계획은 유지한 채 초기 상태를 바꿔 기준 궤적과 예측 궤적을 비교

읽기자료

선택 확장: RNN·LSTM의 은닉 상태

필수 예제는 세 농도 상태와 주어진 온도를 모두 입력으로 받습니다. 필요한 상태가 측정에서 빠져 있다면 과거 관측과 입력으로 그 상태를 추정하는 방법이 도움이 될 수 있습니다.

$$h_k = \varphi\left(W_x x_k + W_h h_{k-1} + b\right)$$
$$\hat{y}_k = W_y h_k + b_y$$

RNN은 학습된 은닉 상태를 갱신하고 LSTM은 gate를 사용한 메모리 갱신을 추가합니다. 비교할 때는 궤적 분할과 예측에 제공하는 미래 정보를 같게 둡니다.

구현은 PyTorch RNN·LSTM을 참고합니다.

선택 확장: encoder와 궤적 decoder

Encoder는 과거 관측과 입력열을 상태 표현으로 요약합니다.

Decoder는 그 표현과 주어진 미래 입력 계획으로 미래 농도열을 예측. 각 미래 입력이 해당 예측 단계에 전달되도록 구성합니다.

Sutskever·Vinyals·Le (2014)의 1-2절에서 sequence-to-sequence 아이디어를 읽습니다.

논문 원문.