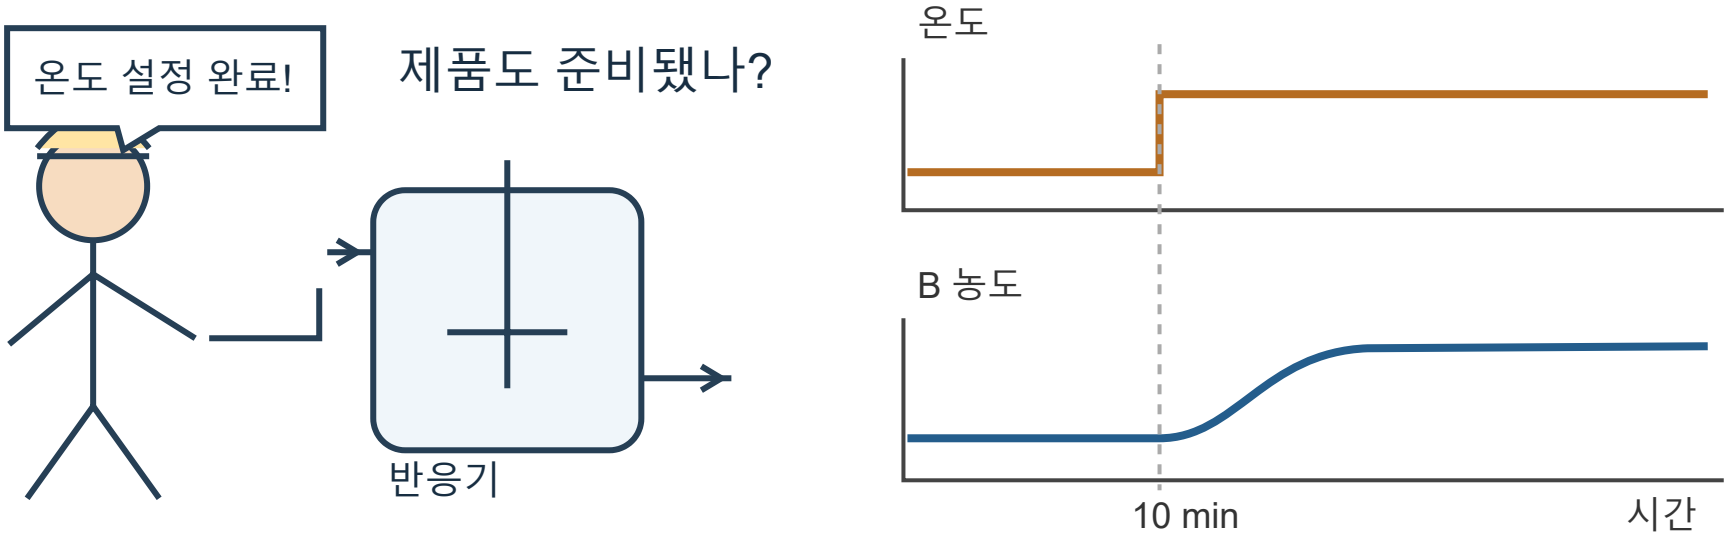
3주차: 동적 응답 예측과 rollout

온도 변경에 따른 제품 농도의 과도응답

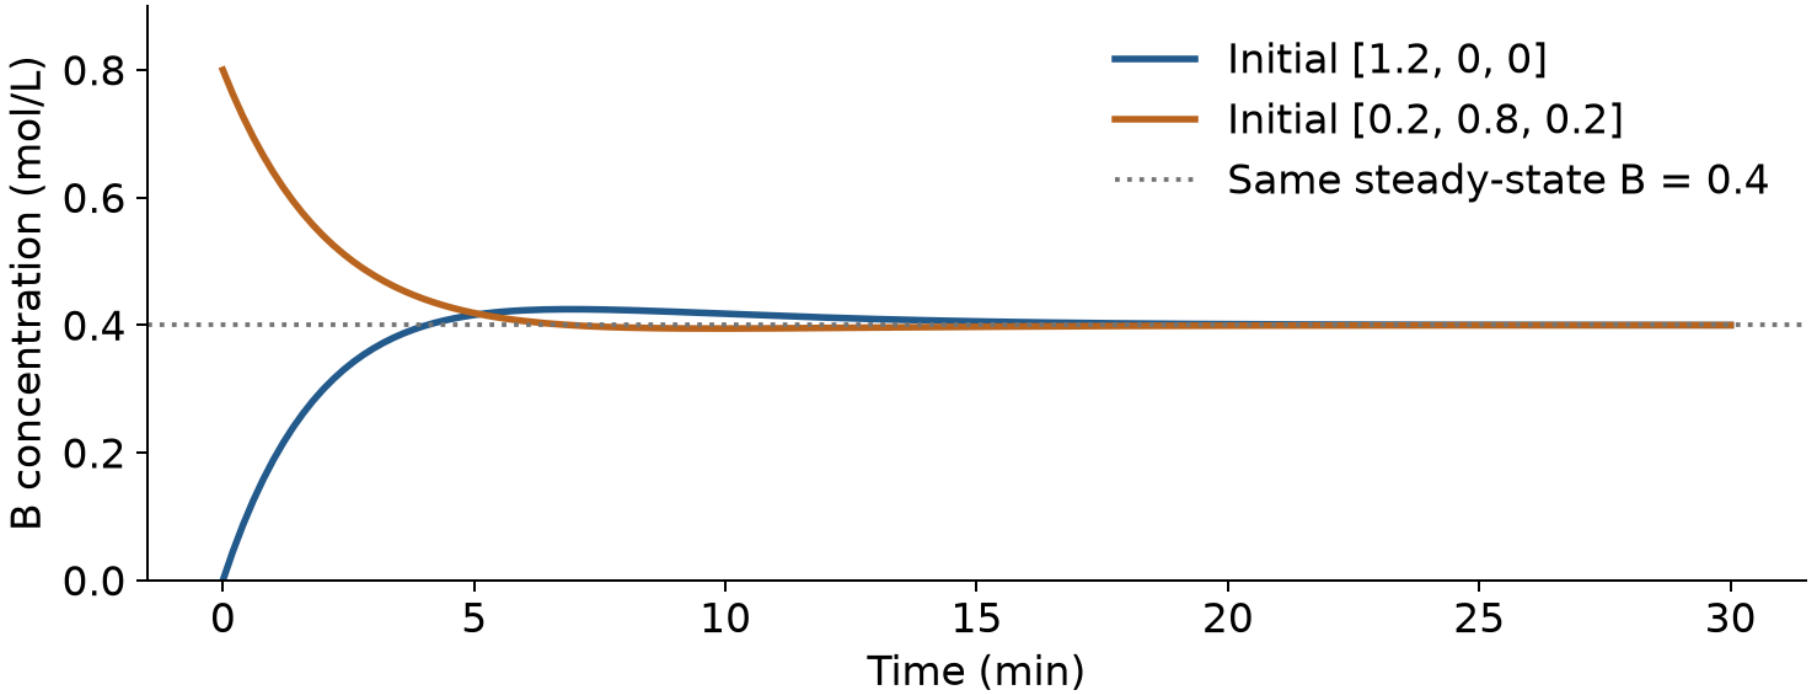
공정 엔지니어가 10분에 반응기 온도를 바꿉니다. 출구 유체가 곧바로 제품 탱크에 들어간다면 앞으로 20분 동안 B 농도는 어떻게 변할까요?



새 정상상태까지의 과도응답

제품 전환이나 기동 중 목표 조성에 도달하기 전에 나온 유체는 따로 모으거나 다시 처리해야 할 수 있습니다. 최종 농도만으로는 이 과도 구간을 설명할 수 없습니다.

온도가 같아도 탱크 안의 현재 조성이 다르면 다음 응답이 달라질 수 있습니다. 짧은 상태전이를 학습하고 반복 적용해 전체 궤적을 예측해봅니다.



T = 330 K, τ = 5 min, C_Af = 1.2 mol/L. 초기 상태만 다르다.

상태전이 모델의 학습과 rollout 평가

1. 현재 상태, 주어진 미래 입력, 고정 조건(context)과 표본 간격을 정의합니다.
2. 농도 변화량을 학습하는 상태전이 MLP를 만듭니다.
3. 독립 test 궤적에서 one-step 예측과 30분 rollout을 비교

제출물: 같은 모델의 두 평가에서 성분별 오차, 예측 거리(horizon)에 따른 오차, 두 온도 계획의 궤적. 선택 확장: RNN/LSTM과 encoder-decoder

정상상태 mapping과 상태전이 mapping

2주차: [T, τ, C_Af] → 정상상태에 도달한 뒤의 조성.

3주차: 현재 조성 + 해당 구간 입력 + context → 한 구간 뒤의 조성.

$$c_{k+1} = F_{\Delta t}\left(c_k, u_k; q\right)$$

이 관계식을 반복 적용하면 궤적을 얻습니다. 전이에 필요한 상태를 입력에 포함하면 feedforward MLP로도 동적 상태전이를 학습할 수 있습니다.

상태·미래 입력·고정 context

기호	의미	단위·역할
$c_k = [C_{A,k}, C_{B,k}, C_{C,k}]$	현재 반응기 조성	mol/L; 상태
$u_k = T_k$	k번째 구간의 온도	K; 주어진 입력
$q = [\tau, C_{Af}]$	체류시간·유입 농도	min, mol/L; 궤적별 고정
$\Delta t = 0.2$	Sampling interval	min; 이 모델에서 고정

Rollout 전에 c_0와 전체 온도 입력열을 정합니다. 실습에서는 온도 계획이 주어집니다.

기준 CSTR

완전 혼합·일정 부피·동일한 유입 및 유출 유량을 가정하는 이상적 반응기입니다. 1:1 화학양론의 1차 연속반응 A → B → C를 사용하며 유입에는 A만 포함됩니다. 온도는 주어지고 에너지수지는 포함하지 않습니다.

$$\frac{dC_A}{dt} = \frac{C_{Af} - C_A}{\tau} - k_1 C_A$$

$$\frac{dC_B}{dt} = k_1 C_A - \frac{C_B}{\tau} - k_2 C_B$$

$$\frac{dC_C}{dt} = k_2 C_B - \frac{C_C}{\tau}$$

$k_1(T) = 0.2 \exp[6000(1/330 - 1/T)]$, $k_2(T) = 0.1 \exp[5000(1/330 - 1/T)]$이며 단위는 min^{-1}. 330 K에서 $k_1 = 0.2$, $k_2 = 0.1\ \text{min}^{-1}$

연속 공정을 일정 간격으로 관찰하기

각 구간 [t_k, t_k + Δt)에서 T_k를 일정하게 유지하고 수지를 적분해 c_k+1을 구합니다. 입력이 바뀌는 순간에도 상태는 연속

30 min / 0.2 min = 상태전이 150개. 초기값을 포함한 관찰 상태: 151개. 10분 온도 변경 시작: index 50 구간

학습한 관계식은 0.2분 전이를 예측. 반복 횟수를 늘리면 예측 거리가 길어지고 표본 간격은 그대로 유지됩니다.

기준 모델의 구간 응답

구간 입력이 일정하면 수지는 상태에 대해 affine합니다. dc/dt = Mc + b로 나타낼 때 정상상태 c∗는 Mc∗ + b = 0을 만족합니다.

$$F_{\Delta t}\left(c, u; q\right) = c^{*} + e^{M\Delta t}\left(c - c^{*}\right)$$

실습은 이 식의 해석해로 정한 Δt의 기준값을 생성. M과 성분별 식의 유도는 읽기자료에서 확인

c_0 = [1.2, 0, 0], T = 330 K, τ = 5 min, feed = 1.2 mol/L이면 $c_1 \approx$ [1.153870, 0.045672, 0.000458] mol/L입니다.

궤적 생성과 상태전이 데이터 구성

입력 범위: 300-360 K, τ = 1-10 min, feed = 0.8-1.5 mol/L. 무작위 온도 계획: 5분 구간 6개. 각 궤적의 초기 조성: 비음수, 합은 유입 농도

분할	궤적 수	상태전이 행 수
Train	60	9000
Validation	15	2250
Test	20	3000

학습 데이터의 상태·입력·목표값

항목	구성
입력 v_k	[C_A,k, C_B,k, C_C,k, T_k, τ, C_Af]
다음 상태 label	기준 구간 응답으로 계산한 c_k+1
변화량 target	Δc_k = c_k+1 − c_k
식별 정보	split, 궤적 ID, t_k

$$\Delta c_k = c_{k+1} - c_k$$

$$\hat{c}_{k+1} = c_k + \mu_\Delta + s_\Delta \odot g_\theta\left(\tilde{v}_k\right)$$

학습 대상: mol/L 단위의 농도 변화량

상태전이 MLP와 scaling

MLP 구조: 6 → 32 → 32 → 3. ReLU 은닉층과 선형 출력층. 파라미터 수: (6×32 + 32) + (32×32 + 32) + (32×3 + 3) = 1379개

입력과 변화량의 평균·표준편차는 train 행으로 계산하며, 같은 통계량을 validation·test·rollout 상태에 적용

MLP가 예측한 표준화 변화량을 mol/L로 복원해 현재 상태에 더합니다.

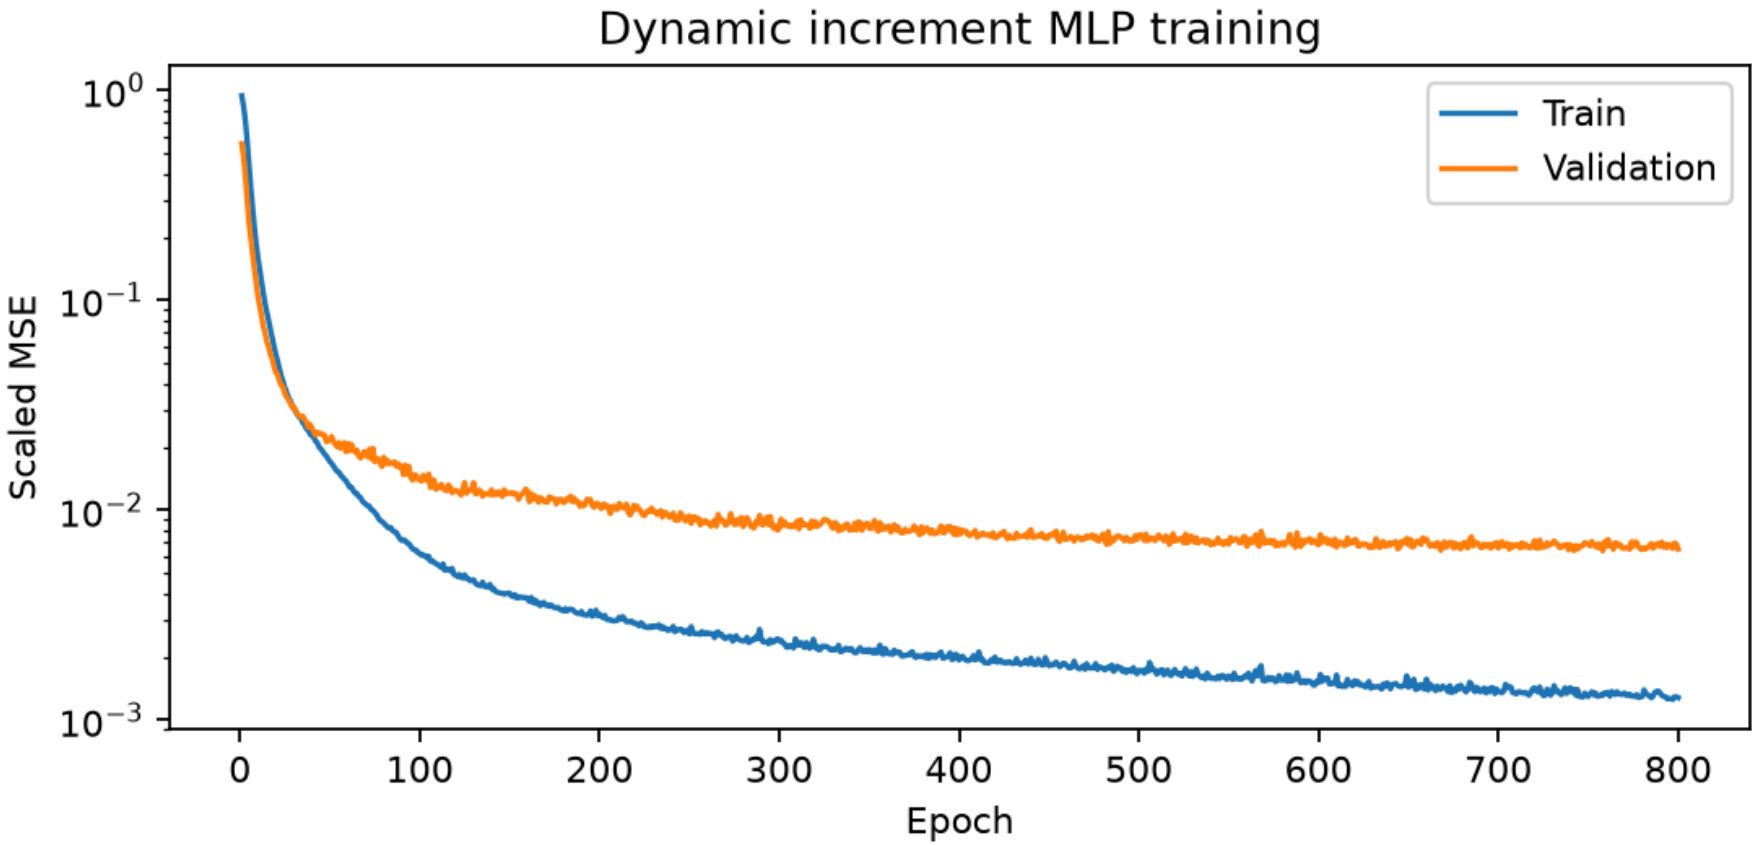
기준 현재 상태에서 학습하기

각 train 입력에는 기준 현재 상태를 넣고, 표준화 변화량의 평균제곱 오차를 최소화

$$L_1 = \frac{1}{3N}\sum_n \sum_j \left(g_\theta(\tilde{\mathrm{v}}_n)_j - \Delta\tilde{\mathrm{c}}_{n,j} \right)^2$$

학습 설정: Adam, 학습률 0.001, batch size 512, 최대 800 epoch. 가중치 선택: 최소 validation loss. 이후 test 궤적 평가

학습 곡선


Dynamic increment MLP training
Train
Validation
Scaled MSE
10^{0}
10^{-1}
10^{-2}
10^{-3}
0
100
200
300
400
500
600
700
800
Epoch

One-step 평가와 rollout 평가

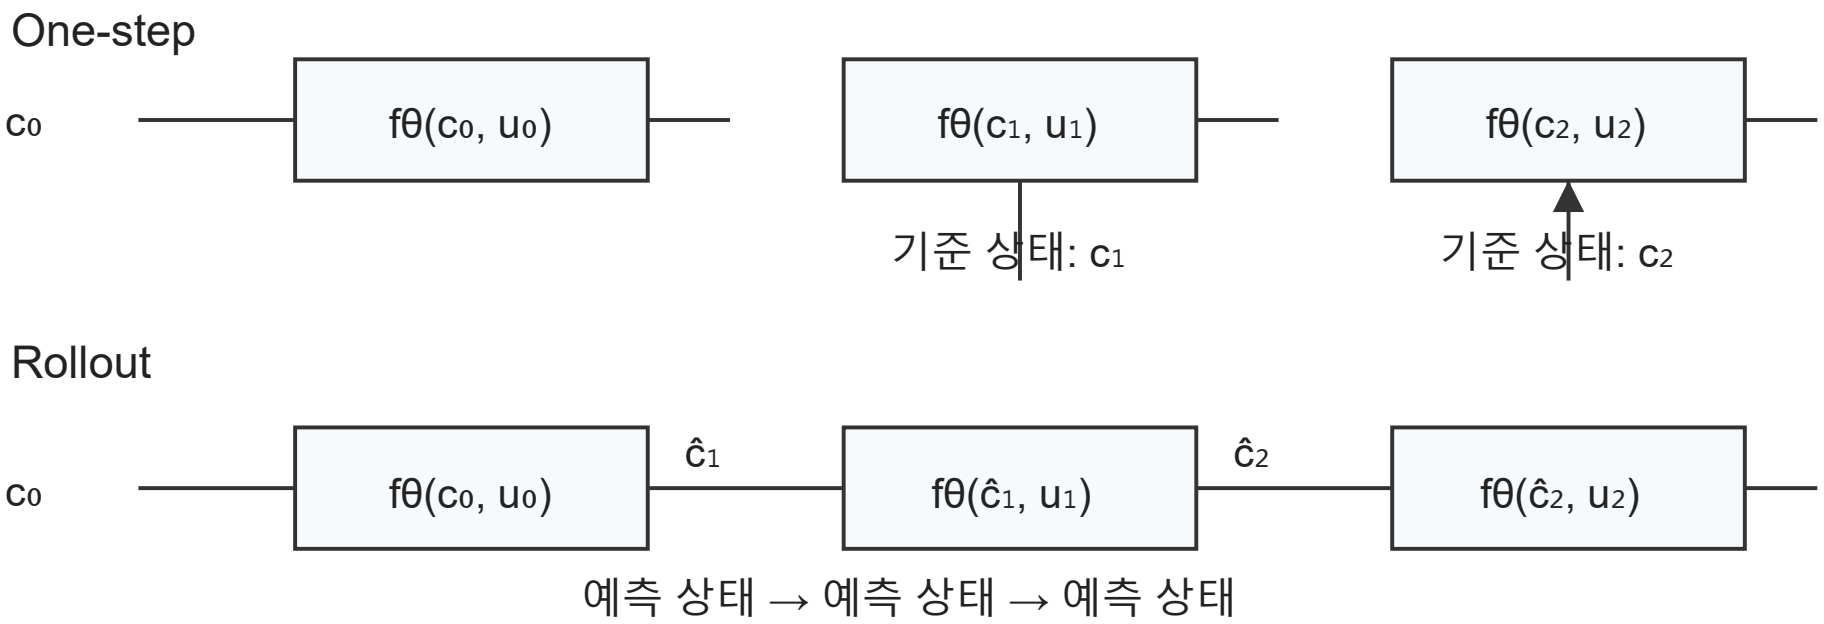
$$\text{one-step:}\hat{c}_{k+1} = f_\theta\left(c_k, u_k; q\right)$$
$$\text{rollout:}\hat{c}_{k+1} = f_\theta\left(\hat{c}_k, u_k; q\right), \hat{c}_0 = c_0$$

One-step에서는 매 시각 기준 상태를 입력으로 새로 넣습니다.

Rollout에서는 c_0에서 시작해 예측 상태를 다음 전이에 계속 넣습니다. 두 평가의 미래 입력과 context는 동일하게 유지

One-step은 매 시각 기준 상태를 다시 받으므로, 초기 상태에서 한 번만 시작하는 예측보다 더 많은 상태 정보를 사용합니다.

기준 상태 입력과 예측 상태 입력



다단계 rollout의 반복 계산

```
pred = np.empty((len(controls) + 1, 3))
pred[0] = initial_state
for k, control in enumerate(controls):
    pred[k + 1] = dynamic_step(
        model, scaling, pred[k:k+1], control[None, :]
    )[0]
```

초기화 후에는 기준 상태를 반복문에 넣지 않고 예측 상태 150개를 평가합니다.

한 단계 오차의 전달식

e_k = ĉ_k − c_k로 정의하고, 기준 상태에서 계산한 예측값을 더했다 빼봅니다.

$$e_{k+1} = f_\theta\left(\hat{c}_k, u_k\right) - f_\theta\left(c_k, u_k\right) + \delta_k$$
$$\delta_k = f_\theta\left(c_k, u_k\right) - F_{\Delta t}\left(c_k, u_k\right)$$

첫 번째 차이는 기존 상태 오차가 학습된 관계식을 거쳐 전달되는 부분. δ_k는 기준 상태에서의 한 단계 예측 오차로, 작더라도 매번 다음 예측에 더해집니다.

One-step 편향의 누적 예제

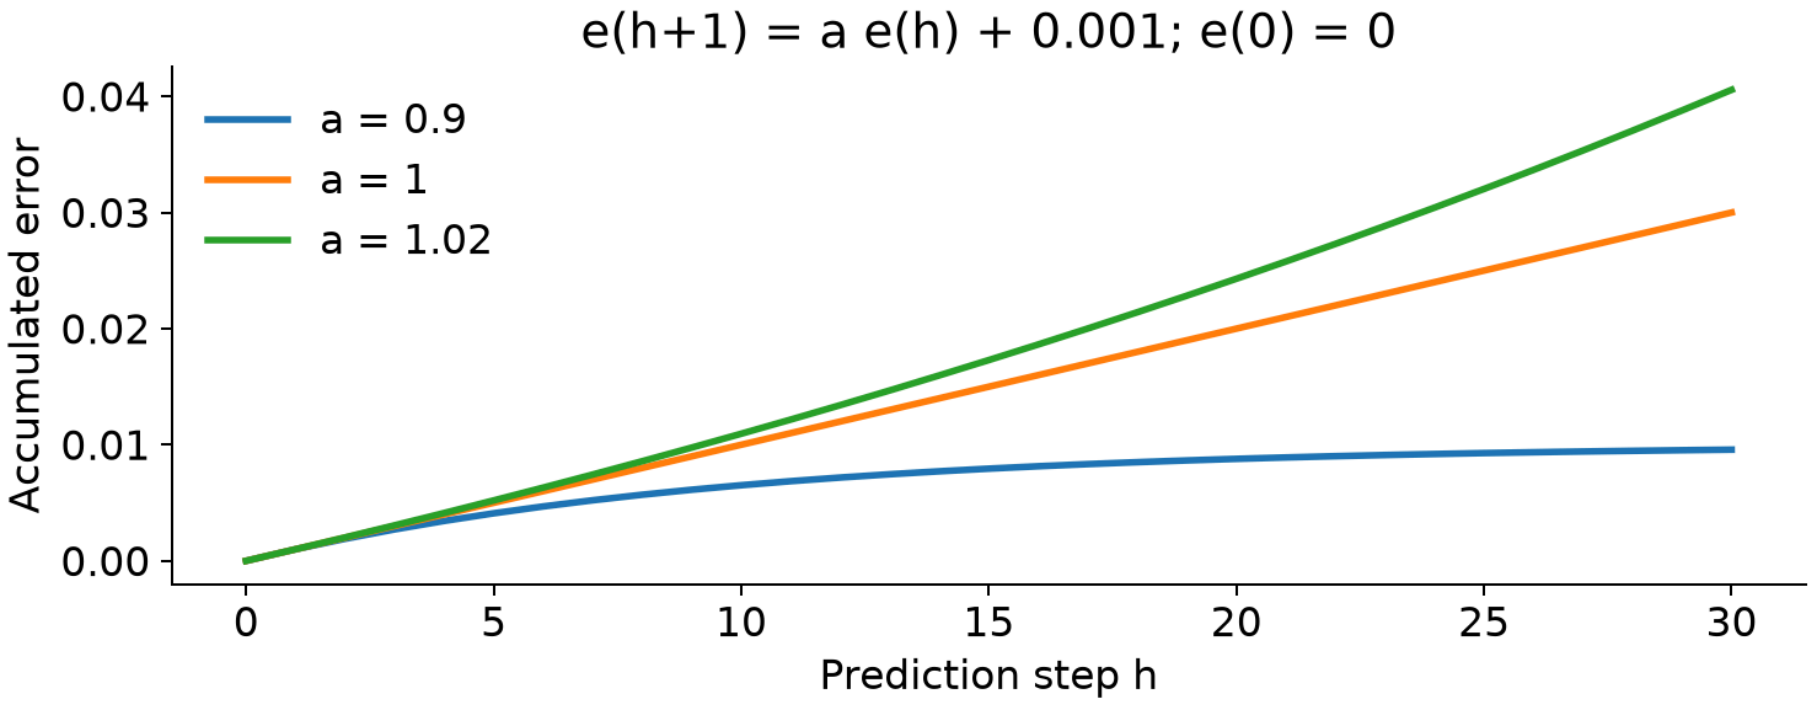
한 변수 예제에서 기준 관계식을 F(c) = 0.9c, 학습 모델을 f(c) = 0.9c + 0.001로 두고 $e_0 = 0$에서 시작합니다.

$$e_{h+1} = 0.9e_h + 0.001$$

$$e_h = 0.001\frac{1 - 0.9^h}{1 - 0.9}$$

One-step bias는 0.001이지만 10번 반복한 오차는 약 0.00651. 수축하는 관계식에서는 누적이 제한되며, 상태 민감도가 달라지면 예측 거리에 따른 오차도 달라집니다.

상태 민감도와 오차 전파



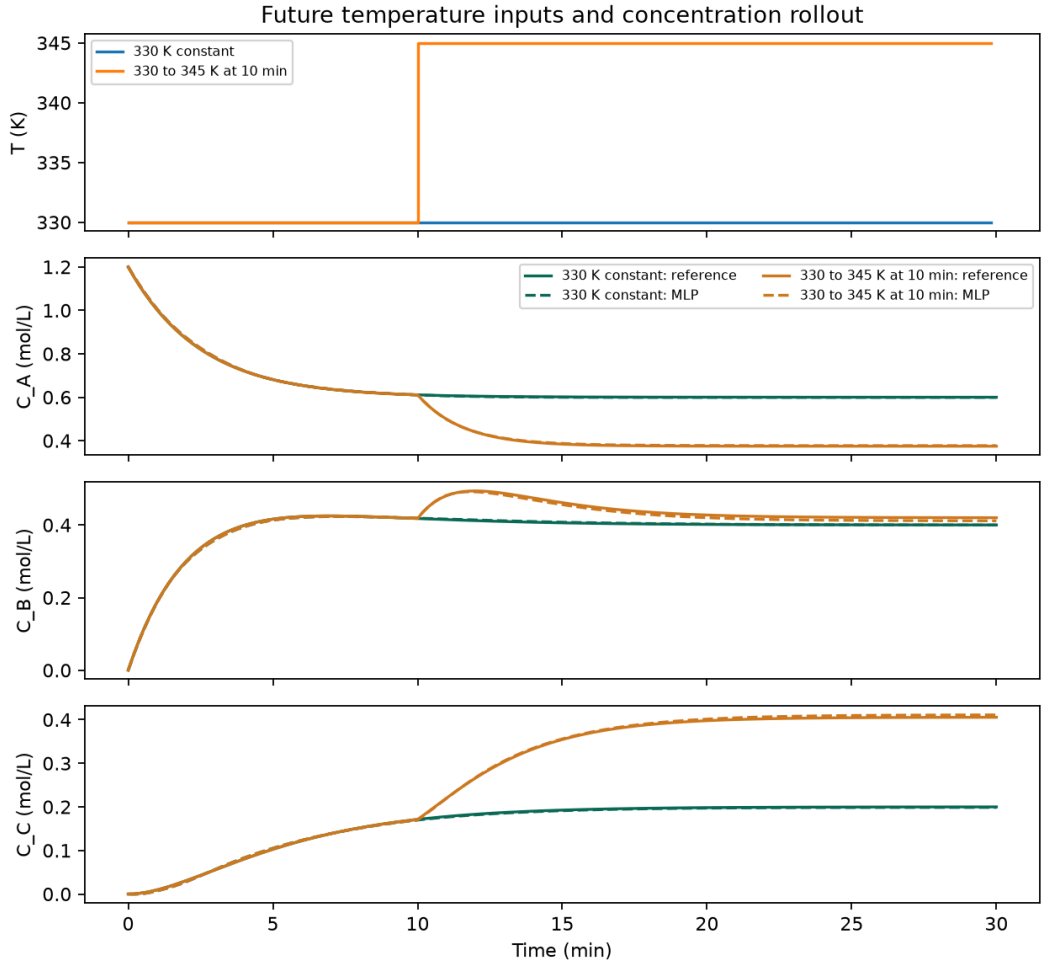
실제 rollout 오차는 증가하거나 완만해지거나 부호가 바뀔 수 있습니다.

주어진 두 온도 계획

조건	일정 온도 계획	온도 변경 계획
초기 조성, mol/L	[1.2, 0, 0]	[1.2, 0, 0]
τ; C_Af	5 min; 1.2 mol/L	5 min; 1.2 mol/L
$0 \le t < 10$ min	330 K	330 K
$10 \le t \le 30$ min	330 K	345 K

동일한 온도 계획에서 기준 궤적과 MLP rollout을 비교. 두 곡선이 달라지기 시작하는 시점과 새 정상상태 응답에 접근하는 과정을 살펴봅니다.

전체 시간에 걸친 A·B·C 농도



물리 단위에서 오차 비교하기

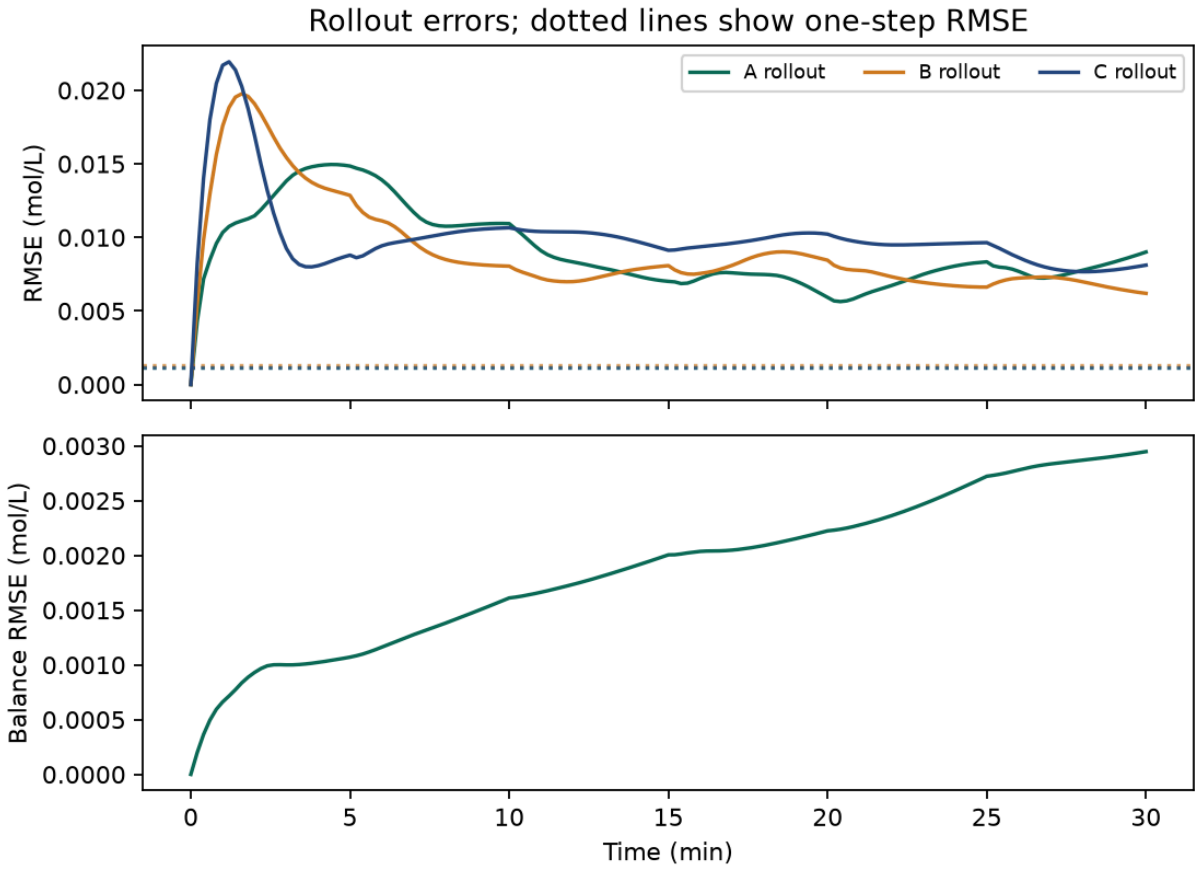
RMSE, mol/L	A	B	C
One-step	0.001170	0.001288	0.001163
Rollout	0.009465	0.009629	0.010425

독립 test 궤적 20개에서 궤적당 예측 시각 150개를 평가한 결과. 이번 실행에서는 rollout 오차가 더 큽니다. 예측 3000개의 성분별 RMSE를 계산하고 각 예측 거리의 오차도 따로 확인

$$\mathrm{RMSE}_{j,h} = \sqrt{\frac{1}{N}\sum_{n}\left(\hat{C}_{n,h,j} - C_{n,h,j}\right)^2}$$

n은 test 궤적, h는 상태전이 횟수, j는 성분을 뜻합니다.

Horizon에 따른 오차 읽기



궤적을 따라 물리적 일관성 확인하기

$$S = C_A + C_B + C_C, \frac{dS}{dt} = \frac{C_{\mathrm{Af}} - S}{\tau}$$

$$S_{k+1} = C_{\mathrm{Af}} + \left(S_k - C_{\mathrm{Af}}\right) e^{-\Delta \mathrm{t} / \tau}$$

$S_0 = C_Af$이고 유입 농도가 고정이면 기준 농도 합은 유입 농도와 같습니다. 학습 모델의 출력에는 이 관계가 자동으로 강제되지 않습니다.

진단, mol/L	One-step	Rollout
농도 합 residual RMSE	0.000051	0.002014
최소 예측 농도	-0.001152	-0.005166

온도 계획별 최종 B 농도 비교

30분 B 농도, mol/L	기준 모델	MLP rollout
일정 330 K	0.400091	0.399819
10분에 330 → 345 K	0.420021	0.411526

두 계산 모두 온도 변경 계획의 30분 B 농도가 더 높습니다. MLP는 그 최종 농도를 약 0.00850 mol/L 낮게 예측

시간에 따라 적용되는 제품 규격을 확인할 때는 마지막 표본과 함께 해당 구간 전체를 살펴야 합니다.

실습 실행과 제출

실습 묶음에서 기준 모델, 저장된 학습 모델, scaling, 그림과 Notebook을 받습니다.

```
python -m pip install -r requirements.txt
python week03_lab.py --output-dir week03-results
# 선택: 같은 데이터 구성으로 다시 학습하기
python week03_lab.py --train --output-dir week03-retrained
```

제출물: 상태·입력 정의, 데이터 분할·scaling, one-step·rollout RMSE, 예측 거리에 따른 오차 그림, 두 온도 계획의 궤적

연습문제와 읽기자료

1. dS/dt를 유도하고 S가 유입 농도와 같게 유지되는 조건을 적습니다.
2. 첫 0.2분 전이를 계산해 forward Euler와 비교
3. 두 평가에서 같은 MLP에 서로 다른 상태를 입력하는 이유를 설명합니다.
4. 입력 계획은 유지한 채 초기 상태를 바꿔 기준 궤적과 예측 궤적을 비교

읽기자료에서 유도·계산 예·코드와 답을 확인. 오차 전달식을 계산하고 multi-step 학습 목적함수는 선택 내용으로 다룹니다.

선택 확장: RNN·LSTM의 은닉 상태

필수 예제는 세 농도 상태와 주어진 온도를 모두 입력으로 받습니다. 필요한 상태가 측정에서 빠져 있다면 과거 관측과 입력으로 그 상태를 추정하는 방법이 도움이 될 수 있습니다.

$$h_k = \varphi\left(W_x x_k + W_h h_{k-1} + b\right)$$
$$\hat{y}_k = W_y h_k + b_y$$

RNN은 학습된 은닉 상태를 갱신하고 LSTM은 gate를 사용한 메모리 갱신을 추가합니다. 비교할 때는 궤적 분할과 예측에 제공하는 미래 정보를 같게 둡니다.

구현은 PyTorch RNN·LSTM을 참고합니다.

선택 확장: encoder와 궤적 decoder

Encoder는 과거 관측과 입력열을 상태 표현으로 요약합니다.

Decoder는 그 표현과 주어진 미래 입력 계획으로 미래 농도열을 예측. 각 미래 입력이 해당 예측 단계에 전달되도록 구성합니다.

Sutskever·Vinyals·Le (2014)의 1-2절에서 sequence-to-sequence 아이디어를 읽습니다.

논문 원문.