3주차 읽기자료: 상태전이와 궤적 예측

한 시작점에서 궤적 예측하기

현재 농도와 구간 동안 일정한 입력에서 다음 농도를 예측하는 F_Δt를 근사합니다. c_0와 $T_0,\ldots,T_{149}$가 주어지면 미래 상태 150개를 반복 계산합니다.

$$c_{k+1} = F_{\Delta t}\left(c_k, u_k; q\right)$$

Δt = 0.2 min이며 궤적 안에서는 τ·C_Af를 고정하고 구간 사이에서 T를 바꿉니다. 이상적인 혼합 상태에 세 성분 농도를 모두 포함하며 열적 동특성은 생략합니다.

필수 범위는 수지·구간 해·데이터 구성과 두 평가 반복문의 계산입니다. Sequence 모델은 선택 내용으로 다룹니다.

농도 수지 유도

부피 V와 유량 Q가 일정하면 τ = V/Q입니다. A가 농도 C_Af로 유입되어 B로 반응하고 B는 C로 반응하므로, 각 성분의 보유량 수지를 V로 나누어 농도 수지를 구합니다.

$$\frac{dC_A}{dt} = \frac{C_{\mathrm{Af}} - C_A}{\tau} - k_1 C_A$$

$$\frac{dC_B}{dt} = k_1 C_A - \frac{C_B}{\tau} - k_2 C_B$$

$$\frac{dC_C}{dt} = k_2 C_B - \frac{C_C}{\tau}$$

세 식을 더하면 반응 항이 상쇄되어 dS/dt = (C_Af − S)/τ를 얻습니다. 유입 농도가 고정이면 S(t) = C_Af + [S(0) − C_Af] exp(−t/τ)입니다.

S(0) = C_Af이면 합이 일정하게 유지되며, 초기 합이 다르면 유입 농도에 점차 접근합니다.

구간 해 유도

$$\frac{dc}{dt} = Mc + b$$

$$M = \begin{bmatrix} -1/\tau - k_1 & 0 & 0 \\ k_1 & -1/\tau - k_2 & 0 \\ 0 & k_2 & -1/\tau \end{bmatrix}, b = \begin{bmatrix} C_{\mathrm{Af}}/\tau \\ 0 \\ 0 \end{bmatrix}$$

Mc∗ + b = 0인 c∗를 사용해 z = c − c∗로 놓으면 dz/dt = Mz입니다. 구간 입력이 고정이면 z(t+Δt) = exp(MΔt)z(t)를 얻습니다.

$$F_{\Delta \mathrm{t}}\left(c, u; q\right) = c^* + e^{M\Delta \mathrm{t}}\left(c - c^*\right)$$

구간 경계에서 T가 바뀌어도 경계 상태를 유지한 채 다음 구간의 M과 c∗를 새로 계산하면 같은 식을 사용할 수 있습니다.

첫 전이 손 계산

330 K, $\tau = 5$ min, feed = 1.2 mol/L에서 $a = 1/\tau + k_1 = 0.4$, $b = 1/\tau + k_2 = 0.3$ min^{-1}입니다. 정상 조성은 $c^* = [0.6, 0.4, 0.2]$ mol/L이며, $\Delta t = 0.2$ min, $c_0 = [1.2, 0, 0]$에서 첫 전이를 계산합니다.

$$C_{A1} = C_A^{\,*} + \left(C_{A0} - C_A^{\,*}\right) e^{-a\Delta t}$$

$$C_{B1} = C_B^{\,*} + \left(C_{B0} - C_B^{\,*}\right) e^{-b\Delta t} + k_1 \left(C_{A0} - C_A^{\,*}\right) \frac{e^{-a\Delta t} - e^{-b\Delta t}}{b - a}$$

$C_{C,1} = S_1 - C_{A,1} - C_{B,1}$이므로 결과는 [1.153870, 0.045672, 0.000458] mol/L입니다.

Forward Euler의 결과는 [1.152, 0.048, 0]입니다. 구간 안에서도 반응속도가 바뀌므로 해석해와 차이가 납니다. $a = b$일 때 분수의 극한은 $\Delta t \exp(-a\Delta t)$입니다.

궤적을 학습 쌍으로 바꾸기

한 궤적의 states 배열 크기는 (151, 3), controls는 (150, 3)입니다. 궤적별로 분할한 후 행을 쌓습니다.

```
inputs = np.column_stack((states[:-1], controls))
increments = states[1:] - states[:-1]
# inputs: (150, 6); increments: (150, 3)
x_mean = train_inputs.mean(axis=0)
x_scale = np.maximum(train_inputs.std(axis=0), 1e-8)
d_mean = train_increments.mean(axis=0)
d_scale = np.maximum(train_increments.std(axis=0), 1e-8)
```

첫 입력 행은 c_0와 첫 구간 입력, 마지막 입력 행은 c_{149}와 마지막 구간 입력입니다. 마지막 label은 c_{150}이며, scaling에는 test 통계량을 사용하지 않습니다.

변화량 복원과 두 평가 반복문

$$\Delta c_k = c_{k+1} - c_k$$
$$\hat{c}_{k+1} = c_k + \mu_\Delta + s_\Delta \odot g_\theta\left(\tilde{v}_k\right)$$

```
# 매 단계 기준 현재 상태를 제공
one_step = dynamic_step(model, scaling,
                        states[:-1], controls)
# 초기 상태만 제공
recursive = rollout(model, scaling, controls, states[0])
err_one = one_step - states[1:]
err_roll = recursive[1:] - states[1:]
```

복원한 Δc를 c에 더합니다. 전체 성분별 RMSE는 초기 상태를 제외한 모든 test 시각을 모아 계산하고, RMSE_j,h는 예측 거리 축을 유지해 계산합니다. 두 반복문에는 같은 미래 입력을 제공합니다.

오차 전달식 유도

$$e_{k+1} = f_\theta\left(\hat{c}_k, u_k\right) - f_\theta\left(c_k, u_k\right) + \delta_k$$
$$\delta_k = f_\theta\left(c_k, u_k\right) - F_{\Delta t}\left(c_k, u_k\right)$$

학습한 관계식이 c_k와 ĉ_k 사이에서 L_k-Lipschitz 조건을 만족하면 아래 부등식을 얻습니다.

$$\left\|e_{k+1}\right\| \le L_k \left\|e_k\right\| + \left\|\delta_k\right\|$$

L과 한 단계 오차 상한 ε이 일정할 때 반복 대입합니다.

$$\left\|e_h\right\| \le L^h \left\|e_0\right\| + \varepsilon \sum_{r=0}^{h-1} L^r$$

$e_0 = 0$에서 $L < 1$이면 상한은 $\varepsilon/(1-L)$ 이하이고 $L = 1$이면 $h\varepsilon$입니다. 이 민감도와 오차 상한은 실제로 거치는 상태에서 유효해야 하며, test RMSE 자체를 상한으로 사용할 수는 없습니다.

선택: 여러 전이를 거쳐 학습하기

Multi-step loss는 기준 상태에서 시작해 예측 상태를 H단계 반복 입력하며 궤적 오차를 벌점으로 줍니다. 성분별 scaling은 일관되게 적용합니다.

$$L_H = \frac{1}{NH} \sum_n \sum_h \left\| \hat{c}_{n,h} - c_{n,h} \right\|_2$$

Gradient는 펼친 각 전이를 거쳐 전달됩니다. 모델이 학습 중 자신의 예측 상태를 경험하게 할 수 있지만 메모리 사용이 늘고 학습이 어려워질 수 있습니다. Train 궤적 안에서만 window를 만들고 H는 validation 궤적으로 선택합니다.

제공된 실험 결과는 one-step 학습 결과입니다. Multi-step 학습의 성능은 확장 과제에서 직접 비교합니다.

연습문제와 짧은 답 확인

1. 상태가 151개인 이유: 30분에는 0.2분 구간 150개와 초기 상태가 있습니다.
2. 파라미터 수: 224 + 1056 + 99 = 1379입니다.
3. S_0가 feed와 다른 경우: 기준 합은 $\text{feed} + (S_0 - \text{feed})\exp(-t/\tau)$로 변하므로 일정한 합을 검사하면 잘못된 진단이 됩니다.
4. 한 변수 예제의 h = 10 오차: $0.001(1-0.9^{10})/0.1 \approx 0.006513$입니다.
5. Δt = 1분으로 바꿔 실행하는 경우: 학습한 출력은 여전히 0.2분 변화량입니다. 다섯 번 적용하거나 새 간격의 관계식을 학습해야 합니다.
6. Rollout 중간에 기준 상태를 넣는 경우: 예측을 다시 시작한 것이므로 reset 시각을 적고 해당 평가 방식을 따로 보고합니다.

선택 sequence 모델과 원문

관측이 불완전하면 RNN/LSTM의 은닉 상태로 가용한 과거 정보를 요약할 수 있습니다. Encoder-decoder는 관측 이력과 주어진 미래 입력으로 미래 상태열을 예측하며, encoder에는 미래 측정값을 넣지 않습니다.

- Sutskever·Vinyals·Le (2014), 1-2절: sequence의 encoding·decoding을 다룹니다. 원 모델의 응용은 번역입니다.
- PyTorch RNN·LSTM: 반복 갱신, 입력, 은닉 상태와 출력을 확인합니다.
- SciPy matrix exponential: exp(MΔt)의 다른 구현 방법을 확인합니다.