

3주차 읽기자료: 상태전이와 궤적 예측

한 시작점에서 궤적 예측하기

핵심 과제는 $F_{\Delta t}$ 를 근사하는 것이다. 현재 농도와 구간 동안 일정한 입력에서 다음 농도를 예측한다. c_0 와 $T_0, \dots, T_{149}$ 가 주어지면 미래 상태 150개를 반복 계산한다.

$$c_{k+1} = F_{\Delta t}(c_k, u_k; q)$$

$\Delta t = 0.2 \text{ min}$, 궤적 내 $\tau \cdot C_{Af}$ 는 고정한다. T 는 구간 사이에서 바뀐다. 이상적 혼합 상태는 세 성분 농도를 모두 포함하며 열적 동특성은 생략한다.

수지·구간 해·데이터 구성·두 평가 반복문을 먼저 계산하고, sequence 모델은 선택 내용으로 읽는다.

농도 수지 유도

부피 V 와 유량 Q 가 일정하면 $\tau = V/Q$ 다. 각 성분의 보유량 수지를 V 로 나눈다. A 가 C_{Af} 로 들어오고 B 로 반응하며, B 는 C 로 반응한다.

$$\begin{aligned}\frac{dC_A}{dt} &= \frac{C_{Af} - C_A}{\tau} - k_1 C_A \\ \frac{dC_B}{dt} &= k_1 C_A - \frac{C_B}{\tau} - k_2 C_B \\ \frac{dC_C}{dt} &= k_2 C_B - \frac{C_C}{\tau}\end{aligned}$$

세 식을 더하면 반응 항이 상쇄되어 $dS/dt = (C_{Af} - S)/\tau$ 다. 유입 농도가 고정이면 $S(t) = C_{Af} + [S(0) - C_{Af}] \exp(-t/\tau)$ 다.

$S(0) = C_{Af}$ 이면 합이 일정하다. 초기 합이 다르면 유입 농도로 점차 다가간다.

구간 해 유도

$$\frac{dc}{dt} = Mc + b$$
$$M = \begin{bmatrix} -1/\tau - k_1 & 0 & 0 \\ k_1 & -1/\tau - k_2 & 0 \\ 0 & k_2 & -1/\tau \end{bmatrix}, b = \begin{bmatrix} C_{Af}/\tau \\ 0 \\ 0 \end{bmatrix}$$

$Mc^* + b = 0$ 인 c^* 를 이용해 $z = c - c^*$ 로 두면 $dz/dt = Mz$ 다. 구간 입력이 고정이면 $z(t+\Delta t) = \exp(M\Delta t)z(t)$ 다.

$$F_{\Delta t}(c, u; q) = c^* + e^{M\Delta t}(c - c^*)$$

경계에서 T 가 바뀌어도 같은 식을 쓸 수 있다. 경계 상태는 유지하고 다음 구간의 M 과 c^* 를 새로 계산한다.

첫 전이 손 계산

330 K, $\tau = 5$ min, feed = 1.2 mol/L이면 $a = 1/\tau + k_1 = 0.4$, $b = 1/\tau + k_2 = 0.3 \text{ min}^{-1}$ 다. 정상 조성은 $c^* = [0.6, 0.4, 0.2] \text{ mol/L}$ 다. $\Delta t = 0.2$ min, $c_0 = [1.2, 0, 0]$ 이면:

$$C_{A_1} = C_A^* + (C_{A_0} - C_A^*)e^{-a\Delta t}$$
$$C_{B_1} = C_B^* + (C_{B_0} - C_B^*)e^{-b\Delta t} + k_1(C_{A_0} - C_A^*)\frac{e^{-a\Delta t} - e^{-b\Delta t}}{b - a}$$

$C_{C,1} = S_1 - C_{A,1} - C_{B,1}$ 이므로 **[1.153870, 0.045672, 0.000458] mol/L**다.

Forward Euler는 [1.152, 0.048, 0]이다. 구간 안에서 반응속도가 바뀌므로 값이 다르다. $a = b$ 이면 분수의 극한은 $\Delta t \exp(-a\Delta t)$ 다.

궤적을 학습 쌍으로 바꾸기

한 궤적의 states shape는 (151, 3), controls shape는 (150, 3)이다. 궤적별로 분할한 뒤 행을 쌓는다.

```
inputs = np.column_stack((states[:-1], controls))
increments = states[1:] - states[:-1]
# inputs: (150, 6); increments: (150, 3)
x_mean = train_inputs.mean(axis=0)
x_scale = np.maximum(train_inputs.std(axis=0), 1e-8)
d_mean = train_increments.mean(axis=0)
d_scale = np.maximum(train_increments.std(axis=0), 1e-8)
```

첫 입력 행은 c_0 와 첫 구간 입력이다. 마지막은 c_{149} 와 마지막 입력이고 label은 c_{150} 다. Scaling에 test 통계량은 들어가지 않는다.

변화량 복원과 두 평가 반복문

$$\Delta c_k = c_{k+1} - c_k$$
$$\hat{c}_{k+1} = c_k + \mu_{\Delta} + s_{\Delta} \odot g_{\theta}(\tilde{v}_k)$$

```
# 매 단계 기준 현재 상태를 제공
one_step = dynamic_step(model, scaling,
                        states[:-1], controls)

# 초기 상태만 제공
recursive = rollout(model, scaling, controls, states[0])
err_one = one_step - states[1:]
err_roll = recursive[1:] - states[1:]
```

Δc 를 복원한 뒤 c 에 더한다. 전체 성분별 RMSE는 초기 상태를 뺀 모든 test 시각을 모아 계산한다. RMSE_{j,h}는 horizon 축을 유지해 계산한다. 두 반복문은 같은 미래 입력을 쓴다.

오차 전달식 유도

$$\begin{aligned}e_{k+1} &= f_{\theta}(\hat{c}_k, u_k) - f_{\theta}(c_k, u_k) + \delta_k \\ \delta_k &= f_{\theta}(c_k, u_k) - F_{\Delta t}(c_k, u_k)\end{aligned}$$

학습 mapping이 c_k 와 $\hat{c}_k$ 사이에서 L_k -Lipschitz이면:

$$\|e_{k+1}\| \leq L_k \|e_k\| + \|\delta_k\|$$

L 과 한 단계 오차 상한 ε 이 일정하면 반복 대입으로:

$$\|e_h\| \leq L^h \|e_0\| + \varepsilon \sum_{r=0}^{h-1} L^r$$

$e_0 = 0$ 일 때 $L < 1$ 이면 상한은 $\varepsilon/(1-L)$ 이하이고, $L = 1$ 이면 $h\varepsilon$ 다. 실제로 거치는 상태에서 유효한 민감도와 오차 상한이 필요하다. Test RMSE 자체가 그 상한은 아니다.

선택: 여러 전이를 거쳐 학습하기

Multi-step loss는 기준 상태에서 시작해 예측 상태를 H단계 반복 입력하고 궤적 오차를 벌점으로 준다. 성분 scaling을 일관되게 적용한다.

$$L_H = \frac{1}{NH} \sum_n \sum_h \left\| \hat{c}_{n,h} - c_{n,h} \right\|^2$$

Gradient는 펼친 각 전이를 거쳐 전달된다. 학습 중 모델 자신의 상태를 경험하게 할 수 있지만 메모리가 늘고 학습이 어려워질 수 있다. Train 궤적 안에서만 window를 만들고 H는 validation 궤적으로 선택한다.

저장된 핵심 실험은 one-step 학습이다. Multi-step 비교는 직접 실행할 확장 과제이며, 이미 얻은 실험 결과로 제시하지 않는다.

연습문제와 짧은 답 확인

1. 왜 상태가 151개인가? 30분에는 0.2분 구간 150개와 초기 상태가 있다.
2. 파라미터 수는? $224 + 1056 + 99 = 1379$ 다.
3. S_0 가 feed와 다르면? 기준 합은 $\text{feed} + (S_0 - \text{feed})\exp(-t/\tau)$ 로 변한다. 일정한 합을 검사하면 잘못된 진단이다.
4. 한 변수 예의 $h = 10$ 오차는? $0.001(1 - 0.9^{10})/0.1 \approx 0.006513$ 이다.
5. 변수만 바꾸어 $\Delta t = 1$ 분으로 실행할 수 있나? 학습된 출력은 여전히 0.2분 변화량이다. 다섯 번 적용하거나 새 간격의 mapping을 학습한다.
6. Rollout 중간에 기준 상태를 넣으면? 예측을 다시 시작한 것이다. Reset 시각을 적고 그 평가 방식을 따로 보고한다.

선택 sequence 모델과 원문

관측이 불완전하면 RNN/LSTM hidden state로 가용한 과거 정보를 요약할 수 있다. Encoder-decoder는 관측 이력에서 미래 sequence를 만들되 주어진 미래 입력을 조건으로 사용한다. 미래 측정값을 encoder에 넣지 않는다.

- Sutskever·Vinyals·Le (2014), [1-2절](#): sequence encoding·decoding. 원 모델의 응용은 번역이다.
- PyTorch [RNN·LSTM](#): 반복 갱신, 입력, hidden state와 출력.
- SciPy [matrix exponential](#): $\exp(M\Delta t)$ 의 다른 구현 방법.

CSTR 유도과 계산 연습은 이 과목을 위해 직접 작성했다.